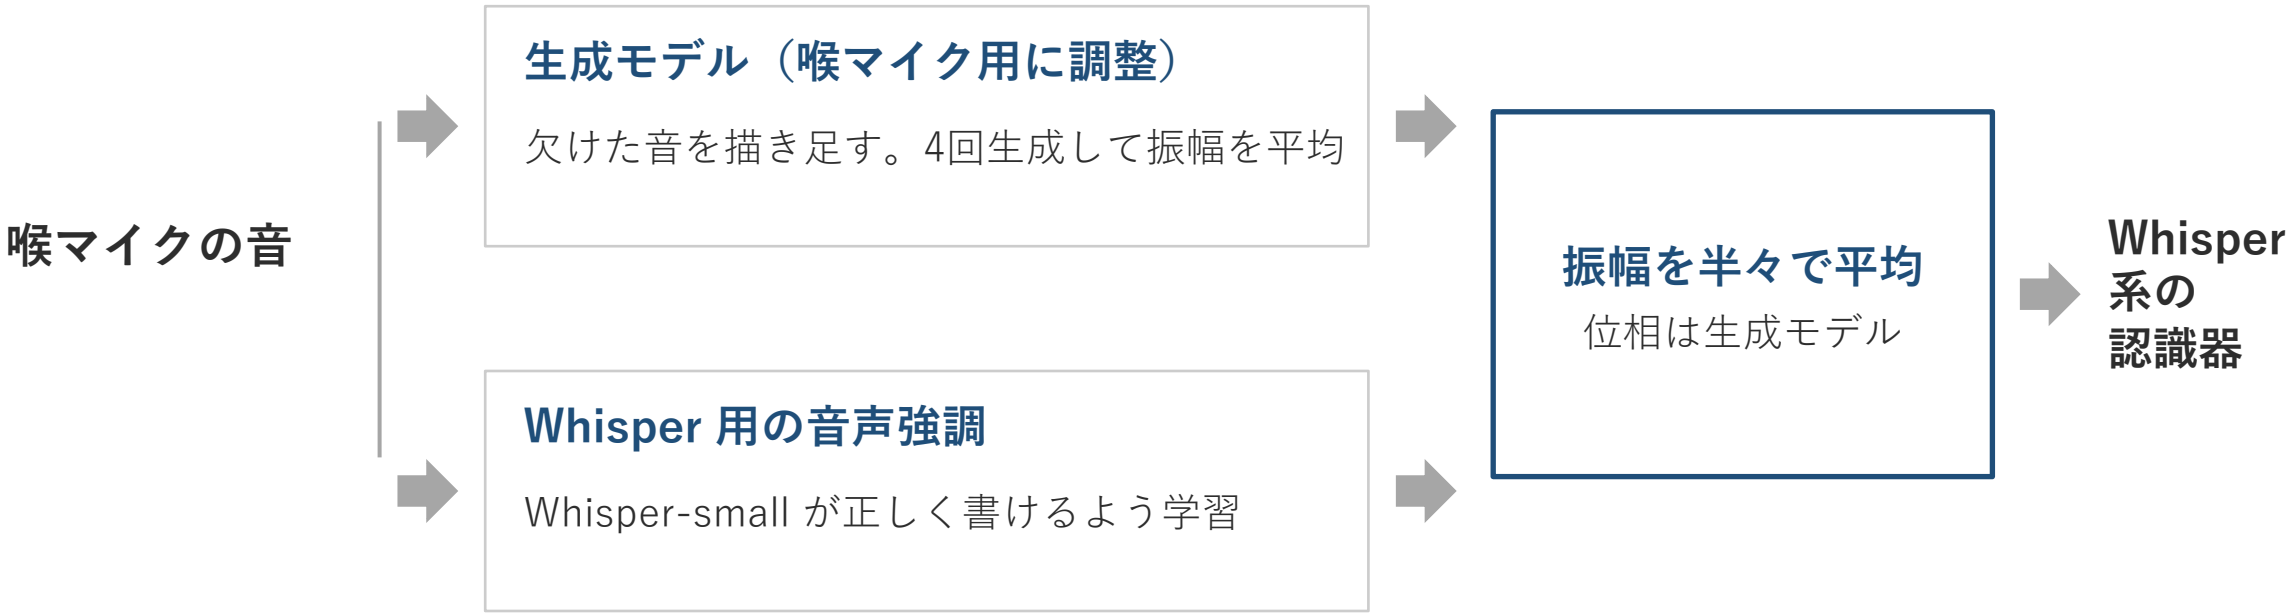
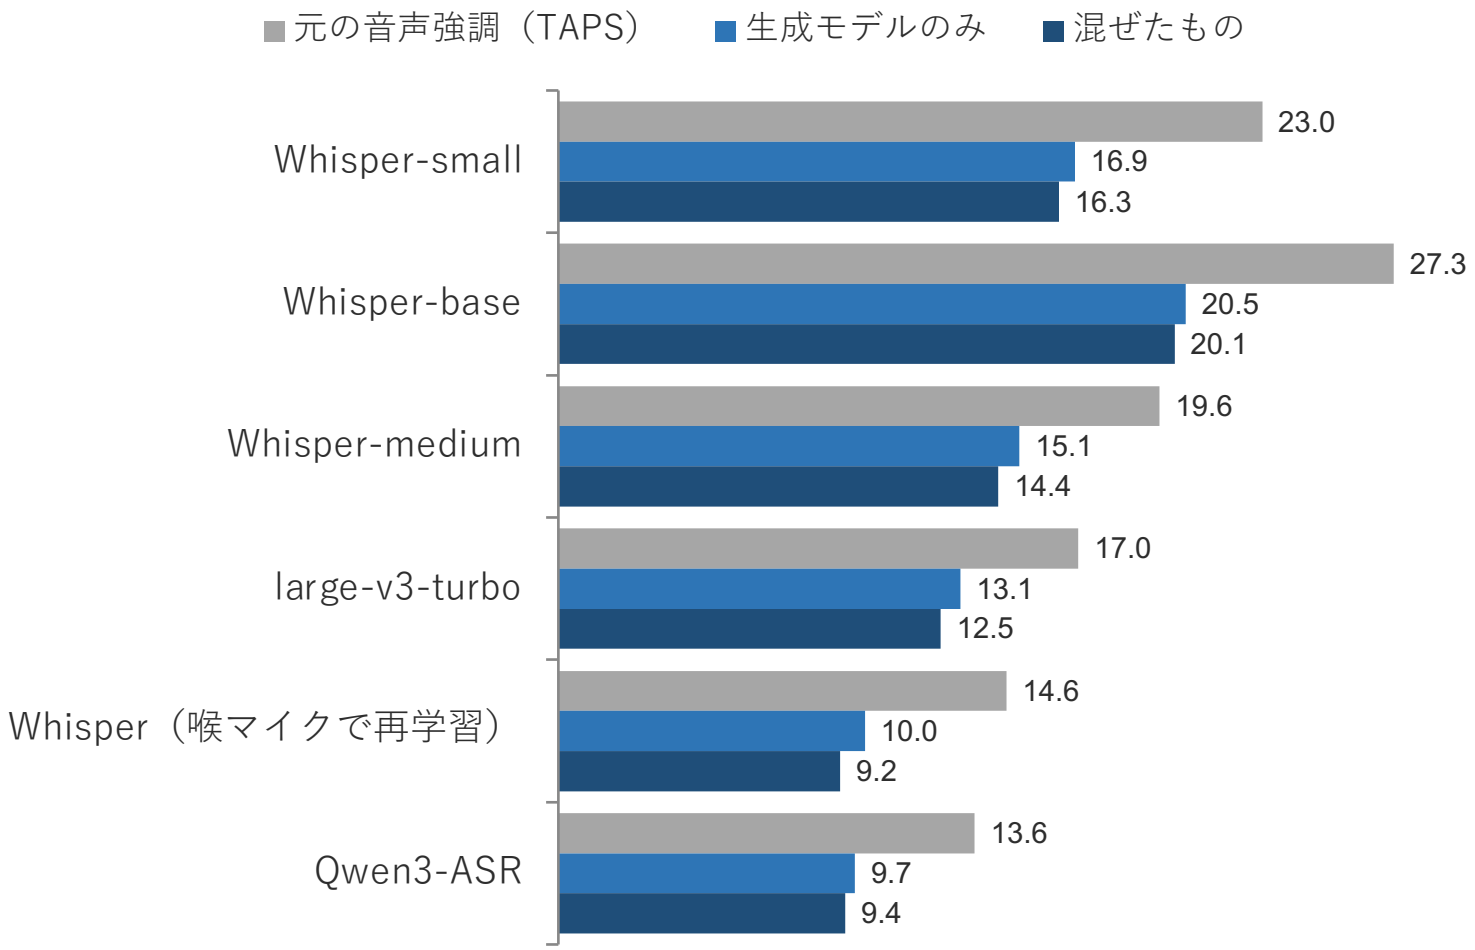
生成モデルの出力に、Whisper 用の音声強調を半分混ぜる



- 混ぜる割合 0.5 は、開発データで Whisper-small だけを見て決めた
- 新たな学習は不要（部品はどちらも学習済み）

生成モデル: NVIDIA の flow matching（4.3億パラメータ、Ku et al., arXiv:2409.16117）を TAPS で追加学習

混ぜると、Whisper 系6つすべてで誤りがさらに減った



- 元の音声強調より**26〜37% 減**
- 生成モデルのみより**2〜8% 減**
- 学習に使っていない Whisper にも効いた

文字誤り率（%）、TAPS テスト 1000発話。生成モデルのみとの差は 4つで有意（medium・turbo・再学習 Whisper・small）

他の認識器への悪影響は、混ぜ方を工夫すればほぼ消せる

	生成モデルのみ	混ぜたもの	混ぜ方を工夫
Whisper-small	16.9	16.3	16.2
Whisper-base	20.5	20.1	19.9
Whisper（再学習）	10.0	9.2	9.2
Qwen3-ASR	9.7	9.4	9.3
XLS-R（対照）	16.1	16.3	16.1
Zipformer（対照）	43.3	**48.3**	**44.2**

- 混ぜると、Whisper 以外の Zipformer は**12% 悪化**
- 工夫：音声強調の重みを**3割元に戻し、対数で**混ぜる
- Whisper 系はそのままで、**悪化は 2% に縮小**

文字誤り率（%）。工夫 = Whisper 用音声強調と元の音声強調の重みを 7:3 で内挿し、生成モデルの出力と対数振幅で平均

欠けた音の補完と Whisper への合わせ込みは、分けて設計できる

分かったこと

1. Whisper 用に学習すると、他の認識器では悪化

作りの違う XLS-R・Zipformer では誤りが 26〜46% 増える

2. 生成モデルは、どの認識器にも効く

9つすべてで誤りが 15〜24% 減る。効果の源は事前学習

3. Whisper に効くのは「声の大まかな形」

母音などを決める周波数の山の形（スペクトル包絡）。
細かい倍音だけ混ぜても効かない

4. 他の認識器への害は「元々無い高い音」から

喉マイクに無い 4 kHz 以上を Whisper 向けに作った成分。
4 kHz 未満だけ混ぜれば害は出ない

この研究の価値

前処理だけで誤り 26〜37% 減

クラウドの認識器など、中身を変えられない
Whisper 系にも使える

設計の指針になる

欠けた音は生成モデルで補い、
Whisper 向けの調整は外側で控えめに足す

限界：TAPS で学習した部品は、別機種の喉マイク（VibraVox、仏語）にはそのままでは効かない（機種ごとの適応が必要）