Whisper 系音声認識に向けた喉マイク音声強調における事前学習済み生成モデルと ASR 損失の役割[*1]

春日　裕次（明治大学　総合数理学部　先端メディアサイエンス学科）

1　はじめに

喉マイクは頸部の振動を接触型センサで捉えるため環境騒音に強く、工場や建設現場のような騒音下での音声入力や通話に使われる。一方、軟組織の伝搬特性により高域が大きく失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] では喉マイクが 8 kHz で収録されており、4 kHz 以上は収録時点から存在しない。Whisper-small [2] で喉マイク音声をそのまま認識すると文字誤り率（CER）は 0.446 に達する。

前処理としての音声強調（SE）は有力な対策であるが、知覚品質の改善が音声認識（ASR）の改善を保証しないことが知られている [3]。この乖離に対し、凍結した ASR の損失で SE を学習する方法が提案されてきた [4, 5]。しかし、損失に用いた認識器以外への効果は十分に調べられていない。本稿の実験でも、Whisper-small の交差エントロピー（CE）損失で学習した喉マイク SE は、Whisper では CER を下げる一方、入力特徴量の異なる認識器では悪化した（4.1 節）。ASR 損失で学習した SE は、損失に用いた認識器の入力特徴量に特化しうる。

一方、喉マイクの問題は雑音の混入ではなく帯域や子音の欠落であり、欠けた成分を補う必要がある。大規模音声で事前学習した生成モデル [6] は、入力が持たない成分を自然な音声として生成できる。体内伝導マイクではこの種の生成モデルの適応が有効との報告がある [7] が、評価は単一の認識器に限られる。また、生成的な帯域拡張や声質変換が喉マイク音声の CER を悪化させたという報告もある [8]。

本稿では対象を Whisper と同じ対数メルスペクトログラムを入力とする認識器（以下 Whisper 系）に定め、損失と設定の選択には Whisper-small のみを用い、他の Whisper 系 5 種を評価専用とする。構成を図 1に示す。そのうえで次の 4 点を示す。(1) 事前学習済みの flow matching 生成モデルを TAPS で適応すると、入力特徴量の異なる認識器を含む 9 種すべてで CER が下がり、効果は事前学習に由来する。(2) その出力に Whisper 用 SE の出力を振幅で融合すると、学習に用いていない Whisper 系にも上乗せが得られ、既存手法より良い。(3) Whisper 系への上乗せは主にスペクトル包絡から生じ、他系統の認識器への害は喉マイクに元々存在しない 4 kHz 以上の成分から生じる。この害は簡単な変更でほぼ解消できる。(4) TAPS で学習した部品は別機種・別言語の喉マイクにはそのままでは効かないが、同じ手順で適応し直すと同じ結論が再現する。

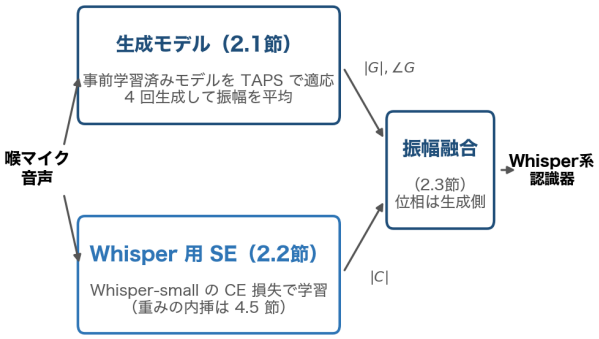


図1: 手法の全体像。喉マイク音声を生成モデルと Whisper 用 SE の両方に通し、出力の振幅を融合して Whisper 系の認識器に入力する

2　方法

2.1　生成モデルによる復元

NVIDIA が公開している flow matching [9] 型の音声復元モデル（4.3 億パラメータ、複素 STFT 領域）[6] を用いる。大規模音声でマスク区間の復元により事前学習されたモデルである。本研究では TAPS の喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する（ASR の損失は用いない）。推論では標準正規分布の雑音から出発し、喉マイク音声を条件として常微分方程式を Euler 法 20 ステップで解く。

生成は出発点の雑音に依存して発話ごとにばらつく。そこで乱数の種を変えた N 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる。

$$|G| = \frac{1}{N}\sum_{n=1}^{N}|G_n|, \qquad \angle G = \angle G_1 \tag{1}$$

[*1] Roles of a pretrained generative model and ASR-loss enhancement in throat-microphone speech enhancement for Whisper-family recognizers, by KASUGA, Yuji (Meiji University).

2.2 Whisper 用 SE

TAPS 論文 [1] の SE-Conformer（1210 万パラメータ、以下 TAPS SE）を初期値とし、次の損失で追加学習したモデル（以下 CE-SE）を用いる。

$$L = L_{\mathrm{recon}}(\hat{s}, s_{\mathrm{air}}) + \lambda\,\mathrm{CE}(\mathrm{Whisper}(\hat{s}), y) \qquad (2)$$

$\hat{s}$ は SE 出力、s_{air} は気導音声、y は正解テキスト、L_{recon} は L1 波形損失と多重解像度 STFT 損失の和である。Whisper-small は凍結し、λ は dev の CER で $\{0, 0.1, 0.5, 1, 2, 5, 10\}$ から選んで $\lambda = 10$ とした。

2.3 振幅融合

生成モデルの出力 G（$N = 4$ の平均）と CE-SE の出力 C を、STFT（512 点、シフト 128 点）の振幅で重み付き平均し、位相は生成モデルのものを用いる。

$$Y = \left\{(1 - w)|G| + w|C|\right\} e^{j\angle G} \qquad (3)$$

w は、生成 1 回の出力との融合を dev で比べ、Whisper-small の CER のみを見て $\{0.25, 0.5, 0.75\}$ から選んだ（CER はそれぞれ 0.202・0.196・0.198）。test では同じ $w = 0.5$ を 4 サンプル平均との融合に用いた。融合に新たな学習は要らない。以下、この融合を融合 A と呼ぶ。

3 実験条件

3.1 データと学習

TAPS [1] の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各話者 100 発話）を用いた。生成モデルは train の 4,000 対で 20k step 追加学習した（batch 8、6.14 秒の切り出し、学習率 10^{-4}、EMA、32 ビット浮動小数点）。モデルの選択には最終ステップを用い、test を見て選んでいない。test は学習と話者が重ならないが、収録機種・言語・文の種類は学習と同じであり、データセットとしてはクローズドな評価である。別データセットでの評価は 4.4 節で行う。CE-SE は Adam（学習率 3×10^{-4}、batch 4）で最大 50 エポック学習し、dev の損失で early stopping を行った。15 秒を超える発話は学習から除外した。

3.2 比較手法

TAPS SE、CE-SE に加え、2 つの既存手法を比較した。SSL-MSE は、SE 出力と気導音声の WavLM-Large [10] 全層の表現の二乗誤差を再構成損失に加えて TAPS SE を追加学習したもので、Sato ら [5] の方式に従う。Dissen 型は、凍結した ASR の損失で前段を学習する方法 [4] に倣い、喉マイクの対数メルを入出力とする U-Net（約 700 万パラメータ）を Whisper-small の CE で学習したものである。

3.3 認識器と評価

Whisper 系。 Whisper-small（損失と選択に使用）、Whisper-base、Whisper-medium、Whisper-large-v3-turbo、TAPS の喉マイク音声でファインチューニングした Whisper-small（FT Whisper）、Qwen3-ASR-1.7B の 6 種である。Qwen3-ASR のエンコーダは Whisper と異なるが、入力は同形式の対数メル（128 次元）である。Whisper は faster-whisper（CTranslate2）で言語を韓国語に指定して認識した。

入力特徴量の異なる認識器。 Whisper 系への特化を確認する対照として、波形入力の CTC 型である MMS-1B [11] と XLS-R [12]（韓国語で追加学習したもの）、Kaldi 型のフィルタバンクを入力とする Zipformer [13] を用いた。

指標。 test 1,000 発話で、正解と認識結果の双方から句読点を除いた CER を発話ごとに求め（1.0 で打ち切り）、平均した。Zipformer は空白を含めた CER である。同一話者の発話は独立でないため、話者ごとの平均 CER を単位とする Wilcoxon 符号順位検定（$n = 10$、最小の $p = 0.002$）を用いた。

4 実験結果

4.1 生成モデルの効果

表 1に各手法の CER を、図 2に TAPS SE 比の相対変化を示す。生成モデル（1 回の生成）は 9 種の認識器すべてで TAPS SE より CER を 15〜24% 下げ、いずれも 10 話者全員で改善した（$p = 0.002$）。崩れた発話や出力長の変化はなく、作り話の兆候は見られなかった。同じ構造・同じ学習量で初期値を乱数としたモデルは、Whisper-small で 0.551 と TAPS SE より大幅に悪化し、効果は事前学習に由来する。

一方、CE-SE 単体は Whisper 系では TAPS SE より CER を下げたが、XLS-R では 25.8%、Zipformer では 45.9% 悪化した。ASR 損失による改善は、入力特徴量の異なる認識器には及ばない。

4.2 融合と既存手法との比較

4 サンプルの振幅平均（生成 ×4）は、生成のばらつきを抑え、1 回の生成よりさらに CER を下げた（Whisper-small 0.180→0.169）。融合 A は、Whisper 系の 6 種すべてで生成 ×4 より CER を下げ（−1.8〜−8.0%、4

表1: 各手法の test CER。TAPS: TAPS SE、SSL: SSL-MSE、生成 $\times N$: 生成モデルの N サンプル平均、W-FT: FT Whisper、*: 損失・選択に使用

認識器	TAPS	CE-SE	SSL	生成 ×1	生成 ×4	融合 A
W-small*	0.230	0.196	0.204	0.180	0.169	**0.163**
W-base	0.273	0.267	0.241	0.218	0.205	**0.201**
W-medium	0.196	0.169	0.177	0.159	0.151	**0.144**
W-turbo	0.170	0.142	0.153	0.137	0.131	**0.125**
W-FT	0.146	0.121	0.124	0.110	0.100	**0.092**
Qwen3	0.136	0.114	0.114	0.104	0.097	**0.094**
XLS-R	0.222	0.279	0.190	0.169	**0.161**	0.163
MMS-1B	0.350	0.354	0.321	0.297	**0.284**	0.285
Zipformer	0.542	0.791	0.486	0.451	**0.433**	0.483

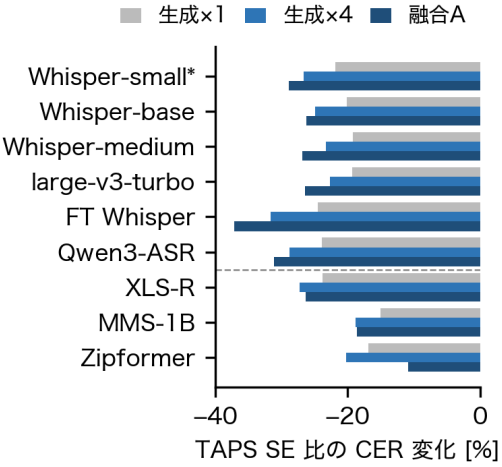


図2: TAPS SE 比の CER 変化（棒が左に長いほど改善）。破線より上が Whisper 系、下が入力特徴量の異なる認識器

種で有意）、TAPS SE 比では −26〜−37% となった。既存手法である SSL-MSE や CE-SE 単体よりも、6 種すべてで良い。Dissen 型は、同じ条件で測り直しても TAPS SE と同等以下であった（Whisper-small: TAPS SE 0.237、Dissen 型 0.239、融合 A 0.169。80 次元メルの Whisper にしか使えないため別の認識経路で比較）。一方、入力特徴量の異なる認識器では融合の上乗せはなく、Zipformer では生成 ×4 より 11.7% 悪化した。融合 A は Whisper 系に特化した上乗せである。

4.3 何が効き、何が害になるか

融合の作り方を変えて、CE-SE の何が Whisper 系に効くかを調べた（表 2）。4 kHz 未満のみ、または 4 kHz 以上のみを融合すると、Whisper 系の上乗せはそれぞれ約半分になった。さらに対数振幅をケプストラムで包絡（低次）と細かい調波構造（高次）に分けると、包絡だけの融合で上乗せの大半が得られ、細部だけではほとんど得られなかった。CE-SE の出力に現れる櫛状のピークは、除いても結果が変わらず、原因ではなかった。一方、Zipformer は 4 kHz 未満のみの融合では悪化せず、害は CE-SE が喉マイクに元々無い 4 kHz 以上に作る成分から生じていた。

表2: 融合の分解（test CER）。<4 kHz ／ ≥4 kHz: その帯域だけ融合

認識器	生成 ×4	融合 A	<4 kHz	≥4 kHz
W-small*	0.169	0.163	0.166	0.167
W-medium	0.151	0.144	0.145	0.148
W-FT	0.100	0.092	0.094	0.099
Zipformer	0.433	0.483	**0.431**	0.479

表3: 害を減らす変更（test CER）。内挿: CE-SE と TAPS SE の重みの内挿（$\alpha = 0.7$）、融合 B: 対数振幅 × 内挿

認識器	CE-SE	内挿	融合 A	融合 B
W-small*	0.196	0.192	0.163	0.162
W-base	0.267	0.248	0.201	0.199
W-medium	0.169	0.165	0.144	0.143
W-turbo	0.142	0.139	0.125	0.124
W-FT	0.121	0.115	0.092	0.092
Qwen3	0.114	0.109	0.094	0.093
XLS-R	0.279	0.238	0.163	0.161
Zipformer	0.791	0.619	0.483	**0.442**

この害を減らすため、2 つの簡単な変更を加えた。1 つ目は重み空間での内挿 [14] で、CE-SE の重みを初期値の TAPS SE の重みへ部分的に戻す。

$$\theta(\alpha) = (1-\alpha)\,\theta_{\mathrm{TAPS}} + \alpha\,\theta_{\mathrm{CE}} \tag{4}$$

α は dev で Whisper-small の CER のみを見て $\{0.1, 0.2, \ldots, 0.9\}$ から選び、$\alpha = 0.7$ とした。2 つ目は、式 (3) の振幅の平均を対数振幅の平均に替える。両方を加えた融合を融合 B と呼ぶ（表 3）。内挿した SE は単体でも CE-SE より Whisper 系の CER が低く、他系統での悪化も小さい。融合 B は、Whisper 系では融合 A と ±1% 以内で同等のまま、Zipformer の悪化を大きく減らした（0.483→0.442、10/10 話者）。

4.4 別データセットでの評価

ここまでの評価は TAPS 内のクローズドな条件である。そこで仏語の体内伝導マイクコーパス VibraVox [15] の test の喉マイク音声（3,064 発話、21 話者）を用い、仏語で認識した（表 4）。

まず、TAPS で学習した部品を追加学習せずに適用した。機種・言語・収録条件のすべてが学習と異なる、

表4: VibraVox（仏語・別機種）での test CER。上段: TAPS で学習した部品をそのまま使用、下段: VibraVox で同じ手順の適応をやり直したもの

条件	W-small	W-base	W-medium	W-turbo	Qwen3
処理なし	0.422	0.536	0.366	0.270	0.242
TAPS で学習した部品のまま					
TAPS SE	0.711	0.755	0.718	0.654	0.594
生成 ×4	0.559	0.594	0.542	0.497	0.454
融合 B	0.527	0.575	0.512	0.463	0.407
VibraVox で適応					
VibraVox SE	0.256	0.313	0.212	0.163	0.154
CE-SE	0.153	0.226	0.114	0.081	0.081
内挿	0.136	0.207	0.099	0.070	0.070
生成 ×4	0.087	0.123	0.067	0.053	0.047
融合 A	**0.079**	0.119	**0.059**	**0.045**	0.041
融合 B	**0.079**	**0.116**	**0.059**	**0.045**	**0.040**

オープンな条件である。いずれの処理も処理なしより CER を悪化させた（融合 B でも +8〜+71%）。音量を TAPS にそろえ 4 kHz で帯域制限した入力でも結果はほぼ変わらず、原因は機種の違いに適応していないことと考えられる。

次に、VibraVox の train（20,981 対、話者は test と重ならない）で、TAPS と同じ手順の適応をやり直した。生成モデルは同じ事前学習済みモデルから追加学習し、SE は TAPS SE を再構成損失のみで VibraVox に合わせたもの（以下 VibraVox SE）を初期値として、仏語の Whisper-small で CE-SE を学習した。α は VibraVox の dev で選び、TAPS と同じ 0.7 となった。その結果、TAPS での結論がそのまま再現した。生成 ×4 は処理なしより CER を 78〜83% 下げ（20〜21/21 話者）、融合 A はさらに 3〜15% 下げた（Whisper-base 以外で有意）。内挿も CE-SE 単体を 9〜13% 改善した。test の文のうち train にも現れるのは 3,064 中 1 文のみであり、文の暗記による改善ではない。

5 考察

結果は、喉マイク音声の Whisper 系向け SE において 2 つの成分が役割を分けていることを示す。事前学習済み生成モデルは欠けた成分を自然な音声として補い、認識器の系統によらず CER を下げる。CE-SE は Whisper の入力特徴量に合わせて主にスペクトル包絡を変え、その効果は学習に用いていない他サイズの Whisper や Qwen3-ASR にも及ぶ。ただし Whisper-base と Qwen3-ASR では融合の上乗せが有意でなく、Whisper 系の中でも効き方には差がある。

Whisper に合わせる成分を生成モデルの中に組み込む方法も試した。生成モデル自体を Whisper-small の CE で追加学習する方法（途中の 1 段の見積もりに CE をかける、最終段のみにかける DRaFT-K [16] 型など）は、いずれも CER を悪化させるか効果がなかった。Whisper に合わせる成分は、生成の外側で足すほうが容易である。

重みを 3 割戻すだけで Whisper 系の効果を保ったまま害が減ったことは、CE 損失による学習が Whisper-small に「効き過ぎ」ており、その行き過ぎた部分が他系統への害を担っていることを示唆する。実用上は、融合 B が Whisper 系の上乗せを保ちつつ他系統への害をほぼ避けられるため、最も扱いやすい。

一方、VibraVox での結果は、TAPS で学習した部品が収録機種に強く特化していることを示す（TAPS SE は TAPS では処理なしの CER を 0.446 から 0.230 へ下げるが、VibraVox では 0.422 から 0.711 へ悪化させる）。一方で、同じ手順で適応し直せば、言語も機種も異なる VibraVox でも生成モデル・融合・内挿の効果が同じ順序で再現した。作られた部品は機種ごとの適応を必要とするが、作り方はデータセットを越えて成り立つ。なお、VibraVox 内での評価もデータセットとしてはクローズドである。

本研究の限界として、融合の計算量が大きい（4.3 億パラメータのモデルを 20 段・4 サンプル実行）こと、機種ごとに同時収録の対データが必要なこと、各モデルの学習が 1 回であることが挙げられる。今後は、適応に必要な対データの量と、効かなかった原因が機種と言語のどちらにあるかを調べる。

6 まとめ

Whisper 系向けの喉マイク SE について、事前学習済み生成モデルと ASR 損失で学習した SE の役割を調べた。生成モデルの適応は 9 種の認識器すべてで CER を下げ、効果は事前学習に由来した。その 4 サンプル平均と Whisper 用 SE の融合は、学習に用いていない Whisper 系にも上乗せをもたらし（TAPS SE 比 −26〜−37%）、既存手法より良かった。Whisper 系への上乗せは主にスペクトル包絡から生じ、他系統への害は 4 kHz 以上の成分から生じ、重みの内挿と対数振幅での融合でほぼ解消できた。TAPS で学習した部品は別データセットの喉マイクにはそのままでは効かなかったが、同じ手順で適応し直すと VibraVox でも同じ結論が再現した。

参考文献

[1] Y. Kim *et al.*, “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” *Scientific Data*, 2026.

[2] A. Radford *et al.*, “Robust speech recognition via large-scale weak supervision,” in *Proc. ICML*, 2023.

[3] T. Ochiai *et al.*, “Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance,” *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 32, 2024.

[4] Y. Dissen *et al.*, “Enhanced ASR robustness to packet loss with a front-end adaptation network,” in *Proc. Interspeech*, 2024.

[5] H. Sato *et al.*, “Generic speech enhancement with self-supervised representation space loss,” *Frontiers in Signal Processing*, vol. 5, 2025.

[6] P.-J. Ku *et al.*, “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117, 2024.

[7] J. Hauret *et al.*, arXiv:2508.02974, 2025.

[8] 山中涼雅 *et al.*, “Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” in 日本音響学会 *2026* 年秋季研究発表会講演論文集, 2026, 1-Q-42.

[9] Y. Lipman *et al.*, “Flow matching for generative modeling,” in *Proc. ICLR*, 2023.

[10] S. Chen *et al.*, “WavLM: Large-scale self-supervised pre-training for full stack speech processing,” *IEEE J. Sel. Topics Signal Process.*, vol. 16, 2022.

[11] V. Pratap *et al.*, “Scaling speech technology to 1,000+ languages,” *J. Mach. Learn. Res.*, vol. 25, 2024.

[12] A. Babu *et al.*, “XLS-R: Self-supervised cross-lingual speech representation learning at scale,” in *Proc. Interspeech*, 2022.

[13] Z. Yao *et al.*, “Zipformer: A faster and better encoder for automatic speech recognition,” in *Proc. ICLR*, 2024.

[14] M. Wortsman *et al.*, “Robust fine-tuning of zero-shot models,” in *Proc. CVPR*, 2022.

[15] J. Hauret *et al.*, “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” *Speech Communication*, 2025.

[16] K. Clark *et al.*, “Directly fine-tuning diffusion models on differentiable rewards,” in *Proc. ICLR*, 2024.