Whisper 系音声認識に向けた喉マイク音声強調における事前学習済み生成モデルと ASR 損失の役割[*1]

春日　裕次（明治大学　総合数理学部　先端メディアサイエンス学科）

1　はじめに

喉マイクは頸部の振動を接触型センサで捉えるため環境騒音に強く、工場や建設現場のような騒音下での音声入力や通話に使われる。一方、軟組織の伝搬特性により高域が大きく失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] では喉マイクが 8 kHz で収録されており、4 kHz 以上は収録時点から存在しない。Whisper-small [2] で喉マイク音声をそのまま認識すると文字誤り率（CER）は 0.447 に達する。

前処理としての音声強調（SE）は有力な対策であるが、知覚品質の改善が音声認識（ASR）の改善を保証しないことが知られている [3]。この乖離に対し、凍結した ASR の損失で前処理を学習する方法 [4] や、自己教師あり表現空間の損失で SE を学習する方法 [5] が提案されてきた。しかし、ASR の損失で学習した SE が、損失に用いた認識器以外にどこまで効くかは十分に調べられていない。本稿の実験でも、Whisper-small の交差エントロピー（CE）損失で学習した喉マイク SE は、TAPS では Whisper のエラーを減らす一方、系統の異なる認識器では悪化した（4.1 節）。

一方、喉マイクの問題は雑音の混入ではなく帯域や子音の欠落であり、欠けた成分を補う必要がある。大規模音声で事前学習した生成モデル [6] は、入力が持たない成分を生成によって補うことができる。Hauret ら [7] は、本稿と同じ NeMo の flow matching モデルを体内伝導マイクコーパス VibraVox の喉マイクで比較し、音素誤り率の大幅な低下を報告したが、認識器は 1 種のみである。また、生成的な帯域拡張や声質変換が喉マイク音声の CER を悪化させたという報告もある [8]。

本稿は、既存の生成モデルの適応を土台に、ASR 損失で学習した SE を組み合わせたときの効き方を、複数の認識器で分析する。対象は Whisper と同形式の対数メルスペクトログラムを入力とする認識器（以下 Whisper 系）とし、損失の計算と所定のハイパーパラメータの選択には Whisper-small のみを用いる。構成を図 1に示す。示すのは次の 4 点である。(1) 事前学習済みの flow matching 生成モデルを TAPS で適応すると、系統の異なる認識器を含む 9 種すべてで CER が下がる。喉マイク音声でファインチューニングした Whisper でも、処理なしより CER が下がる。同じ追加学習量では、事前学習なしのモデルは大きく劣る。(2) その出力に Whisper 用 SE の出力を振幅で融合すると、Whisper 系では生成モデル単体と本研究で比べた既存手法より CER が下がる（生成モデル単体に対しては、4 種で 3 回の学習とも有意）。再構成損失のみで学習した SE との融合では一貫した上乗せは得られず、CE-SE との融合は Whisper 系 6 種すべてでそれより CER が低い。(3) 融合の上乗せは、包絡だけの融合でも複数の Whisper で得られる。元の学習で見られた Zipformer での悪化は、主に 4 kHz 以上の成分の融合と関連し、重みの内挿と対数振幅での融合で小さくできる。ただし、この悪化の大きさは学習し直すと大きく変わる。(4) VibraVox では、TAPS で学習した部品はそのままでは効かなかったが、同じ手順で適応し直すと、生成・融合・内挿による改善が再現した。ただし VibraVox では、CE-SE と融合は系統の異なる認識器も改善し、TAPS で見られた悪化は生じなかった。

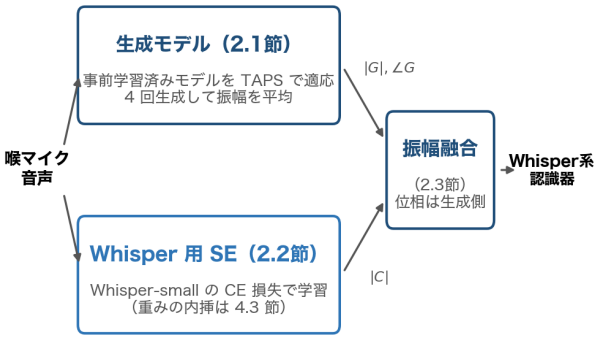


図1: 手法の全体像。喉マイク音声を生成モデルと Whisper 用 SE の両方に通し、出力の振幅を融合して Whisper 系の認識器に入力する

[*1] Roles of a pretrained generative model and ASR-loss enhancement in throat-microphone speech enhancement for Whisper-family recognizers, by KASUGA, Yuji (Meiji University).

2 方法

2.1 生成モデルによる復元

NVIDIA が公開している flow matching [9] 型の音声復元モデル（4.3 億パラメータ、複素 STFT 領域）[6] を用いる。大規模音声でマスク区間の復元により事前学習されたモデルである。本研究では TAPS の喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する（ASR の損失は用いない）。推論では標準正規分布の雑音から出発し、喉マイク音声を条件として常微分方程式を Euler 法 20 ステップで解く。

生成は出発点の雑音に依存して発話ごとにばらつく。そこで乱数の種を変えた N 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる。

$$|G| = \frac{1}{N}\sum_{n=1}^{N}|G_n|, \qquad \angle G = \angle G_1 \tag{1}$$

2.2 Whisper 用 SE

TAPS 論文 [1] が公開している SE-Conformer [10]（1210 万パラメータ、以下 TAPS SE）を初期値とし、次の損失で追加学習したモデル（以下 CE-SE）を用いる。

$$L = L_{\mathrm{recon}}(\hat{s}, s_{\mathrm{air}}) + \lambda\,\mathrm{CE}(\mathrm{Whisper}(\hat{s}), y) \tag{2}$$

$\hat{s}$ は SE 出力、s_{air} は気導音声、y は正解テキスト、L_{recon} は L1 波形損失と多重解像度 STFT 損失の和である。Whisper-small は凍結し、λ は dev の CER で $\{0, 0.1, 0.5, 1, 2, 5, 10\}$ から選んで $\lambda = 10$ とした。

2.3 振幅融合

生成モデルの出力 G（$N = 4$ の平均）と CE-SE の出力 C を、STFT（512 点、シフト 128 点）の振幅で重み付き平均し、位相は生成モデルのものを用いる。

$$Y = \left\{(1-w)|G| + w|C|\right\} e^{j\angle G} \tag{3}$$

w は、生成 1 回の出力との融合を dev で比べ、Whisper-small の CER のみを見て $\{0.25, 0.5, 0.75\}$ から選んだ（CER はそれぞれ 0.202・0.196・0.198）。test では同じ $w = 0.5$ を 4 サンプル平均との融合に用いた。融合に新たな学習は要らない。以下、この融合を融合 A と呼ぶ。

3 実験条件

3.1 データと学習

TAPS [1] の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各話者 100 発話）を用いた。生成モデルは train の 4,000 対で 20k step 追加学習した（batch 8、6.14 秒の切り出し、学習率 10^{-4}、EMA、32 ビット浮動小数点）。評価には学習終了時（最終ステップ）に保存した重みを用いた。test は学習と話者が重ならないが、収録機器・言語・文の種類は学習と同じであり、同一収録ドメインでの話者独立評価である。また、融合の採用や、4.3 節の内挿・対数振幅への変更は、TAPS の test での他の認識器の結果も見ながら決めており、TAPS 上の分析は探索的である。手順を固定した後の検証として、別データセットでの評価を 4.4 節で行う。CE-SE は Adam（学習率 3×10^{-4}、batch 4）で最大 50 エポック学習し、dev の損失で early stopping を行った。15 秒を超える発話は学習から除外した。

3.2 比較手法

TAPS SE、CE-SE に加え、2 つの既存手法を比較した。いずれも本研究で実装・適応したものである。SSL-MSE は、SE 出力と気導音声の WavLM-Large [11] 全層の表現の二乗誤差（重み 0.3）を再構成損失に加えて TAPS SE を追加学習したもので、Sato ら [5] の方式に倣う。Dissen 型は、凍結した ASR の損失で前段を学習する方法 [4] に倣い、喉マイクの対数メルを入出力とする U-Net（約 700 万パラメータ、初期値は乱数）を、Whisper-small の CE と気導音声の対数メルへの L1 損失で 20 エポック学習したものである。原論文はパケット欠損を対象としており、本稿の比較は喉マイクへの移植である。

3.3 認識器と評価

Whisper 系。 Whisper-small（損失と選択に使用）、Whisper-base、Whisper-medium、Whisper-large-v3-turbo、TAPS の喉マイク音声でファインチューニングした Whisper-small（FT Whisper）、Qwen3-ASR-1.7B [12] の 6 種である。Qwen3-ASR のエンコーダは Whisper と異なるが、入力は同形式の対数メル（128 次元）である。Whisper は faster-whisper で言語を指定して認識した。

系統の異なる認識器。 Whisper 系への特化を確認する対照として、波形入力の CTC 型である MMS-1B [13] と、XLSR-53 [14] を韓国語で追加学習したモデル（kresnik/wav2vec2-large-xlsr-korean、以下 XLSR）、Kaldi 型のフィルタバンクを入力とする Zipformer [15] を用いた。

指標。 test 1,000 発話で、正解と認識結果の双方か

ら句読点を除き、発話ごとの CER を 1.0 で打ち切って平均した（上限付き発話平均 CER）。空白は全認識器で含めた。総編集距離を総文字数で割る通常の CER と、空白を除いた CER でも、生成モデルによる改善と Whisper 系での融合の上乗せという主な傾向は変わらなかったが、差の小さい条件の間では順位が入れ替わる場合もあった。同一話者の発話は独立でないため、話者ごとの平均 CER を単位とする両側の Wilcoxon 符号順位検定（TAPS は 10 話者で未補正の最小 $p \approx 0.002$、VibraVox は 21 話者）を用い、条件の対ごとに、両条件の評価が揃った認識器（TAPS は 8〜9 種、VibraVox は 5〜7 種）をまたいで Holm 法で補正した（全探索に対する補正ではない）。以下の p は Holm 補正後の値である。検定は話者間の一貫性を示すもので、学習の再現性は CE-SE と生成モデルを 2 回ずつ学習し直して確かめた（4.2 節）。

4　実験結果

4.1　生成モデルの効果

表 1に各手法の CER を、図 2に TAPS SE 比の相対変化を示す。生成モデル（1 回の生成）は 9 種の認識器すべてで TAPS SE より CER を 15〜24% 下げ、いずれも 10 話者全員で改善した（$p \approx 0.018$）。処理なしと比べると、融合 A は 9 種すべてで CER を 43〜72% 下げた（10/10 話者）。FT Whisper でも処理なしの 0.138 から融合 A で 0.092（−33%）へ下がり、認識器を喉マイクに適応した後も前処理が効いた。Whisper-small では、発話の崩壊（CER≥0.99）や挿入誤りの増加はなかった。同じ構造・追加学習量で初期値を乱数としたモデルは Whisper-small で 0.551 と大幅に悪化し、この学習量では事前学習が不可欠であった（学習不足の可能性もある）。

一方、CE-SE 単体は Whisper 系では TAPS SE より CER を下げたが、XLSR では 25.8%、Zipformer では 45.9% 悪化した。学習し直した 2 回では悪化は小さかった（XLSR・Zipformer とも約 +11〜12%、Zipformer の 1 回は有意でない）。MMS は 3 回とも有意差がなかった。TAPS では、ASR 損失による有意な改善は系統の異なる認識器には及ばず、XLSR と Zipformer では悪化する傾向であった。

4.2　融合と既存手法との比較

4 サンプルの振幅平均（生成 ×4）は、生成のばらつきを抑え、1 回の生成よりさらに CER を下げた（Whisper-small 0.180→0.169）。融合 A は、Whisper 系の 6 種すべてで生成 ×4 より CER を下げ（−1.8〜−8.0%、Holm 補正後に有意なのは small・medium・turbo・FT の 4 種）、TAPS SE 比では −26〜−37% となった。本研究で実装・適応した比較手法（SSL-MSE、CE-SE 単体）よりも、6 種すべてで低い。Dissen 型（80 次元メルの Whisper のみ対応のため、transformers 版の貪欲復号で比較）は TAPS SE と同等以下であった（Whisper-small: TAPS SE 0.237、Dissen 型 0.239、融合 A 0.169）。一方、系統の異なる認識器では融合の上乗せはなく、Zipformer では生成 ×4 より 11.7% 悪化した。

この上乗せが単に 2 つの出力を平均した効果かを確かめるため、CE 損失を用いない SE を同じ方法で融合した（表 2）。TAPS SE との融合、および同じ手順で再構成損失のみを用いて追加学習した SE（$\lambda = 0$）との融合は、Whisper 系 6 種で生成 ×4 から −1.7〜+3.1% とほぼ改善しなかった。融合 A は $\lambda = 0$ の SE

表1: 各手法の test CER。なし: 処理なし、TAPS: TAPS SE、SSL: SSL-MSE、生成 ×N: 生成モデルの N サンプル平均、W-FT: FT Whisper、*: 損失・選択に使用

認識器	なし	TAPS	CE-SE	SSL	生成 ×1	生成 ×4	融合 A
W-small*	0.447	0.230	0.196	0.204	0.180	0.169	**0.163**
W-base	0.655	0.273	0.267	0.241	0.218	0.205	**0.201**
W-medium	0.337	0.196	0.169	0.177	0.159	0.151	**0.144**
W-turbo	0.257	0.170	0.142	0.153	0.137	0.131	**0.125**
W-FT	0.138	0.146	0.121	0.124	0.110	0.100	**0.092**
Qwen3	0.243	0.136	0.114	0.114	0.104	0.097	**0.094**
XLSR	0.584	0.222	0.279	0.190	0.169	**0.161**	0.163
MMS-1B	0.497	0.350	0.354	0.321	0.297	**0.284**	0.285
Zipformer	0.997	0.542	0.791	0.486	0.451	**0.433**	0.483

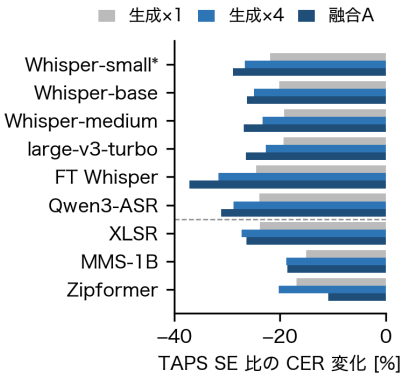


図2: TAPS SE 比の CER 変化（棒が左に長いほど改善）。破線より上が Whisper 系、下が系統の異なる認識器。* は損失・選択に使用

表2: 生成 ×4 に融合する SE を変えた対照（test CER）。$\lambda = 0$: TAPS SE を再構成損失のみで追加学習した SE。+CE（右端）が融合 A

認識器	生成 ×4	+TAPS	+λ=0	+SSL	+CE
W-small*	0.169	0.172	0.172	0.168	**0.163**
W-base	0.205	0.210	0.211	0.203	**0.201**
W-medium	0.151	0.150	0.151	0.147	**0.144**
W-turbo	0.131	0.130	0.129	0.128	**0.125**
W-FT	0.100	0.099	0.098	0.095	**0.092**
Qwen3	0.097	0.099	0.100	0.096	**0.094**
Zipformer	0.433	0.443	0.445	**0.428**	0.483

との融合より Whisper 系 6 種すべてで CER が低かった（−3.4〜−6.4%、Holm 補正後すべて有意）。ただし、SSL-MSE との融合でも生成 ×4 より改善する認識器があった（turbo −2.6%、FT −5.5%、いずれも有意）。融合 A と SSL-MSE との融合の直接比較では、融合 A が Whisper 系 6 種すべてで低かったが（−0.7〜−2.8%）、Holm 補正後に有意なのは small と turbo のみであった。今回の比較では Whisper 系 6 種で CE-SE との融合が最も CER が低かったが、CE 損失が上乗せの必要条件とまではいえない。

学習の乱数や環境による違いを見るため、CE-SE と生成モデルを 2 回ずつ学習し直し、同じ回どうしで融合した。生成 ×4 の CER は 3 回でほぼ同じであった（多くの認識器で差は 0.001 程度、最大は Qwen3-ASR の 0.003）。融合 A の生成 ×4 に対する上乗せは、Whisper-small・medium・turbo・FT では 3 回とも得られ、Holm 補正後も有意であった（−3.1〜−8.9%）。Whisper-base では 3 回とも −2% 前後（有意は 1 回）、Qwen3-ASR では −3.3・−3.2・+0.2%（いずれも有意でない）であった。一方、Zipformer での悪化は元の学習では +11.7% であったが、学習し直した 2 回では +1.1・+1.7%（有意でない）にとどまった。

4.3 何が効き、何が害になるか

融合の作り方を変えて、CE-SE の何が Whisper 系に効くかを元の学習のモデルで調べた（表 3）。帯域で分けると、多くの Whisper では 4 kHz 未満のみ・以上のみのどちらでも上乗せの一部が得られたが、Qwen3-ASR では高域のみの融合でほぼすべてが得られ、低域のみでは改善しなかった。次に、対数振幅の融合をケプストラムで包絡（30 次未満）と細かい調波構造に分けた。包絡だけの融合は、Whisper-medium・turbo・FT では対数振幅融合の上乗せの約 9 割以上を得たが、small・base では約半分にとどまり、細部だけの融合ではどの認識器でもほとんど改善しなかった。CE-SE の出力に現れる櫛状のピークは、除いても結果がほぼ変わらなかった。一方、元の学習の CE-SE では、Zipformer での悪化は高域のみの融合でほぼ再現し、低域のみでは生じなかった。4 kHz 以上に CE-SE が作る成分が Zipformer に不利に働いたと考えられる。

表3: 融合の分解（test CER）。<4k ／ ≥4k: その帯域だけ融合、対数: 対数振幅の融合、包絡／細部: 対数振幅の融合をケプストラムで分けて片方だけ融合

認識器	生成 ×4	融合 A	<4k	≥4k	対数	包絡	細部
W-small*	0.169	0.163	0.166	0.167	0.162	0.166	0.169
W-base	0.205	0.201	0.204	0.204	0.197	0.202	0.203
W-medium	0.151	0.144	0.145	0.148	0.144	0.145	0.150
W-turbo	0.131	0.125	0.126	0.128	0.125	0.125	0.131
W-FT	0.100	0.092	0.094	0.099	0.093	0.094	0.100
Qwen3	0.097	0.094	0.097	0.094	0.093	0.094	0.098
Zipformer	0.433	0.483	0.431	0.479	0.451	0.455	0.454

この害を減らすため、2 つの簡単な変更を加えた。1 つ目は重み空間での内挿 [16] で、CE-SE の重みを初期値の TAPS SE の重みへ部分的に戻す。

$$\theta(\alpha) = (1-\alpha)\,\theta_{\mathrm{TAPS}} + \alpha\,\theta_{\mathrm{CE}} \tag{4}$$

α は dev で Whisper-small の CER のみを見て $\{0.1, 0.2, \ldots, 0.9\}$ から選び、$\alpha = 0.7$ とした。2 つ目は、式 (3) の振幅の平均を対数振幅の平均に替える。両方を加えた融合を融合 B と呼ぶ（表 4）。内挿した SE は単体でも CE-SE より Whisper 系の CER が低く、XLSR・Zipformer での悪化も小さい。融合 B と融合 A の Whisper 系での差は −1.2〜0% で、Holm 補正後はいずれも有意でなかった。一方、Zipformer の悪化は大きく減った（0.483→0.442、10/10 話者）が、生成 ×4（0.433）より +2.1% 悪く、この差も有意であった（$p = 0.041$）。学習し直した 2 回で同じ融合 B（$\alpha = 0.7$ に固定）を作ると、生成 ×4 より 9 種すべてで点推定が低く（Zipformer −2.8・−1.4%）、融合 A との差はいずれも有意でなかった。

4.4 別データセットでの評価

ここまでの評価は TAPS の同一コーパス内である。そこで仏語の体内伝導マイクコーパス VibraVox [17] の test の喉マイク音声（3,064 発話、21 話者）を用い、仏語で認識した（表 5）。

まず、TAPS で学習した部品を追加学習せずに適用した。いずれの処理も処理なしより CER を悪化させ

表4: 害を減らす変更（test CER）。内挿: CE-SE と TAPS SE の重みの内挿（$\alpha = 0.7$）、融合 B: 対数振幅 × 内挿

認識器	生成 ×4	CE-SE	内挿	融合 A	融合 B
W-small*	0.169	0.196	0.192	0.163	0.162
W-base	0.205	0.267	0.248	0.201	0.199
W-medium	0.151	0.169	0.165	0.144	0.143
W-turbo	0.131	0.142	0.139	0.125	0.124
W-FT	0.100	0.121	0.115	0.092	0.092
Qwen3	0.097	0.114	0.109	0.094	0.093
XLSR	0.161	0.279	0.238	0.163	0.161
Zipformer	0.433	0.791	0.619	0.483	0.442

た（融合 B でも +7〜+72%）。音量を TAPS にそろえ 4 kHz で帯域制限しても結果はほぼ変わらなかった。

次に、VibraVox の train（20,981 対、話者は test と重ならない）で、TAPS と同じ手順の適応をやり直した。生成モデルは同じ事前学習済みモデルから追加学習し、SE は TAPS SE を再構成損失のみで VibraVox に合わせたもの（以下 VibraVox SE）を初期値として、仏語の Whisper-small で CE-SE を学習した（表 5の「再構成のみ」が VibraVox SE）。$\lambda = 10$、$w = 0.5$、$N = 4$ は TAPS で決めた値に固定し、α のみ VibraVox の dev (2,523 発話)で選んだ(TAPS と同じ 0.7)。系統の異なる認識器として、XLSR-53 [14] を仏語で追加学習したモデル(jonatasgrosman/wav2vec2-large-xlsr-53-french、言語モデルなしの貪欲復号）と MMS-1B（仏語アダプタ）も用いた。その結果、生成・融合・内挿による改善が再現した。生成 ×4 は処理なしより CER を 70〜82% 下げ（20〜21/21 話者）、融合 A はさらに 3〜15% 下げた（Holm 補正後、Whisper-base 以外で有意）。内挿も CE-SE 単体を 9〜14% 改善した。一方 TAPS と異なり、CE-SE は仏語の CTC 認識器も改善し（VibraVox SE 比で XLSR −22%、MMS −30%）、融合 A も生成 ×4 より両者の CER を下げた（−8%、−12%）。VibraVox では他系統への悪化が生じず、融合 B は MMS で融合 A より悪かった（+5.5%、$p < 0.001$）。test と train で完全に一致する文は 1 文のみである。

5 考察

結果は、喉マイク音声の Whisper 系向け SE において 2 つの成分が役割を分けていることを示す。事前学習済み生成モデルの適応は、評価した認識器の系統によらず CER を下げた。CE-SE による上乗せは Whisper 互換の入力を持つ認識器で観察され、学習に用いていない他サイズの Whisper や Qwen3-ASR にも及んだ。ただし認識器の間では入力特徴量だけでなく構造や学習データも異なり、上乗せの原因を入力特徴量に特定することはできない。また VibraVox では、CE-SE と融合が系統の異なる仏語の認識器も改善しており、ASR 損失による改善が他系統に及ぶかはデータセットに依存する。TAPS での悪化には、4 kHz 以上が欠けた入力に CE-SE が高域を作るという TAPS 特有の条件が関わる可能性がある（未検証）。ただし元の学習の融合 A では、Whisper-base と Qwen3-ASR で生成 ×4 に対する上乗せが有意でなく、Whisper 系の中でも効き方には差がある。

表5: VibraVox（仏語・別機種）での test CER。上段: TAPS で学習した部品をそのまま使用、下段: VibraVox で同じ手順の適応をやり直したもの。XLSR・MMS は仏語版（–は未評価）

条件	W-small	W-turbo	Qwen3	XLSR	MMS
処理なし	0.422	0.270	0.242	0.275	0.258
TAPS で学習した部品のまま					
TAPS SE	0.711	0.654	0.594	0.501	0.577
生成 ×4	0.559	0.497	0.454	–	–
融合 B	0.527	0.463	0.407	–	–
VibraVox で適応					
再構成のみ	0.256	0.163	0.154	0.163	0.187
CE-SE	0.153	0.081	0.081	0.128	0.131
内挿	0.136	0.070	0.070	0.111	0.113
生成 ×4	0.087	0.053	0.047	0.063	0.076
融合 A	**0.079**	**0.045**	0.041	0.058	**0.067**
融合 B	**0.079**	**0.045**	**0.040**	**0.057**	0.071

生成モデル自体を Whisper-small の CE で追加学習する方法（DRaFT-K [18] 型など）は効果がなかった。

元のモデルでは、CE 学習による重みの変化を 3 割弱めるだけで他系統への害が減った。ただし融合 B は、元の TAPS のモデルでは Zipformer の悪化が有意に残り、VibraVox の MMS では融合 A より悪かった。学習し直したモデルでは他系統を悪化させなかったが融合 A との差は有意でなく、融合 B の優位性は評価条件に依存する。

一方、VibraVox での結果は、TAPS で学習した部品が今回のデータセット間ではそのまま使えず、再適応が必要だったことを示す。同じ VibraVox の別の体内伝導センサー（柔らかい耳栓型マイク、額の加速度センサー）に、喉マイクで適応した部品を適用しても、いずれも処理なしより悪化した（Whisper-small: 耳栓型 0.089→ 融合 A 0.129、額 0.075→0.118）。同じ言語・

話者・文でもセンサーを変えると転移に失敗したことから、言語差がなくても収録系の違いが性能低下を生じうる。ただし、これは TAPS から VibraVox への転移とは別の実験であり、その失敗における言語と機器の寄与を比べたものではない。ただし両センサーは処理なしでも誤りが少ない。一方、同じ手順で適応し直せば生成・融合・内挿の効果は同じ順序で再現し、作り方は 2 つのデータセットで成り立った（ただし VibraVox での評価も同一コーパス内）。

本研究の限界として、TAPS 上の分析が探索的であること、融合の計算量が大きい（4.3 億パラメータのモデルを 20 段・4 サンプル実行）こと、機器ごとに同時収録の対データが必要なことが挙げられる。また、主な結論（生成モデルの効果と、Whisper 系への融合の上乗せ）は 3 回の学習で確かめたが、他系統への悪化の大きさは学習ごとに大きく異なり、4.3 節の帯域・包絡の分解は元の 1 回の学習についての結果である。元の学習と学習し直した 2 回とでは計算環境（CE-SE の 16 ビット浮動小数点の形式）も異なり、乱数による違いと区別できていない（生成モデルの学習では乱数の種を明示的に固定していない）。ただし対データの量については、VibraVox の train から選んだ一部の対だけで生成モデルを適応すると、1,000 対（約 1.3 時間、10k step）で、全データ（約 26 時間、20k step）の改善量の約 86% が得られた（生成 1 回・1 試行、Whisper-small 0.422→0.148、全データでは 0.102）。1,000 対は全対から無作為に選んだ。融合 A の出力への SE-Conformer の蒸留は融合 A に遠く及ばず（Whisper-small 0.190）、計算量の削減と少ない対データでの適応は今後の課題である。

6　まとめ

Whisper 系向けの喉マイク SE について、事前学習済み生成モデルと ASR 損失で学習した SE の役割を調べた。生成モデルの適応は 9 種の認識器すべてで CER を下げ、喉マイクで追加学習した Whisper にも効いた。その 4 サンプル平均と Whisper 用 SE の融合は、学習に用いていない Whisper 系でも CER を下げ（TAPS SE 比 −26〜−37%）、本研究で比べた既存手法より低かった。この上乗せは再構成損失のみの SE との融合では一貫して得られず、CE-SE との融合はそれを Whisper 系のすべてで上回った。融合の上乗せは包絡だけでも複数の Whisper で得られた。元の TAPS のモデルでの Zipformer の悪化は 4 kHz 以上の融合と関連し、内挿と対数振幅での融合で縮小したが残った。TAPS で学習した部品は別データセットの喉マイクにはそのままでは効かなかったが、同じ手順で適応し直すと、VibraVox でも生成・融合・内挿による改善が再現した。VibraVox では CE-SE と融合が系統の異なる認識器も改善しており、ASR 損失による改善が他系統に及ぶかはデータセットに依存する。

参考文献

[1] Y. Kim *et al.*, “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” *Scientific Data*, 2026.

[2] A. Radford *et al.*, “Robust speech recognition via large-scale weak supervision,” in *Proc. ICML*, 2023.

[3] T. Ochiai *et al.*, “Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance,” *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 32, 2024.

[4] Y. Dissen *et al.*, “Enhanced ASR robustness to packet loss with a front-end adaptation network,” in *Proc. Interspeech*, 2024.

[5] H. Sato *et al.*, “Generic speech enhancement with self-supervised representation space loss,” *Frontiers in Signal Processing*, vol. 5, 2025.

[6] P.-J. Ku *et al.*, “Generative speech foundation model pre-training for high-quality speech extraction and restoration,” arXiv:2409.16117, 2024.

[7] J. Hauret, T. Joubaud, and É. Bavu, “Real-time speech enhancement in noise for throat microphone using neural audio codec as foundation model,” arXiv:2508.02974, 2025.

[8] 山中涼雅 *et al.*, “Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” in 日本音響学会 *2026* 年秋季研究発表会講演論文集, 2026, 1-Q-42.

[9] Y. Lipman *et al.*, “Flow matching for generative modeling,” in *Proc. ICLR*, 2023.

[10] E. Kim and H. Seo, “SE-Conformer: Time-domain speech enhancement using conformer,” in *Proc. Interspeech*, 2021, pp. 2736–2740.

[11] S. Chen *et al.*, “WavLM: Large-scale self-supervised pre-training for full stack speech processing,” *IEEE J. Sel. Topics Signal Process.*, vol. 16, 2022.

[12] Qwen Team, “Qwen3-ASR technical report,” arXiv:2601.21337, 2026.

[13] V. Pratap *et al.*, “Scaling speech technology to 1,000+ languages,” *J. Mach. Learn. Res.*, vol. 25, 2024.

[14] A. Conneau *et al.*, “Unsupervised cross-lingual representation learning for speech recognition,” in *Proc. Interspeech*, 2021, pp. 2426–2430.

[15] Z. Yao *et al.*, “Zipformer: A faster and better encoder for automatic speech recognition,” in *Proc. ICLR*, 2024.

[16] M. Wortsman *et al.*, “Robust fine-tuning of zero-shot models,” in *Proc. CVPR*, 2022.

[17] J. Hauret *et al.*, “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” *Speech Communication*, 2025.

[18] K. Clark *et al.*, “Directly fine-tuning diffusion models on differentiable rewards,” in *Proc. ICLR*, 2024.