Whisper 系音声認識に向けた喉マイク音声強調における事前学習済み生成モデルと ASR 損失の役割[*1]

春日　裕次（明治大学　総合数理学部　先端メディアサイエンス学科）

1　はじめに

喉マイクは頸部の振動を接触型センサで捉えるため環境騒音に強く、工場や建設現場のような騒音下での音声入力や通話に使われる。一方、軟組織の伝搬特性により高域が大きく失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] では喉マイクが 8 kHz で収録されており、4 kHz 以上は収録時点から存在しない。Whisper-small [2] で喉マイク音声をそのまま認識すると文字誤り率（CER）は 0.446 に達する。

前処理としての音声強調（SE）は有力な対策であるが、知覚品質の改善が音声認識（ASR）の改善を保証しないことが知られている [3]。この乖離に対し、凍結した ASR の損失で前処理を学習する方法 [4] や、自己教師あり表現空間の損失で SE を学習する方法 [5] が提案されてきた。しかし、ASR の損失で学習した SE が、損失に用いた認識器以外にどこまで効くかは十分に調べられていない。本稿の実験でも、Whisper-small の交差エントロピー（CE）損失で学習した喉マイク SE は、Whisper ではエラーを減らす一方、系統の異なる認識器では悪化した（4.1 節）。

一方、喉マイクの問題は雑音の混入ではなく帯域や子音の欠落であり、欠けた成分を補う必要がある。大規模音声で事前学習した生成モデル [6] は、入力が持たない成分を自然な音声として生成できる。Hauret ら [7] は、本稿と同じ NeMo の flow matching モデルを体内伝導マイクコーパス VibraVox の喉マイクで比較対象とし、音素誤り率の大幅な低下を報告しているが、評価は単一の認識器に限られる。また、生成的な帯域拡張や声質変換が喉マイク音声の CER を悪化させたという報告もある [8]。

本稿は、既存の生成モデルの適応を土台に、ASR 損失で学習した SE を組み合わせたときの効き方を、複数の認識器で分析する。対象は Whisper と同形式の対数メルスペクトログラムを入力とする認識器（以下 Whisper 系）とし、損失の計算と所定のハイパーパラメータの選択には Whisper-small のみを用いる。構成を図 1に示す。示すのは次の 4 点である。(1) 事前学習済みの flow matching 生成モデルを TAPS で適応すると、系統の異なる認識器を含む 9 種すべてで CER が下がる。同じ追加学習量では、事前学習なしのモデルは大きく劣る。(2) その出力に Whisper 用 SE の出力を振幅で融合すると、Whisper 系では生成モデル単体と本研究で比べた既存手法より CER が下がる。この上乗せは、CE 損失を用いない SE との融合では得られない。(3) 融合の上乗せは、包絡だけの融合でも複数の Whisper で得られる。Zipformer での悪化は、主に 4 kHz 以上の成分の融合と関連し、重みの内挿と対数振幅での融合で小さくできる。(4) VibraVox では、TAPS で学習した部品はそのままでは効かなかったが、同じ手順で適応し直すと、生成・融合・内挿による改善の傾向が Whisper 系で再現した。

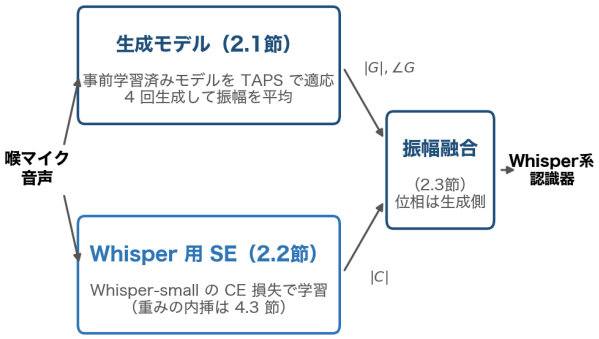


図1: 手法の全体像。喉マイク音声を生成モデルと Whisper 用 SE の両方に通し、出力の振幅を融合して Whisper 系の認識器に入力する

2　方法

2.1　生成モデルによる復元

NVIDIA が公開している flow matching [9] 型の音声復元モデル（4.3 億パラメータ、複素 STFT 領域）[6] を用いる。大規模音声でマスク区間の復元により事前学習されたモデルである。本研究では TAPS の喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する（ASR の損失は用いない）。推論では標

[*1] Roles of a pretrained generative model and ASR-loss enhancement in throat-microphone speech enhancement for Whisper-family recognizers, by KASUGA, Yuji (Meiji University).

準正規分布の雑音から出発し、喉マイク音声を条件として常微分方程式を Euler 法 20 ステップで解く。

生成は出発点の雑音に依存して発話ごとにばらつく。そこで乱数の種を変えた N 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる。

$$|G| = \frac{1}{N}\sum_{n=1}^{N}|G_n|, \qquad \angle G = \angle G_1 \tag{1}$$

2.2 Whisper 用 SE

TAPS 論文 [1] が公開している SE-Conformer [10]（1210 万パラメータ、以下 TAPS SE）を初期値とし、次の損失で追加学習したモデル（以下 CE-SE）を用いる。

$$L = L_{\mathrm{recon}}(\hat{s}, s_{\mathrm{air}}) + \lambda\,\mathrm{CE}(\mathrm{Whisper}(\hat{s}), y) \tag{2}$$

$\hat{s}$ は SE 出力、s_{air} は気導音声、y は正解テキスト、L_{recon} は L1 波形損失と多重解像度 STFT 損失の和である。Whisper-small は凍結し、λ は dev の CER で $\{0, 0.1, 0.5, 1, 2, 5, 10\}$ から選んで $\lambda = 10$ とした。

2.3 振幅融合

生成モデルの出力 G（$N = 4$ の平均）と CE-SE の出力 C を、STFT（512 点、シフト 128 点）の振幅で重み付き平均し、位相は生成モデルのものを用いる。

$$Y = \big\{(1-w)|G| + w|C|\big\}\, e^{j\angle G} \tag{3}$$

w は、生成 1 回の出力との融合を dev で比べ、Whisper-small の CER のみを見て $\{0.25, 0.5, 0.75\}$ から選んだ（CER はそれぞれ 0.202・0.196・0.198）。test では同じ $w = 0.5$ を 4 サンプル平均との融合に用いた。融合に新たな学習は要らない。以下、この融合を融合 A と呼ぶ。

3 実験条件

3.1 データと学習

TAPS [1] の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各話者 100 発話）を用いた。生成モデルは train の 4,000 対で 20k step 追加学習した（batch 8、6.14 秒の切り出し、学習率 10^{-4}、EMA、32 ビット浮動小数点）。評価には学習終了時（最終ステップ）に保存した重みを用いた。test は学習と話者が重ならないが、収録機器・言語・文の種類は学習と同じであり、同一収録ドメインでの話者独立評価である。また、融合の採用や、4.3 節の内挿・対数振幅への変更は、TAPS の test での他の認識器の結果も見ながら決めており、TAPS 上の分析は探索的である。手順を固定した後の検証として、別データセットでの評価を 4.4 節で行う。CE-SE は Adam（学習率 3×10^{-4}、batch 4）で最大 50 エポック学習し、dev の損失で early stopping を行った。15 秒を超える発話は学習から除外した。

3.2 比較手法

TAPS SE、CE-SE に加え、2 つの既存手法を比較した。いずれも本研究で実装・適応したものである。SSL-MSE は、SE 出力と気導音声の WavLM-Large [11] 全層の表現の二乗誤差（重み 0.3）を再構成損失に加えて TAPS SE を追加学習したもので、Sato ら [5] の方式に倣う。Dissen 型は、凍結した ASR の損失で前段を学習する方法 [4] に倣い、喉マイクの対数メルを入出力とする U-Net（約 700 万パラメータ、初期値は乱数）を、Whisper-small の CE と気導音声の対数メルへの L1 損失で 20 エポック学習したものである。原論文はパケット欠損を対象としており、本稿の比較は喉マイクへの移植である。

3.3 認識器と評価

Whisper 系。 Whisper-small（損失と選択に使用）、Whisper-base、Whisper-medium、Whisper-large-v3-turbo、TAPS の喉マイク音声でファインチューニングした Whisper-small（FT Whisper）、Qwen3-ASR-1.7B [12] の 6 種である。Qwen3-ASR のエンコーダは Whisper と異なるが、入力は同形式の対数メル（128 次元）である。Whisper は faster-whisper（CTranslate2）で言語を韓国語に指定して認識した。

系統の異なる認識器。 Whisper 系への特化を確認する対照として、波形入力の CTC 型である MMS-1B [13] と XLS-R [14]（韓国語で追加学習したもの）、Kaldi 型のフィルタバンクを入力とする Zipformer [15] を用いた。

指標。 test 1,000 発話で、正解と認識結果の双方から句読点を除き、発話ごとの CER を 1.0 で打ち切って平均した（上限付き発話平均 CER）。空白は全認識器で含めた。総編集距離を総文字数で割る通常の CER と、空白を除いた CER でも、主な条件の順位は変わらなかった。同一話者の発話は独立でないため、話者ごとの平均 CER を単位とする両側の Wilcoxon 符号順位検定（$n = 10$、最小の $p = 0.002$）を用い、比較ごとに認識器をまたいで Holm 法で補正した。各モデルの学習は 1 回であり、検定は学習済みモデルについての話者間の一貫性を示すものである。

表1: 各手法の test CER。TAPS: TAPS SE、SSL: SSL-MSE、生成 $\times N$: 生成モデルの N サンプル平均、W-FT: FT Whisper、*: 損失・選択に使用

認識器	TAPS	CE-SE	SSL	生成 ×1	生成 ×4	融合 A
W-small*	0.230	0.196	0.204	0.180	0.169	**0.163**
W-base	0.273	0.267	0.241	0.218	0.205	**0.201**
W-medium	0.196	0.169	0.177	0.159	0.151	**0.144**
W-turbo	0.170	0.142	0.153	0.137	0.131	**0.125**
W-FT	0.146	0.121	0.124	0.110	0.100	**0.092**
Qwen3	0.136	0.114	0.114	0.104	0.097	**0.094**
XLS-R	0.222	0.279	0.190	0.169	**0.161**	0.163
MMS-1B	0.350	0.354	0.321	0.297	**0.284**	0.285
Zipformer	0.542	0.791	0.486	0.451	**0.433**	0.483

4 実験結果

4.1 生成モデルの効果

表 1に各手法の CER を、図 2に TAPS SE 比の相対変化を示す。生成モデル (1 回の生成) は 9 種の認識器すべてで TAPS SE より CER を 15〜24% 下げ、いずれも 10 話者全員で改善した ($p = 0.002$)。Whisper-small の認識結果では、大規模な崩壊 (CER≥0.99 の発話) や挿入誤りの増加は見られなかった。同じ構造・同じ追加学習量で初期値を乱数としたモデルは、Whisper-small で 0.551 と TAPS SE より大幅に悪化した。この学習量では事前学習が不可欠であった (事前学習なしのモデルは学習不足の可能性もある)。

一方、CE-SE 単体は Whisper 系では TAPS SE より CER を下げたが、XLS-R では 25.8%、Zipformer では 45.9% 悪化した。ASR 損失による改善は、系統の異なる認識器には及ばなかった。

4.2 融合と既存手法との比較

4 サンプルの振幅平均(生成 ×4)は、生成のばらつきを抑え、1 回の生成よりさらに CER を下げた (Whisper-small 0.180→0.169)。融合 A は、Whisper 系の 6 種すべてで生成 ×4 より CER を下げ (−1.8〜−8.0%、Holm 補正後に有意なのは small・medium・turbo・FT の 4 種)、TAPS SE 比では −26〜−37% となった。本研究で実装・適応した比較手法 (SSL-MSE、CE-SE 単体) よりも、6 種すべてで低い。Dissen 型は 80 次元メルの Whisper にしか使えないため、TAPS SE と融合 A も同じ別の認識経路 (transformers 版 Whisper の貪欲復号) で測り直して比べた。Dissen 型は TAPS SE と同等以下であった (Whisper-small: TAPS SE 0.237、Dissen 型 0.239、融合 A 0.169)。一方、系統の異なる認識器では融合の上乗せはなく、Zipformer では生成 ×4 より 11.7% 悪化した。

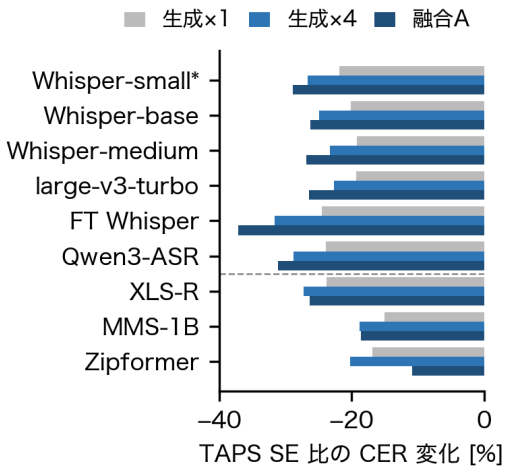


図2: TAPS SE 比の CER 変化 (棒が左に長いほど改善)。破線より上が Whisper 系、下が系統の異なる認識器。* は損失・選択に使用

表2: 生成 ×4 に融合する SE を変えた対照 (test CER)。$\lambda = 0$: TAPS SE を再構成損失のみで追加学習した SE。+CE (右端) が融合 A

認識器	生成 ×4	+TAPS	+λ=0	+SSL	+CE
W-small*	0.169	0.172	0.172	0.168	**0.163**
W-base	0.205	0.210	0.211	0.203	**0.201**
W-medium	0.151	0.150	0.151	0.147	**0.144**
W-turbo	0.131	0.130	0.129	0.128	**0.125**
W-FT	0.100	0.099	0.098	0.095	**0.092**
Qwen3	0.097	0.099	0.100	0.096	**0.094**
Zipformer	0.433	0.443	0.445	**0.428**	0.483

この上乗せが、単に 2 つの出力を平均した効果ではなく CE 損失によるものかを確かめるため、CE 損失を用いない SE を同じ方法で融合した (表 2)。TAPS SE との融合、および同じ手順で再構成損失のみを用いて追加学習した SE ($\lambda = 0$) との融合は、生成 ×4 から −1.7〜+3.1% とほぼ改善しなかった。融合 A は $\lambda = 0$ の SE との融合より Whisper 系 6 種すべてで CER が低く (−3.4〜−6.4%、Holm 補正後すべて有意)、SSL-MSE との融合と比べても 6 種すべてで低かった。融合の上乗せの大部分は、CE 損失で学習した成分によるといえる。

4.3 何が効き、何が害になるか

融合の作り方を変えて、CE-SE の何が Whisper 系に効くかを調べた (表 3)。帯域で分けると、多くの Whisper では 4 kHz 未満のみ・以上のみのどちらでも上乗せの一部が得られたが、Qwen3-ASR では高域の

表3: 融合の分解（test CER）。<4k ／ ≥4k: その帯域だけ融合、対数: 対数振幅の融合、包絡／細部: 対数振幅の融合をケプストラムで分けて片方だけ融合

認識器	生成 ×4	融合 A	<4k	≥4k	対数	包絡	細部
W-small*	0.169	0.163	0.166	0.167	0.162	0.166	0.169
W-base	0.205	0.201	0.204	0.204	0.197	0.202	0.203
W-medium	0.151	0.144	0.145	0.148	0.144	0.145	0.150
W-FT	0.100	0.092	0.094	0.099	0.093	0.094	0.100
Qwen3	0.097	0.094	0.097	0.094	0.093	0.094	0.098
Zipformer	0.433	0.483	0.431	0.479	0.451	0.455	0.454

みの融合でほぼすべてが得られ、低域のみでは改善しなかった。次に、対数振幅の融合をケプストラムで包絡（30 次未満）と細かい調波構造に分けた。包絡だけの融合は、Whisper-medium・turbo・FT では対数振幅融合の上乗せの 9 割前後を得たが、small・base では約半分にとどまり、細部だけの融合ではどの認識器でもほとんど改善しなかった。CE-SE の出力に現れる櫛状のピークは、除いても結果がほぼ変わらなかった。一方、Zipformer での悪化は高域のみの融合でほぼ再現し、低域のみでは生じなかった。喉マイクに元々無い 4 kHz 以上に CE-SE が作る成分が、Zipformer には不利に働いたと考えられる。

この害を減らすため、2 つの簡単な変更を加えた。1 つ目は重み空間での内挿 [16] で、CE-SE の重みを初期値の TAPS SE の重みへ部分的に戻す。

$$\theta(\alpha) = (1-\alpha)\,\theta_{\mathrm{TAPS}} + \alpha\,\theta_{\mathrm{CE}} \tag{4}$$

α は dev で Whisper-small の CER のみを見て $\{0.1, 0.2, \ldots, 0.9\}$ から選び、$\alpha = 0.7$ とした。2 つ目は、式 (3) の振幅の平均を対数振幅の平均に替える。両方を加えた融合を融合 B と呼ぶ（表 4）。内挿した SE は単体でも CE-SE より Whisper 系の CER が低く（-1.8〜-7.0%）、XLS-R・Zipformer での悪化も小さい。融合 B と融合 A の Whisper 系での差は -1.2〜0% で、Holm 補正後はいずれも有意でなかった。一方、Zipformer の悪化は大きく減った（0.483→0.442、10/10 話者）が、生成 ×4（0.433）との差はなお残る。

4.4 別データセットでの評価

ここまでの評価は TAPS 内のクローズドな条件である。そこで仏語の体内伝導マイクコーパス VibraVox [17] の test の喉マイク音声（3,064 発話、21 話者）を用い、仏語で認識した（表 5）。

まず、TAPS で学習した部品を追加学習せずに適用した。収録機器・言語・話者・収録条件のすべてが学習と異なる条件である。いずれの処理も処理なしより CER を悪化させた（融合 B でも +7〜+72%）。音量を TAPS にそろえ 4 kHz で帯域制限した入力でも結果はほぼ変わらず、音量や帯域の違いでは説明できない。

表4: 害を減らす変更（test CER）。内挿: CE-SE と TAPS SE の重みの内挿（$\alpha = 0.7$）、融合 B: 対数振幅 × 内挿

認識器	生成 ×4	CE-SE	内挿	融合 A	融合 B
W-small*	0.169	0.196	0.192	0.163	0.162
W-base	0.205	0.267	0.248	0.201	0.199
W-medium	0.151	0.169	0.165	0.144	0.143
W-turbo	0.131	0.142	0.139	0.125	0.124
W-FT	0.100	0.121	0.115	0.092	0.092
Qwen3	0.097	0.114	0.109	0.094	0.093
XLS-R	0.161	0.279	0.238	0.163	0.161
Zipformer	0.433	0.791	0.619	0.483	0.442

次に、VibraVox の train（20,981 対、話者は test と重ならない）で、TAPS と同じ手順の適応をやり直した。生成モデルは同じ事前学習済みモデルから追加学習し、SE は TAPS SE を再構成損失のみで VibraVox に合わせたもの（以下 VibraVox SE）を初期値として、仏語の Whisper-small で CE-SE を学習した（表 5の「再構成のみ」が VibraVox SE）。$\lambda = 10$、$w = 0.5$、$N = 4$ は TAPS で決めた値に固定し、α のみ VibraVox の dev (2,523 発話）で選んだ（TAPS と同じ 0.7）。その結果、生成・融合・内挿による改善の傾向が Whisper 系で再現した。生成 ×4 は処理なしより CER を 77〜82% 下げ（20〜21/21 話者）、融合 A はさらに 3〜15% 下げた（Holm 補正後、Whisper-base 以外で有意）。内挿も CE-SE 単体を 9〜14% 改善した。仏語の系統の異なる認識器は用いていないため、他系統への害とその緩和は VibraVox では検証していない。test の文のうち train と完全に一致するのは 3,064 中 1 文のみであった。

5 考察

結果は、喉マイク音声の Whisper 系向け SE において 2 つの成分が役割を分けていることを示す。事前学習済み生成モデルは欠けた成分を自然な音声として補い、認識器の系統によらず CER を下げる。CE-SE による上乗せは Whisper 互換の入力を持つ認識器で観察され、学習に用いていない他サイズの Whisper や Qwen3-ASR にも及んだ。ただし認識器の間では入力特徴量だけでなく構造や学習データも異なり、上乗せの原因を入力特徴量に特定することはできない。ただ

表5: VibraVox（仏語・別機種）での test CER。上段: TAPS で学習した部品をそのまま使用、下段: VibraVox で同じ手順の適応をやり直したもの

条件	W-small	W-base	W-medium	W-turbo	Qwen3
処理なし	0.422	0.536	0.366	0.270	0.242
TAPS で学習した部品のまま					
TAPS SE	0.711	0.755	0.718	0.654	0.594
生成 ×4	0.559	0.594	0.542	0.497	0.454
融合 B	0.527	0.575	0.512	0.463	0.407
VibraVox で適応					
再構成のみ	0.256	0.313	0.212	0.163	0.154
CE-SE	0.153	0.226	0.114	0.081	0.081
内挿	0.136	0.207	0.099	0.070	0.070
生成 ×4	0.087	0.123	0.067	0.053	0.047
融合 A	**0.079**	0.119	**0.059**	**0.045**	0.041
融合 B	**0.079**	**0.116**	**0.059**	**0.045**	**0.040**

し Whisper-base と Qwen3-ASR では融合の上乗せが有意でなく、Whisper 系の中でも効き方には差がある。

Whisper に合わせる成分を生成モデルの中に組み込む方法も試した。生成モデル自体を Whisper-small の CE で追加学習する方法（途中の 1 段の見積もりに CE をかける、最終段のみにかける DRaFT-K [18] 型など）は、いずれも CER を悪化させるか効果がなかった。Whisper に合わせる成分は、生成の外側で足すほうが容易である。

重みを 3 割戻すだけで Whisper 系の効果を保ったまま害が減ったことは、CE 損失による学習が Whisper-small に「効き過ぎ」ており、その行き過ぎた部分が他系統への害を担っていることを示唆する。実用上は、融合 B が Whisper 系の上乗せを保ちつつ他系統への害をほぼ避けられるため、最も扱いやすい。

一方、VibraVox での結果は、TAPS で学習した部品が今回のデータセット間ではそのまま使えず、再適応が必要だったことを示す（TAPS SE は TAPS では処理なしの CER を 0.446 から 0.230 へ下げるが、VibraVox では 0.422 から 0.711 へ悪化させる）。同じ VibraVox の別の体内伝導センサー（柔らかい耳栓型マイク、額の加速度センサー）に、喉マイクで適応した部品を適用しても、いずれも処理なしより悪化した（Whisper-small: 耳栓型 0.089→ 融合 A 0.129、額 0.075→0.118）。言語・話者・文が同じでも効かなかったことから、主な原因は言語より収録機器の違いと考えられる。ただしこの 2 つのセンサーは処理なしでも誤りが少なく、補うべき成分が少ない点で喉マイクとは条件が異なる。一方で、同じ手順で適応し直せば、言語も機種も異なる VibraVox でも生成モデル・融合・内挿の効果が同じ順序で再現した。作られた部品は機種ごとの適応を必要とするが、作り方はデータセットを越えて成り立つ。なお、VibraVox 内での評価もデータセットとしてはクローズドである。

本研究の限界として、TAPS 上の分析が探索的であること、融合の計算量が大きい（4.3 億パラメータのモデルを 20 段・4 サンプル実行）こと、機器ごとに同時収録の対データが必要なこと、各モデルの学習が 1 回であることが挙げられる。ただし対データの量については、VibraVox の train から選んだ一部の対だけで生成モデルを適応すると、1,000 対（約 1.3 時間）で全データ（約 26 時間）の改善量の約 8 割が得られた（生成 1 回、Whisper-small 0.422→0.148、全データでは 0.102）。今後は、融合の計算量の削減と、より少ない対データでの適応を検討する。

6 まとめ

Whisper 系向けの喉マイク SE について、事前学習済み生成モデルと ASR 損失で学習した SE の役割を調べた。生成モデルの適応は 9 種の認識器すべてで CER を下げ、同じ追加学習量では事前学習が不可欠であった。その 4 サンプル平均と Whisper 用 SE の融合は、学習に用いていない Whisper 系でも CER を下げ（TAPS SE 比 −26〜−37%）、本研究で比べた既存手法より低かった。この上乗せは CE 損失を用いない SE との融合では得られなかった。融合の上乗せは包絡だけでも複数の Whisper で得られ、Zipformer での悪化は主に 4 kHz 以上の融合と関連し、重みの内挿と対数振幅での融合で小さくできた。TAPS で学習した部品は別データセットの喉マイクにはそのままでは効かなかったが、同じ手順で適応し直すと、VibraVox でも生成・融合・内挿による改善の傾向が再現した。

参考文献

[1] Y. Kim *et al.*, “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” *Scientific Data*, 2026.

[2] A. Radford *et al.*, “Robust speech recognition via large-scale weak supervision,” in *Proc. ICML*, 2023.

[3] T. Ochiai *et al.*, “Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance,” *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 32, 2024.

[4] Y. Dissen *et al.*, “Enhanced ASR robustness to

packet loss with a front-end adaptation network," in *Proc. Interspeech*, 2024.

[5] H. Sato *et al.*, "Generic speech enhancement with self-supervised representation space loss," *Frontiers in Signal Processing*, vol. 5, 2025.

[6] P.-J. Ku *et al.*, "Generative speech foundation model pretraining for high-quality speech extraction and restoration," arXiv:2409.16117, 2024.

[7] J. Hauret, T. Joubaud, and É. Bavu, "Real-time speech enhancement in noise for throat microphone using neural audio codec as foundation model," arXiv:2508.02974, 2025.

[8] 山中涼雅 *et al.*, "Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討," in 日本音響学会 *2026* 年秋季研究発表会講演論文集, 2026, 1-Q-42.

[9] Y. Lipman *et al.*, "Flow matching for generative modeling," in *Proc. ICLR*, 2023.

[10] E. Kim and H. Seo, "SE-Conformer: Time-domain speech enhancement using conformer," in *Proc. Interspeech*, 2021, pp. 2736–2740.

[11] S. Chen *et al.*, "WavLM: Large-scale self-supervised pre-training for full stack speech processing," *IEEE J. Sel. Topics Signal Process.*, vol. 16, 2022.

[12] Qwen Team, "Qwen3-ASR technical report," arXiv:2601.21337, 2026.

[13] V. Pratap *et al.*, "Scaling speech technology to 1,000+ languages," *J. Mach. Learn. Res.*, vol. 25, 2024.

[14] A. Babu *et al.*, "XLS-R: Self-supervised cross-lingual speech representation learning at scale," in *Proc. Interspeech*, 2022.

[15] Z. Yao *et al.*, "Zipformer: A faster and better encoder for automatic speech recognition," in *Proc. ICLR*, 2024.

[16] M. Wortsman *et al.*, "Robust fine-tuning of zero-shot models," in *Proc. CVPR*, 2022.

[17] J. Hauret *et al.*, "Vibravox: A dataset of French speech captured with body-conduction audio sensors," *Speech Communication*, 2025.

[18] K. Clark *et al.*, "Directly fine-tuning diffusion models on differentiable rewards," in *Proc. ICLR*, 2024.