喉マイク音声の認識に前処理はいつ効くのか ——事前学習済み生成モデルの適応と ASR 損失の役割——[*1]

春日　裕次（明治大学　総合数理学部　先端メディアサイエンス学科）

1　はじめに

喉マイクは頸部の振動を捉えるため環境騒音に強いが、高域や一部の子音の情報が失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] の喉マイク音声を Whisper-small [2] でそのまま認識すると、文字誤り率（CER）は 0.447 に達する。

前処理としての音声強調（SE）は有力な対策に見えるが、知覚品質の改善が音声認識（ASR）の改善を保証しないことが知られている [3]。喉マイクでも、汎用の帯域拡張や声質変換（TAPS で追加学習したものを含む）が CER を悪化させたと報告されている（CER の基準は気導音の認識結果）[4]。一方、Hauret ら [5] は本稿と同じ生成モデルを体内伝導マイクで追加学習し、1 種の音素認識器で誤りの大幅な低下を報告した。また、凍結した ASR の損失で前処理を学習する方法 [6] や、生成型と予測型の出力を融合する方法 [7] も提案されている。しかし、喉マイクに対して前処理が認識を助けるのはどんな条件か、ASR 損失が何を足すのか、それがなぜ効くのかは、複数の認識器で調べられていない。本稿の目的は融合方式の提案ではなく、追加の改善が残る条件と、その改善に関わる成分の分析である。

本稿は、TAPS で 9 種、VibraVox で 7 種の認識器を用いてこれを分析し、次の 3 点を示す。(1) 事前学習済みの生成モデルを対象の喉マイクで適応すると、9 種すべてで CER が下がり、喉マイク音声で追加学習した Whisper でもさらに CER を下げられる。同じ学習量で事前学習のないモデルや、別の喉マイクで適応した生成モデルをそのまま使うと悪化した。(2) Whisper の損失で学習した SE との融合は、Whisper 系で生成モデル単体よりさらに少し CER を下げる（以下、この追加の改善を上乗せと呼ぶ）。最初に学習したモデル（以下、元の学習）では、上乗せは時間平均した固定のゲインでは再現せず、融合と生成モデル単体の差のうち包絡の成分だけを加えると medium・turbo・FT で有意に改善し、融合の改善量の約半分〜9 割に当たった。同じ包絡の成分は、XLSR と Zipformer を悪化させた。(3) 今回の 2 つのデータセットの間では、生成モデルを調整なしで用いるとどちらの向きにも悪化したが、同じ手順で適応し直せば、生成モデルで大きく改善し融合でさらに改善する関係は再現した。



図1: 手法の全体像。喉マイク音声を生成モデルと Whisper 用 SE の両方に通し、出力の振幅を融合する

2　方法

2.1　生成モデルによる復元

NVIDIA が公開している flow matching [8] 型の音声復元モデル [9] を用いる。複素短時間フーリエ変換（STFT）を扱う 24 層の Transformer（4.3 億パラメータ）で、英語約 6 万時間の音声で、マスクした区間を復元するタスクにより事前学習されている。これを喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する（以下、適応。ASR の損失は用いない）。喉マイクと気導マイクの同時収録の組を対データと呼ぶ。推論では標準正規分布の雑音から出発し、Euler 法 20 ステップで生成する。生成は出発点の雑音に依存してばらつくので、$N = 4$ 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる（以下、生成 ×4）。

2.2　Whisper 用 SE と振幅融合

TAPS 論文 [1] が公開している SE-Conformer [10]（1210 万パラメータ、以下 TAPS SE）を初期値とし、交差エントロピー（CE）を含む次の損失で追加学習する

[*1] When does preprocessing help throat-microphone speech recognition? Roles of pretrained generative restoration and ASR-loss enhancement, by KASUGA, Yuji (Meiji University).

(以下 CE-SE)。

$$L = L_{\text{recon}}(\hat{s}, s_{\text{air}}) + \lambda\,\text{CE}(\text{Whisper}(\hat{s}), y) \qquad (1)$$

$\hat{s}$ は SE 出力、s_{air} は気導音声、L_{recon} は L1 波形損失と多重解像度 STFT 損失の和、y は正解テキストで、Whisper-small は凍結する。生成 ×4 の出力 G と CE-SE の出力 C は、STFT（512 点、シフト 128 点）の振幅で融合し、位相は G のものを用いる（以下、この方法を単に融合と呼ぶ)。

$$Y = \left(0.5\,|G| + 0.5\,|C|\right) e^{j\angle G} \qquad (2)$$

$\lambda = 10$ は $\{0, 0.1, 0.5, 1, 2, 5, 10\}$ から、重み 0.5 は生成 1 回の出力との融合で $\{0.25, 0.5, 0.75\}$ から、いずれも dev で Whisper-small の CER のみを見て選んだ。

3 実験条件

TAPS [1]（韓国語）の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各 100 発話）を用いた。生成モデルは train の 4,000 対で 20k step 追加学習し、最終ステップの重みを用いた。CE-SE は最大 50 エポック学習し、dev の損失で early stopping を行った。test は話者が学習と重ならないが、収録機器・言語は同じである。融合の採用は test の他の認識器も見て決めたため、TAPS 上の分析は探索的である。

認識器は、Whisper と同形式の対数メルを入力とする Whisper 系 6 種（Whisper-small（損失と選択に使用)・base・medium・large-v3-turbo、TAPS の喉マイク音声で追加学習した Whisper-small（FT Whisper)、Qwen3-ASR-1.7B [11]）と、系統の異なる 3 種（波形入力の CTC 型である MMS-1B [12] と XLSR-53 [13] の韓国語版（XLSR)、Zipformer [14]）である。CER は句読点を除き（仏語は小文字化も)、空白を含めて発話ごとに 1.0 で打ち切って平均した。総編集距離を総文字数で割る通常の CER でも主な傾向は同じであった。話者ごとの平均 CER で両側の Wilcoxon 符号順位検定を行い、条件の対ごとに、評価が揃った認識器をまたいで Holm 法で補正した（全探索に対する補正ではない)。比較手法の SSL-MSE は、WavLM-Large 全層の表現の二乗誤差（重み 0.3）を再構成損失に加えて TAPS SE を追加学習したものである [15]。CE-SE と生成モデルは、元の学習に加えて 2 回ずつ学習し直し、再現性を確かめた。

表1: TAPS test の CER。なし: 処理なし、TAPS: TAPS SE、W-FT: FT Whisper、*: 損失・選択に使用

認識器	なし	TAPS	CE-SE	生成 ×4	融合
W-small*	0.447	0.230	0.196	0.169	**0.163**
W-base	0.655	0.273	0.267	0.205	**0.201**
W-medium	0.337	0.196	0.169	0.150	**0.144**
W-turbo	0.257	0.170	0.141	0.131	**0.125**
W-FT	0.138	0.146	0.121	0.100	**0.092**
Qwen3	0.243	0.136	0.114	0.097	**0.094**
XLSR	0.584	0.222	0.279	**0.161**	0.163
MMS-1B	0.497	0.350	0.354	**0.284**	0.285
Zipformer	0.997	0.542	0.791	**0.433**	0.483

4 実験結果

4.1 前処理が効く条件

表 1に各手法の CER を示す。生成モデルは 9 種すべてで TAPS SE より CER を下げた（1 回の生成でも 15〜24%、10 話者全員)。喉マイク音声で追加学習した FT Whisper でも、処理なしの 0.138 から生成 ×4 で 0.100、融合で 0.092（−33%、10 話者全員）へ下がり、認識器を喉マイクに適応した後も前処理が効いた。一方、同じ構造を同じ量だけ乱数の初期値から学習したモデルは Whisper-small で 0.551（学習不足の可能性もある)、別の喉マイク（4.4 節の VibraVox）で適応した生成モデルをそのまま用いると 0.628（1 回の生成）と、いずれも処理なし（0.447。逆向きの評価と同じ回に認識し直した値は 0.448）より悪化した。今回の設定では、事前学習と、対象の喉マイクでの適応の両方が効いていた。

4.2 ASR 損失は何を足すか

融合は、Whisper 系 6 種すべてで生成 ×4 より CER を下げた（−1.8〜−8.0%)。small・medium・turbo・FT では、元の学習を含む 3 回とも有意であった。base と Qwen3 は元の学習では有意でなかった。CE-SE 単体は Whisper 系を改善したが、XLSR と Zipformer は悪化させた（元の学習で +26%・+46%、学習し直した 2 回では約 +11〜12%)。

上乗せが単に 2 つの出力を平均した効果かを確かめるため、CE 損失を用いない SE を同じ方法で融合した（表 2)。TAPS SE や再構成損失のみで追加学習した SE（$\lambda = 0$）との融合は、Whisper 系で生成 ×4 から −1.7〜+3.1% とほぼ改善せず、CE-SE との融合はそれより 6 種すべてで有意に低かった。ただし SSL-MSE との融合でも、turbo・FT では有意に改善した。CE 損

表2: 生成 ×4 に融合する SE を変えた対照（CER）。+CE が本稿の融合（CE-SE との融合）

認識器	生成 ×4	+TAPS	+λ=0	+SSL	+CE
W-small*	0.169	0.172	0.172	0.168	**0.163**
W-medium	0.150	0.150	0.151	0.147	**0.144**
W-turbo	0.131	0.130	0.129	0.128	**0.125**
W-FT	0.100	0.099	0.098	0.095	**0.092**
Qwen3	0.097	0.099	0.100	0.096	**0.094**

失による学習は上乗せを大きくするが、必要条件とまではいえない。

4.3 上乗せに関わる成分

融合が生成 ×4 から何を変えたかを、元の学習のモデルで切り分けた（表 3）。対数振幅の差 $D = \log|Y| - \log|G|$（Y: 融合）を用いる。まず、D を無音以外のフレームで時間平均した周波数ごとの値（以下、平均ゲイン）を、生成 ×4 の対数振幅に加えた。dev で求めたもの、有声・無声・無音ごとのもの、同じ発話の融合から求めたもの（発話別 EQ）のいずれも、Whisper 系で生成 ×4 から ±2% 以内であった（すべて有意でない）。検討した平均ゲインでは、上乗せを再現できなかった。

次に、D をケプストラム 30 次未満の包絡 PD と残りの細部 $(I-P)D$ に分け、片方だけをフレームごとに生成 ×4 の対数振幅に加えた（両方を加えると融合の対数振幅に戻る。位相は生成 ×4 に固定）。細部だけでは、どの認識器にも有意な改善は認められなかった。包絡だけでは medium・turbo・FT で生成 ×4 より 3〜4% 下がり（有意）、融合の改善量の約半分〜9 割に当たった。Qwen3 では包絡だけでは改善せず、融合は包絡だけより有意に低かった。また、融合を有声らしいフレーム(生成 ×4 で無音でなく 2 kHz 未満のエネルギーの割合が 0.5 を超える、全体の約 83%）に限ると上乗せの多くが残ったが、同じマスクを発話内で時間方向に巡回シフトしても同程度に残った（両者の差はすべて有意でない）。効果が特定の区間に集まる証拠は得られなかった。音響的には、融合は高域の量やスペクトル傾斜を気導音に近づける一方、LPC で推定したフォルマントの帯域幅を広げて気導音から遠ざけた。Whisper-small・medium・FT・Qwen3 では、発話ごとのこれらの量の変化と CER の変化の単調な相関は小さかった（$|\rho|$ は約 0.08 以下）。

系統の異なる認識器では逆の傾向があった。Zipformer は発話別 EQ だけで生成 ×4 より 3.6% 改善した（10 話者全員）が、包絡だけを加えると +17.7% と、融合（+11.7%）以上に悪化した。複数の Whisper への上乗せと、XLSR・Zipformer の悪化は、どちらも包絡の成分に関わっていた（XLSR も包絡だけで +3.9%）。

表3: 上乗せの切り分け（元の学習、CER）。EQ: 発話別 EQ、包絡／細部: 融合と生成 ×4 の対数振幅の差の包絡／細部だけを加える、有声／ずらし: 有声らしいフレーム／同じマスクを時間方向にずらしたフレームだけ融合

認識器	生成 ×4	EQ	包絡	細部	有声	ずらし	融合
W-small*	0.169	0.170	0.166	0.169	0.164	0.165	0.163
W-medium	0.150	0.151	0.146	0.151	0.146	0.146	0.144
W-turbo	0.131	0.131	0.126	0.132	0.126	0.126	0.125
W-FT	0.100	0.100	0.096	0.099	0.095	0.095	0.092
Qwen3	0.097	0.096	0.097	0.099	0.092	0.095	0.094
Zipformer	0.433	0.417	0.510	0.444	0.489	0.486	0.483

4.4 別の喉マイクでの評価

仏語の体内伝導マイクコーパス VibraVox [16] の喉マイク音声（test 3,064 発話・21 話者、話者は train と重ならない）で評価した（表 4）。TAPS で学習した生成モデルと SE をそのまま用いると、いずれも処理なしより悪化した。音量と帯域を TAPS にそろえても変わらなかった。逆向き（VibraVox で適応した生成モデルを TAPS に用いる）でも悪化しており（4.1 節）、今回の 2 つのデータセットの間では、生成モデルはどちらの向きにも調整なしでは使えなかった。ただし言語と機器が同時に変わっており、両者の寄与は分けていない。VibraVox の train（20,981 対）で同じ手順の適応をやり直すと（生成モデルは事前学習済みから、SE は TAPS SE を再構成損失のみで VibraVox に合わせてから CE-SE を学習。λ、重み、N は TAPS の値に固定）、生成 ×4 は処理なしより 70〜82%、融合はさらに 3〜15%CER を下げ（base のみ有意でない）、改善の順序が再現した。TAPS と異なり、CE-SE と融合は仏語の CTC 認識器も改善し、他系統への影響はデータセットに依存した。Whisper-small・1 回の生成では、train の 1,000 対（約 1.3 時間、10k step）の適応でも、全データ（約 26 時間、20k step）の改善量の約 86% が得られた（1 試行）。

5 考察と限界

前処理が喉マイク音声の認識を助けるかは、条件で反転する。今回の設定では、事前学習済みの生成モデルを対象の喉マイクで適応したときは認識器の系統によらず効き、事前学習がないときや別の喉マイクのままのときは害になった。汎用の復元で CER が悪化した先

表4: VibraVox test の CER（仏語）。上段: TAPS で学習したまま、下段: VibraVox で適応。XLSR・MMS は仏語版（–は未評価）

条件	W-small	W-turbo	Qwen3	XLSR	MMS
処理なし	0.422	0.269	0.242	0.275	0.258
TAPS SE	0.711	0.654	0.594	0.501	0.577
生成 ×4	0.559	0.497	0.454	–	–
再構成のみ	0.256	0.163	0.154	0.163	0.187
CE-SE	0.153	0.081	0.081	0.128	0.131
生成 ×4	0.087	0.053	0.046	0.063	0.076
融合	**0.079**	**0.045**	**0.041**	**0.058**	**0.067**

行研究の評価条件 [4] とも整合する。ASR 損失で学習した SE は、その上に Whisper 系向けの小さな上乗せを足すもので、検討した平均ゲインでは再現せず、フレームごとの包絡の差が複数の Whisper で改善に関わった。この変化は気導音への一様な接近では説明できず、近づく特徴と遠ざかる特徴があった。他系統の認識器への影響はデータセットによって正負が変わり、原因は特定できていない。

限界として、今回は喉マイクごとに対データで適応しており、見たことのない機器への汎化は示せていない。VibraVox での評価も、話者は学習と重ならないが同一コーパス内の評価である。融合の計算量は大きい（4.3 億パラメータのモデルを 20 ステップ・4 サンプル実行）が、5 ステップ・1 サンプルにしても Whisper 系の CER はほぼ変わらず（Whisper-small 0.164）、推論時間は約 1/10 になった。ただし Zipformer はステップ数を減らすと悪化した。また、元の学習と学習し直した学習とでは計算環境も異なり、他系統への悪化の大きさは学習ごとに変わった。4.3 節の分解は元の学習についての結果である。用いた生成モデルの重みは非商用のライセンスである。

6 まとめ

喉マイク音声の前処理が認識を助ける条件と仕組みを、9 種の認識器と 2 つのデータセットで調べた。事前学習済みの生成モデルを対象の喉マイクで適応すると、9 種すべての認識器と、喉マイク用に学習した Whisper でも CER が下がった。Whisper の損失で学習した SE との融合は Whisper 系に小さな上乗せを足し、元の学習では、融合と生成 ×4 の差の包絡だけで、medium・turbo・FT の上乗せの約半分〜9 割が得られた。今回の 2 つのデータセットの間では生成モデルは調整なしでは転移せず、少量の対データでの適応と、見たことのない機器への汎化が今後の課題である。

参考文献

[1] Y. Kim *et al.*, “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” *Scientific Data*, 2026.

[2] A. Radford *et al.*, “Robust speech recognition via large-scale weak supervision,” in *Proc. ICML*, 2023.

[3] T. Ochiai *et al.*, “Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance,” *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 32, 2024.

[4] 山中涼雅 *et al.*, “Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” in 日本音響学会 *2026* 年秋季研究発表会講演論文集, 2026, 1-Q-42.

[5] J. Hauret, T. Joubaud, and É. Bavu, “Real-time speech enhancement in noise for throat microphone using neural audio codec as foundation model,” arXiv:2508.02974, 2025.

[6] Y. Dissen *et al.*, “Enhanced ASR robustness to packet loss with a front-end adaptation network,” in *Proc. Interspeech*, 2024.

[7] H. Shi *et al.*, “Diffusion-based speech enhancement with joint generative and predictive decoders,” in *Proc. ICASSP*, 2024, pp. 12 951–12 955.

[8] Y. Lipman *et al.*, “Flow matching for generative modeling,” in *Proc. ICLR*, 2023.

[9] P.-J. Ku *et al.*, “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117, 2024.

[10] E. Kim and H. Seo, “SE-Conformer: Time-domain speech enhancement using conformer,” in *Proc. Interspeech*, 2021, pp. 2736–2740.

[11] Qwen Team, “Qwen3-ASR technical report,” arXiv:2601.21337, 2026.

[12] V. Pratap *et al.*, “Scaling speech technology to 1,000+ languages,” *J. Mach. Learn. Res.*, vol. 25, 2024.

[13] A. Conneau *et al.*, “Unsupervised cross-lingual representation learning for speech recognition,” in *Proc. Interspeech*, 2021, pp. 2426–2430.

[14] Z. Yao *et al.*, “Zipformer: A faster and better encoder for automatic speech recognition,” in *Proc. ICLR*, 2024.

[15] H. Sato *et al.*, “Generic speech enhancement with self-supervised representation space loss,” *Frontiers in Signal Processing*, vol. 5, 2025.

[16] J. Hauret *et al.*, “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” *Speech Communication*, 2025.