喉マイク音声の認識に前処理はいつ効くのか ——事前学習済み生成モデルの適応と ASR 損失の役割——[*1]

春日　裕次（明治大学　総合数理学部　先端メディアサイエンス学科）

1　はじめに

喉マイクは頸部の振動を捉えるため環境騒音に強いが、高域や一部の子音の情報が失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] の喉マイク音声を Whisper-small [2] でそのまま認識すると、文字誤り率（CER）は 0.447 に達する。

前処理としての音声強調（SE）は有力な対策に見えるが、知覚品質の改善が音声認識（ASR）の改善を保証しないことが知られている [3]。喉マイクでも、学習なしの生成的な帯域拡張や声質変換は CER を悪化させたと報告されている [4]。一方、Hauret ら [5] は事前学習済みの生成モデルを体内伝導マイクで追加学習し、1 種の音素認識器で誤りの大幅な低下を報告した。また、凍結した ASR の損失で前処理を学習する方法 [6] や、生成型と予測型の出力を融合する方法 [7] も提案されている。しかし、喉マイクに対して前処理が認識を助けるのはどんな条件か、ASR 損失が何を足すのか、それがなぜ効くのかは、複数の認識器で調べられていない。

本稿は、9 種の認識器と 2 つのデータセットでこれを分析し、次の 3 点を示す。(1) 事前学習済みの生成モデルを対象の喉マイクで適応すると、9 種すべてで CER が下がり、喉マイク音声で追加学習した Whisper にも上乗せできる。事前学習なし、または別の喉マイクで適応したままでは悪化する。(2) Whisper の損失で学習した SE との融合は、Whisper 系に小さな上乗せを足す。上乗せの正体は有声区間における時間変化するスペクトル包絡の変形であり、平均的な音色の違いではない。同じ変形が、系統の異なる認識器には害になりうる。(3) 部品は喉マイクの間でどちらの向きにも転移しないが、同じ手順で適応し直せば改善の順序は再現する。

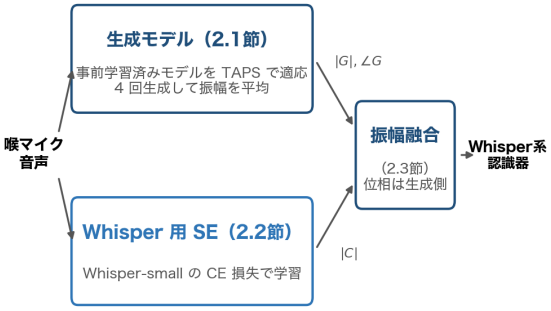


図1: 手法の全体像。喉マイク音声を生成モデルと Whisper 用 SE の両方に通し、出力の振幅を融合する

2　方法

2.1　生成モデルによる復元

NVIDIA が公開している flow matching [8] 型の音声復元モデル [9] を用いる。複素 STFT を扱う 24 層の Transformer（4.3 億パラメータ）で、英語約 6 万時間の音声で、マスクした区間を復元するタスクにより事前学習されている。これを喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する（ASR の損失は用いない）。推論では標準正規分布の雑音から出発し、Euler 法 20 ステップで生成する。生成は出発点の雑音に依存してばらつくので、$N = 4$ 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる（以下、生成 $\times 4$）。

2.2　Whisper 用 SE と振幅融合

TAPS 論文 [1] が公開している SE-Conformer [10]（1210 万パラメータ、以下 TAPS SE）を初期値とし、次の損失で追加学習する（以下 CE-SE）。

$$L = L_{\mathrm{recon}}(\hat{s}, s_{\mathrm{air}}) + \lambda\,\mathrm{CE}(\mathrm{Whisper}(\hat{s}), y) \qquad (1)$$

L_{recon} は L1 波形損失と多重解像度 STFT 損失の和、y は正解テキストで、Whisper-small は凍結する。生成 $\times 4$ の出力 G と CE-SE の出力 C は、STFT（512 点、シフト 128 点）の振幅で融合し、位相は G のものを用

[*1] When does preprocessing help throat-microphone speech recognition? Roles of pretrained generative restoration and ASR-loss enhancement, by KASUGA, Yuji (Meiji University).

いる（以下、融合 A）。

$$Y = \left(0.5\,|G| + 0.5\,|C|\right) e^{j\angle G} \tag{2}$$

$\lambda = 10$ と重み 0.5 は、dev で Whisper-small の CER のみを見て選んだ。

3 実験条件

TAPS [1]（韓国語）の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各 100 発話）を用いた。生成モデルは train の 4,000 対で 20k step 追加学習し、最終ステップの重みを用いた。CE-SE は最大 50 エポック学習し、dev の損失で early stopping を行った。test は話者が学習と重ならないが、収録機器・言語は同じである。融合の採用は test の他の認識器も見て決めたため、TAPS 上の分析は探索的である。

認識器は、Whisper と同形式の対数メルを入力とする Whisper 系 6 種（Whisper-small（損失と選択に使用）・base・medium・large-v3-turbo、TAPS の喉マイク音声で追加学習した Whisper-small（FT Whisper）、Qwen3-ASR-1.7B [11]）と、系統の異なる 3 種（波形入力の CTC 型である MMS-1B [12] と XLSR-53 [13] の韓国語版（XLSR）、Zipformer [14]）である。CER は句読点を除き、発話ごとに 1.0 で打ち切って平均した。話者ごとの平均 CER で両側の Wilcoxon 符号順位検定を行い、条件の対ごとに認識器をまたいで Holm 法で補正した（10 話者全員が同じ向きのとき $p \approx 0.018$）。CE-SE と生成モデルは 2 回ずつ学習し直して再現性を確かめた。

4 実験結果

4.1 前処理が効く条件

表 1に各手法の CER を示す。生成モデルは 9 種すべてで TAPS SE より CER を下げた（1 回の生成でも 15〜24%、10 話者全員）。喉マイク音声で追加学習した FT Whisper でも、処理なしの 0.138 から生成 ×4 で 0.100、融合 A で 0.092（−33%、10 話者全員）へ下がり、認識器を喉マイクに適応した後も前処理が効いた。一方、同じ構造を同じ量だけ初期値から学習したモデルは Whisper-small で 0.551、別の喉マイク（4.4 節の VibraVox）で適応した生成モデルを用いると 0.628 と、いずれも処理なし（0.447）より悪化した。事前学習と、対象の喉マイクでの適応の両方が要る。

表1: TAPS test の CER。なし: 処理なし、TAPS: TAPS SE、W-FT: FT Whisper、*: 損失・選択に使用

認識器	なし	TAPS	CE-SE	生成 ×4	融合 A
W-small*	0.447	0.230	0.196	0.169	**0.163**
W-base	0.655	0.273	0.267	0.205	**0.201**
W-medium	0.337	0.196	0.169	0.151	**0.144**
W-turbo	0.257	0.170	0.142	0.131	**0.125**
W-FT	0.138	0.146	0.121	0.100	**0.092**
Qwen3	0.243	0.136	0.114	0.097	**0.094**
XLSR	0.584	0.222	0.279	**0.161**	0.163
MMS-1B	0.497	0.350	0.354	**0.284**	0.285
Zipformer	0.997	0.542	0.791	**0.433**	0.483

表2: 生成 ×4 に融合する SE を変えた対照（CER）。+CE が融合 A

認識器	生成 ×4	+TAPS	+λ=0	+SSL	+CE
W-small*	0.169	0.172	0.172	0.168	**0.163**
W-medium	0.151	0.150	0.151	0.147	**0.144**
W-turbo	0.131	0.130	0.129	0.128	**0.125**
W-FT	0.100	0.099	0.098	0.095	**0.092**
Qwen3	0.097	0.099	0.100	0.096	**0.094**

4.2 ASR 損失は何を足すか

融合 A は、Whisper 系 6 種すべてで生成 ×4 より CER を下げた（−1.8〜−8.0%）。small・medium・turbo・FT では、学習し直した 3 回とも有意であった。CE-SE 単体は Whisper 系を改善したが、XLSR と Zipformer は悪化させた（元の学習で +26%・+46%、学習し直した 2 回では約 +11〜12%）。

上乗せが単に 2 つの出力を平均した効果かを確かめるため、CE 損失を用いない SE を同じ方法で融合した（表 2）。TAPS SE や再構成損失のみで追加学習した SE（$\lambda = 0$）との融合は、Whisper 系で生成 ×4 から −1.7〜+3.1% とほぼ改善せず、融合 A はそれより 6 種すべてで有意に低かった。ただし自己教師あり表現の損失で学習した SE（SSL-MSE、Sato ら [15] に倣う）との融合でも、turbo・FT では有意に改善した。CE 損失による学習は上乗せを大きくするが、必要条件とまではいえない。

4.3 上乗せの正体

融合 A が生成 ×4 から何を変えたかを、元の学習のモデルで調べた（表 3）。まず、融合 A との振幅の差の時間平均をゲインとして生成 ×4 に掛けた。dev で求めた固定ゲイン、有声・無声・無音ごとのゲイン、その発話の融合 A から求めたゲイン（現実には使えない上限）のいずれも、Whisper 系で生成 ×4 から ±2% 以内で

表3: 上乗せの分解（元の学習、CER）。固定: 発話ごとの固定ゲイン（上限）、包絡: 包絡だけをフレームごとに移す、有声／他: その種類のフレームだけ融合

認識器	生成 ×4	固定	包絡	有声	他	融合 A
W-small*	0.169	0.170	0.166	0.164	0.169	0.163
W-medium	0.151	0.151	0.145	0.146	0.149	0.144
W-turbo	0.131	0.132	0.125	0.126	0.131	0.125
W-FT	0.100	0.100	0.094	0.095	0.099	0.092
Qwen3	0.097	0.096	0.094	0.092	0.099	0.094
Zipformer	0.433	0.417	0.455	0.489	0.429	0.483

あった（すべて有意でない）。一方、対数振幅の差のうちケプストラム 30 次未満の包絡だけを、フレームごとに移すと、融合 A の上乗せの 58〜100% が戻った。さらに融合を一部のフレームだけに適用すると、有声らしいフレーム（生成 ×4 自身から判定）だけで上乗せの 63〜88% が得られ（Qwen3 は融合 A 以上）、それ以外のフレームだけではどの認識器でも効果がなかった。Whisper 系への上乗せは、平均的な音色ではなく、有声区間で時間とともに変わる包絡の変形による。音響的には、融合 A は生成 ×4 より高域の量やスペクトル傾斜を気導音に近づける一方、フォルマントの帯域幅を広げて気導音から遠ざけた（F3: 生成 ×4 256 Hz、融合 A 338 Hz、気導 247 Hz）。ただし、こうした発話ごとの特徴の変化は、Whisper-small・medium・FT・Qwen3 の CER の変化と相関せず（$|\rho| < 0.08$）、単純な音響量には還元できない。

Zipformer では逆に、固定ゲインだけで生成 ×4 より 3〜4% 改善し（10 話者全員）、有声フレームだけの融合で +12.9% と悪化した。同じ有声区間の変形が、Whisper 系には効き、Zipformer には害になる。

4.4 別の喉マイクでの評価

仏語の体内伝導マイクコーパス VibraVox [16] の喉マイク音声（test 3,064 発話・21 話者、話者は train と重ならない）で評価した（表 4）。TAPS で学習した部品をそのまま用いると、いずれも処理なしより悪化した。音量と帯域を TAPS にそろえても変わらなかった。逆向き（VibraVox で適応した生成モデルを TAPS に用いる）でも悪化しており（4.1 節）、部品はどちらの向きにも転移しない。VibraVox の train（20,981 対）で同じ手順の適応をやり直すと（λ、重み、N は TAPS の値に固定）、生成 ×4 は処理なしより 70〜82%、融合 A はさらに 3〜15%CER を下げ、改善の順序が再現した。TAPS と異なり、CE-SE と融合は仏語の CTC 認識器も改善し、他系統への影響はデータセットに依存した。生成モデルの適応は、train の 1,000 対（約 1.3 時間、10k step）でも全データ（約 26 時間、20k step）の改善量の約 86% が得られた（1 試行）。

表4: VibraVox test の CER（仏語）。上段: TAPS の部品のまま、下段: VibraVox で適応。XLSR・MMS は仏語版（–は未評価）

条件	W-small	W-turbo	Qwen3	XLSR	MMS
処理なし	0.422	0.270	0.242	0.275	0.258
TAPS SE	0.711	0.654	0.594	0.501	0.577
生成 ×4	0.559	0.497	0.454	–	–
再構成のみ	0.256	0.163	0.154	0.163	0.187
CE-SE	0.153	0.081	0.081	0.128	0.131
生成 ×4	0.087	0.053	0.047	0.063	0.076
融合 A	**0.079**	**0.045**	**0.041**	**0.058**	**0.067**

5 考察と限界

前処理が喉マイク音声の認識を助けるかは、条件で反転する。事前学習済みの生成モデルを対象の喉マイクで適応したときは認識器の系統によらず効き、事前学習がないとき、別の喉マイクのままのとき、学習なしの汎用の復元 [4] では害になる。ASR 損失で学習した SE は、その上に Whisper 系向けの小さな上乗せを足すもので、その中身は有声区間の包絡の変形であった。この変形は気導音に近づく方向ではなく、他系統の認識器への影響はデータセットによって正負が変わった。原因は特定できていない。

限界として、部品は喉マイクごとに対データで適応する必要があり、見たことのない機器への汎化は示せていない。VibraVox 内での評価もデータセットとしてはクローズドである。融合の計算量も大きい（4.3 億パラメータのモデルを 20 段・4 サンプル実行）。また、元の学習と学習し直した学習とでは計算環境も異なり、他系統への悪化の大きさは学習ごとに変わった。4.3 節の分解は元の学習についての結果である。用いた生成モデルの重みは非商用のライセンスである。

6 まとめ

喉マイク音声の前処理が認識を助ける条件と仕組みを、9 種の認識器と 2 つのデータセットで調べた。事前学習済みの生成モデルを対象の喉マイクで適応すると、9 種すべての認識器と、喉マイク用に学習した Whisper でも CER が下がった。Whisper の損失で学習した SE との融合は Whisper 系に小さな上乗せを足し、その正体は有声区間で時間変化する包絡の変形であった。部

品は喉マイクの間で転移せず、機器ごとの少量の対データでの適応と、見たことのない機器への汎化が今後の課題である。

参考文献

[1] Y. Kim *et al.*, "Throat and acoustic paired speech dataset for deep learning-based speech enhancement," *Scientific Data*, 2026.

[2] A. Radford *et al.*, "Robust speech recognition via large-scale weak supervision," in *Proc. ICML*, 2023.

[3] T. Ochiai *et al.*, "Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance," *IEEE/ACM Trans. Audio, Speech, Lang. Process.*, vol. 32, 2024.

[4] 山中涼雅 *et al.*, "Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討," in 日本音響学会 *2026* 年秋季研究発表会講演論文集, 2026, 1-Q-42.

[5] J. Hauret, T. Joubaud, and É. Bavu, "Real-time speech enhancement in noise for throat microphone using neural audio codec as foundation model," arXiv:2508.02974, 2025.

[6] Y. Dissen *et al.*, "Enhanced ASR robustness to packet loss with a front-end adaptation network," in *Proc. Interspeech*, 2024.

[7] H. Shi *et al.*, "Diffusion-based speech enhancement with joint generative and predictive decoders," in *Proc. ICASSP*, 2024, pp. 12 951–12 955.

[8] Y. Lipman *et al.*, "Flow matching for generative modeling," in *Proc. ICLR*, 2023.

[9] P.-J. Ku *et al.*, "Generative speech foundation model pretraining for high-quality speech extraction and restoration," arXiv:2409.16117, 2024.

[10] E. Kim and H. Seo, "SE-Conformer: Time-domain speech enhancement using conformer," in *Proc. Interspeech*, 2021, pp. 2736–2740.

[11] Qwen Team, "Qwen3-ASR technical report," arXiv:2601.21337, 2026.

[12] V. Pratap *et al.*, "Scaling speech technology to 1,000+ languages," *J. Mach. Learn. Res.*, vol. 25, 2024.

[13] A. Conneau *et al.*, "Unsupervised cross-lingual representation learning for speech recognition," in *Proc. Interspeech*, 2021, pp. 2426–2430.

[14] Z. Yao *et al.*, "Zipformer: A faster and better encoder for automatic speech recognition," in *Proc. ICLR*, 2024.

[15] H. Sato *et al.*, "Generic speech enhancement with self-supervised representation space loss," *Frontiers in Signal Processing*, vol. 5, 2025.

[16] J. Hauret *et al.*, "Vibravox: A dataset of French speech captured with body-conduction audio sensors," *Speech Communication*, 2025.