

Whisper 系音声認識に向けた喉マイク音声強調における 事前学習済み生成モデルと ASR 損失の役割¹

春日 裕次 (明治大学 総合数理学部 先端メディアサイエンス学科)

1. はじめに

喉マイクは頸部の振動を接触型センサで捉えるため環境騒音に強いが、軟組織の伝搬特性により高域が大きく失われる。喉マイクと気導マイクの同時収録コーパス TAPS [1] では喉マイクが 8 kHz で収録されており、4 kHz 以上は収録時点から存在しない。Whisper-small [2] で喉マイク音声のまま認識すると文字誤り率 (CER) は 0.446 に達する。

前処理としての音声強調 (SE) は有力な対策であるが、知覚品質の改善が音声認識 (ASR) の改善を保証しないことが知られている [3]。この乖離に対し、凍結した ASR の損失で SE を学習する方法が提案されてきた [4, 5]。しかし、損失に用いた認識器以外への効果は十分に調べられていない。本稿の実験でも、Whisper-small の交差エントロピー

(CE) 損失で学習した喉マイク SE は、Whisper では CER を下げる一方、入力特徴量の異なる認識器では悪化した (4.1 節)。ASR 損失で学習した SE は、損失に用いた認識器の入力特徴量に特化する。

一方、喉マイクの問題は雑音の混入ではなく帯域や子音の欠落であり、欠けた成分を補う必要がある。大規模音声で事前学習した生成モデル [6] は、入力が持たない成分を自然な音声として生成できる。体内伝導マイクではこの種の生成モデルの適応が有効との報告がある [16] が、評価は単一の認識器に限られる。また、生成的な帯域拡張や声質変換が喉マイク音声の CER を悪化させたという報告もある [8]。

本稿では対象を Whisper と同じ対数メルスペクトログラムを入力とする認識器 (以下 Whisper 系) に定め、損失と設定の選択には Whisper-small のみを用い、他の Whisper 系 5 種を評価専用とする。そのうえで次の 3 点を示す。(1) 事前学習済みの flow matching 生成モデルを TAPS で適応すると、入力特徴量の異なる認識器を含む 9 種すべてで CER が下がり、効果は事前学習に由来する。(2)

生成モデルの複数サンプルの振幅平均に、Whisper 用 SE の出力を振幅で融合すると、学習に用いていない Whisper 系にもさらに上乗せが得られる。(3) 生成モデル自体を Whisper の損失で学習する方法は失敗し、融合の上乗せは帯域の両側から生じ、他系統の認識器への害は元々存在しない 4 kHz 以上の成分から生じる。

2. 方法

2.1 生成モデルによる復元

NVIDIA が公開している flow matching [9] 型の音声復元モデル (4.3 億パラメータ、複素 STFT 領域) [6] を用いる。このモデルは大規模な音声データで、マスクした区間を復元するよう事前学習されている。本研究では TAPS の喉マイク音声を条件、同時収録の気導マイク音声を目標として追加学習する (ASR の損失は用いない)。推論では標準正規分布の雑音から出発し、喉マイク音声を条件として常微分方程式を Euler 法 20 ステップで解く。生成は出発点の雑音に依存して発話ごとにばらつく。そこで乱数の種を変えた N 個のサンプルの STFT 振幅を平均し、位相は 1 つ目のサンプルのものを用いる。

$$|G| = (1/N) \sum_n |G_n|, \angle G = \angle G_1$$

2.2 Whisper 用 SE

TAPS 論文 [1] の SE-Conformer (1210 万パラメータ、以下 TAPS SE) を初期値とし、次の損失で追加学習したモデル (以下 CE-SE) を用いる。

$$L = L_{\text{recon}}(\mathcal{S}, s_{\text{air}}) + \lambda \text{CE}(\text{Whisper}(\mathcal{S}), y)$$

$\mathcal{S}$ は SE 出力、 s_{air} は気導音声、 y は正解テキスト、 L_{recon} は L1 波形損失と多重解像度 STFT 損失の和である。Whisper-small は凍結し、 λ は dev の CER で {0, 0.1, 0.5, 1, 2, 5, 10} から選んで 10 とした。

2.3 振幅融合

生成モデルの出力 G ($N = 4$ の平均) と CE-SE の出力 C を、STFT (512 点、シフト 128 点) の振幅

¹Roles of a pretrained generative model and ASR-loss enhancement in throat-microphone speech enhancement for Whisper-family recognizers, by KASUGA, Yuji (Meiji University).

で重み付き平均し、位相は生成モデルのものを用いる。

$$Y = \{(1 - w)|Q| + w|Q|\} \exp(j\angle Q)$$

w は dev で Whisper-small の CER のみを見て {0.25, 0.5, 0.75} から選び、 $w = 0.5$ とした (dev の CER はそれぞれ 0.202・0.196・0.198)。融合に新たな学習は要らない。

3. 実験条件

3.1 データと学習

TAPS[1]の話者独立な分割 (train 40 話者・dev 10 話者・test 10 話者、各話者 100 発話) を用いた。生成モデルは train の 4,000 対で 20k step 追加学習した (batch 8、6.14 秒の切り出し、学習率 10^{-4} 、EMA、32 ビット浮動小数点)。モデルの選択には最終ステップを用い、test を見て選んでいない。CE-SE は Adam (学習率 3×10^{-4} 、batch 4) で最大 50 エポック学習し、dev の損失で early stopping を行った。15 秒を超える発話は学習から除外した。

3.2 比較手法

TAPS SE、CE-SE に加え、2 つの既存手法を比較した。SSL-MSE は、SE 出力と気導音声の WavLM-Large[10]全層の表現の二乗誤差を再構成損失に加えて TAPS SE を追加学習したもので、Sato ら[5]の方式に従う。Dissen 型は、凍結した ASR の損失で前段を学習する方法[4]に倣い、喉マイクの対数メルスペクトログラムを入力・出力とする U-Net (約 700 万パラメータ) を、Whisper-small の CE と気導音声の対数メルへの L1 損失で学習したものである。

3.3 認識器と評価

Whisper 系. Whisper-small (損失と選択に使用)、Whisper-base、Whisper-medium、Whisper-large-v3-turbo、TAPS の喉マイク音声でファインチューニングした Whisper-small (FT Whisper)、Qwen3-ASR-1.7B の 6 種である。Qwen3-ASR のエンコーダは Whisper と異なるが、入力と同形式の対数メル (128 次元) である。

入力特徴量の異なる認識器. Whisper 系への特化を確認する対照として、波形入力の CTC 型である MMS-1B[11]と XLS-R[12] (韓国語で追加学習したもの)、Kaldi 型のフィルタバンクを入力とする Zipformer[13]を用いた。

指標. test 1,000 発話で、正解と認識結果の双方から句読点を除いた CER を発話ごとに求め (1.0 で打ち切り)、平均した。Zipformer は空白を含めた CER である。同一話者の発話は独立でないため、話者ごとの平均 CER を単位とする Wilcoxon 符号順位検定 ($n = 10$ 、最小の $p = 0.002$) を用いた。

4. 実験結果

4.1 主な結果

表 1 に各手法の CER を、図 1 に TAPS SE 比の相対変化を示す。生成モデル (1 回の生成) は 9 種の認識器すべてで TAPS SE より CER を 15~24% 下げ、いずれも 10 話者全員で改善した ($p = 0.002$)。Whisper-small の認識結果で見ると、CER が 0.99 以上に崩れた発話はなく、出力長の中央値も変わらず (正解長比 0.976)、置換と挿入の誤りが減っていた。生成による作り話の兆候は見られなかった。

同じ構造・同じ学習量で初期値を乱数としたモデルは、Whisper-small で 0.551、XLS-R で 0.524 と TAPS SE より大幅に悪化した。生成モデルの効果はモデルの規模ではなく事前学習に由来する。

表 1: 各手法の test CER (*は損失・選択に使用)

認識器	TAPS	CE-SE	SSL-MSE	生成 ×1	生成 ×4	融合
W-small*	0.230	0.196	0.204	0.180	0.169	0.163
W-base	0.273	0.267	0.241	0.218	0.205	0.201
W-medium	0.196	0.169	0.177	0.159	0.151	0.144
W-turbo	0.170	0.142	0.153	0.137	0.131	0.125
FT Whisper	0.146	0.121	0.124	0.110	0.100	0.092
Qwen3-ASR	0.136	0.114	0.114	0.104	0.097	0.094
XLS-R	0.222	0.279	0.190	0.169	0.161	0.163
MMS-1B	0.350	0.354	0.321	0.297	0.284	0.285
Zipformer	0.542	0.791	0.486	0.451	0.433	0.483




図 1: TAPS SE 比の CER 変化 (破線より上が Whisper 系)

4.2 サンプル平均と融合

4 サンプルの振幅平均は、1 回の生成よりさらに CER を下げた (Whisper-small 0.180→0.169、10/10 話者、 $p = 0.002$)。平均 CER は乱数の種によらずほぼ一定 (0.180・0.182・0.181) であったが、発話単位では 3 回の CER の差が 0.1 を超える発話が 82/1,000 あり、平均によりこのばらつきが抑えられたと考えられる。この改善は入力特徴量の異なる認識器でも同様であった。

CE-SE との融合は、Whisper 系の 6 種すべてで 4 サンプル平均より CER を下げた (-1.8~-8.0%)。Whisper-medium・large-v3-turbo・FT Whisper では 10/10 話者 ($p = 0.002$)、Whisper-small で 9/10 話者 ($p = 0.004$) で改善し、Whisper-base と Qwen3-ASR では有意でなかった。TAPS SE 比では Whisper 系で -26~-37% となり、SSL-MSE・CE-SE 単体のいずれよりも良い。一方、入力特徴量の異なる認識器では融合の上乗せはなく、Zipformer では 4 サンプル平均より 11.7% 悪化した (0/10 話者)。融合は Whisper 系に特化した上乗せである。

Dissen 型は 80 次元メル of Whisper にのみ適用できるため、全条件を transformers 版 Whisper の貪欲復号で認識し直して比較した。Whisper-small で TAPS SE 0.237、Dissen 型 0.239、融合 0.169 であり、Dissen 型は Whisper-base・medium・FT Whisper でも TAPS SE より悪かった。喉マイクのメルのみを入力とするため、欠けた帯域を補えなかったと考えられる。

4.3 生成モデル自体を Whisper に合わせる試み

融合の代わりに、生成モデル自体を Whisper-small の損失で学習する方法を試した (表 2)。途中時刻 t から 1 段で得られる完成音の見積もり $\hat{x}_t = x_t + (1 - \lambda)\hat{v}_t$ に CE をかけて追加学習すると、見積もりの CE は下がるが、20 段で生成した出力の CER は悪化した。CE なしで同じ手順をとると悪化しないため、原因は CE 損失にある。最終段のみに損失をかける DRaFT-K[14] 型の学習、生成出力に小さな補正モジュールを加える方法も効果がなかった。CE-SE を融合後の音に対する CE で再学習すると、Whisper 系では一貫して改善したが、幅は 0.2~1.9% にとどまった。

表 2: 生成モデルを Whisper に合わせる試み (W-small)

方法	結果
生成×1 (基準)	0.180
$\hat{x}_t$ に CE ($\lambda=0.1/0.01$)	0.193/0.191
同じ手順で CE なし ($\lambda=0$)	0.179
DRaFT-K (最終段に CE)	dev 損失が悪化
補正モジュール (0.03M)	変化なし
融合後の音で CE-SE を再学習	0.162 (融合 0.163)

4.4 融合の分解

CE-SE の何が Whisper 系に効くのかを、融合の作り方を変えて調べた (表 3)。CE-SE の出力には、3~7.75 kHz の 250 Hz 間隔の位置に鋭いピークが並ぶ楕状の成分が現れる。このピークをノッチで除いてから融合しても結果はほぼ変わらず、上乗せの原因ではなかった。4 kHz 未満のみ、または 4 kHz 以上のみを融合すると、Whisper 系の上乗せはそれぞれ約半分になり、両帯域から生じていた。一方、Zipformer は 4 kHz 未満のみの融合では悪化せず、悪化の原因は CE-SE が作る 4 kHz 以上の成分であった。喉マイクに元々存在しない帯域に、Whisper 向けに作られた成分が、Kaldi 型の特徴量を用いる認識器には害となっている。帯域ごとに重みを変えた 12 通りを dev で比較しても差は 1% 前後で、 $w = 0.5$ の一様な重みで十分であった。

表 3: 融合の分解 (test CER)

認識器	生成×4	融合	楕除去	<4 kHz	≥4 kHz
W-small*	0.169	0.163	0.163	0.166	0.167
W-medium	0.151	0.144	0.145	0.145	0.148
W-turbo	0.131	0.125	0.126	0.126	0.128
FT Whisper	0.100	0.092	0.093	0.094	0.099
Zipformer	0.433	0.483	0.491	0.431	0.479

4.5 気導音声との距離

ASR の学習に用いていない表現である HuBERT-Large[15] の全層について、同一発話の気導音声とのフレームごとのコサイン距離を求めた。これまでに評価した 17 条件をまたぐと、この距離は 9 認識器のうち最も悪化した認識器の CER 変化と強く相関した (Spearman $\rho = 0.92$)。一方、Whisper 系の CER との相関は弱く (Whisper-small $\rho = 0.37$)、CE-SE のように気導音声から離れる変化でも Whisper 系の CER は下がる。融合はこの両者を組み合わせており、距離は生成×4 の 0.092 から 0.111 へ増える。

5. 考察

結果は、喉マイク音声の Whisper 系向け SE において 2 つの成分が役割を分けていることを示す。事前学習済み生成モデルは欠けた成分を自然な音声として補い、認識器の系統によらず CER を下げる。CE-SE は特定の入力特徴量に合わせた変化を加え、その効果は損失に用いた Whisper-small だけでなく、学習に用いていない他サイズの Whisper や Qwen3-ASR にも及ぶ。ただし CE-SE 単体では Whisper-base の改善は小さく (-2.2%)、生成モデルの出力と融合して初めて系列全体に安定して効いた。

生成モデル自体を CE 損失で学習する試みが失敗したことは、Whisper に合わせる成分を生成過程に組み込むよりも、生成の外側で足すほうが容易であることを示唆する。1 段の見積もりに対する損失が多段の生成に持ち越されない点は、flow matching の学習目標がサンプルの分布を合わせるものであり、個々の出力を特定の損失で最適化する構造になっていないことと整合する。

実用上は 2 つの選択肢がある。Whisper 系のみを用いるなら一様な融合が最良であり、他系統の認識器も併用するなら 4 kHz 未満のみの融合で Zipformer への害を避けつつ Whisper 系の上乗せの約半分が得られる。

本研究の限界として、計算量が大きい (4.3 億パラメータのモデルを 20 段・4 サンプル実行) こと、評価が TAPS (韓国語・1 機種) のみであること、各モデルの学習が 1 回であることが挙げられる。融合自体は既存の部品の組み合わせであり、今後は融合の出力を教師とした軽量な SE への蒸留と、別言語・別機種の体内伝導マイクコーパス [7] での検証を行う。

6. まとめ

Whisper 系の認識器に向けた喉マイク SE について、事前学習済み生成モデルと ASR 損失で学習した SE の役割を調べた。生成モデルの適応は 9 種の認識器すべてで CER を下げ、その効果は事前学習に由来した。生成モデルの 4 サンプル平均と Whisper 用 SE の振幅融合は、学習に用いていない Whisper 系にも上乗せをもたらし、TAPS SE 比で 26~37% CER を下げた。一方、生成モデル自体を Whisper の損失で学習する方法は効果がなく、Whisper 用の成分のうち 4 kHz 以上のものは他系

統の認識器を悪化させた。

参考文献

- [1] Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026.
- [2] A. Radford et al., “Robust speech recognition via large-scale weak supervision,” Proc. ICML, 2023.
- [3] T. Ochiai et al., “Rethinking processing distortions: Disentangling the impact of speech enhancement errors on speech recognition performance,” IEEE/ACM TASLP, vol. 32, 2024.
- [4] Y. Dissen, S. Yonash, I. Cohen, and J. Keshet, “Enhanced ASR robustness to packet loss with a front-end adaptation network,” Proc. Interspeech, 2024.
- [5] H. Sato et al., “Generic speech enhancement with self-supervised representation space loss,” Frontiers in Signal Processing, vol. 5, 2025.
- [6] P.-J. Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117, 2024.
- [7] J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.
- [8] 山中 涼雅 ほか, “Zero-shot 音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” 音講論集, 1-Q-42, 2026 (秋) .
- [9] Y. Lipman et al., “Flow matching for generative modeling,” Proc. ICLR, 2023.
- [10] S. Chen et al., “WavLM: Large-scale self-supervised pre-training for full stack speech processing,” IEEE JSTSP, vol. 16, 2022.
- [11] V. Pratap et al., “Scaling speech technology to 1,000+ languages,” JMLR, vol. 25, 2024.
- [12] A. Babu et al., “XLS-R: Self-supervised cross-lingual speech representation learning at scale,” Proc. Interspeech, 2022.
- [13] Z. Yao et al., “Zipformer: A faster and better encoder for automatic speech recognition,” Proc. ICLR, 2024.
- [14] K. Clark et al., “Directly fine-tuning diffusion models on differentiable rewards,” Proc. ICLR, 2024.
- [15] W.-N. Hsu et al., “HuBERT: Self-supervised speech representation learning by masked prediction of hidden units,” IEEE/ACM TASLP, vol. 29, 2021.
- [16] J. Hauret et al., arXiv:2508.02974, 2025.