

喉マイク音声に対する音声強調が自動音声認識に与える影響の定量的評価

Quantitative Evaluation of Speech Enhancement Effects on Automatic Speech Recognition for Bone Conduction Microphone Audio

○ 著者名（所属機関）

【あらまし】

（喉マイク）は高騒音環境下での音声通信に有用であるが、その音声は低域偏重かつ高周波成分が欠落する特性を持つ。本研究では、DSPベースおよびニューラルネットワークベースの音声強調（SE）を Whisper を用いた文字誤り率（CER）への影響を定量的に評価した。TAPSデータセット（韓国語の50発話）に白色・ピンクノイズを SNR $-5 \sim +20$ dB で付加した計34条件で実験を行った。その結果、全ノイズ条件においてSEがSE未適用より悪化した。特にGTCRNはSTOI（短時間客観的理解度）を改善しながらCERを悪化させるという知見を示した。この現象はOchiai ら（TASLP 2024）が指摘するアーティファクト誤差に起因すると考えられる。喉マイク音声に対して気導マイク学習済みSEモデルを適用することの危険性を示す。

1. はじめに

骨伝導マイク（喉マイク・振動ピックアップ）は、ヘルメット着用や騒音環境下でも安定した音声收音が可能のため、軍事・工業・スポーツ用途で利用されている。しかし、その出力音声は低域エネルギーが支配的であり、高周波成分が著しく欠落するという特性を持つ。この特性により、一般的な音声認識（ASR）システムでは高い文字誤り率（CER）が生じる。

音声強調（Speech Enhancement: SE）は、ノイズ除去や音質改善を目的とした前処理として広く用いられる。しかし、Mawalim ら [1] は深層学習型SEが実環境ではASR性能を必ずしも改善しないことを示した。またOchiai ら [2] は、SEが導入するアーティファクト誤差（artifact error）が残留ノイズよりもASRに有害であることを定量的に示している。

本稿では、喉マイク音声という特殊なドメインにおいて、DSPベースおよびGTCRN [3] を用いたニューラルSEがWhisperの韓国語CERに与える影響を34条件にわたって評価し、SE逆効果が生じる条件を特定することを目的とする。

2. 実験設計

2.1 データセット

TAPSデータセット（Throat and Acoustic Pairing Speech Dataset）[4] のテストセットから50発話を使用した。各発話に対して喉マイク収録音声と気導マイク収録音声のペアが存在し、韓国語の正解テキスト（metadata.csv）が付属する。話者は1名（p00）、サンプリングレ

ートは16 kHz である。

2.2 ノイズ付加

喉マイク音声に対し、白色ノイズおよびピンクノイズを SNR $-5, 0, +5, +10, +20$ dB で混合し、計10条件のノイズ付き音声を生成した。ノイズはターゲット音声のRMSを基準に振幅を調整した。

2.3 音声強調モデル

DSP-only: Butterworth

6次ハイパスフィルタ（カットオフ300 Hz）+プリエンフ（係数0.97）+RMS正規化の組み合わせ。

DeepSE: GTCRN

韓国語の50発話のニューラルSEモデル [3]。DNS3コネクタ（気導マイク）で学習済み。STFT（窓長512、シフト256、Hann窓）を用いた複素領域処理。

2.4 評価指標

CER（Character Error Rate）: faster-whisper small

モデルによりtranscribe し、jiwer

ライブラリで算出した（言語指定: ko）。

STOI（Short-Time Objective Intelligibility）: クリーン喉マイク音声を参照としてpystoi

で算出した（値域0~1, 高いほど良好）。

3. 実験結果

3.1 クリーン条件

図1にクリーン条件のCER比較を示す。気導マイクベースライン（CER=0.131）に対し、喉マイク生音声は0.269と大幅に悪化する。DSP適用（0.416）はさらに悪化するが、GTCRN（0.296）は喉マイク生音声に近い性能を維持した。この結果はGTCRNがクリーン条件では有用であることを示す。




図1 クリーン条件における各手法のCER比較

3.2 ノイズ条件

図2および図3に白色・ピンクノイズ下でのSNRとCERの関係を示す。全SEモデルが全SNR条件でSE未適用（

No SE) よりも高いCERを示した。GTCRNはSNR +20 dBではNo SEに近い値を示すものの (white: 0.378 vs 0.330), SNRが低下するほど乖離が拡大し, SNR 0 dBでは1.214 (No SE: 0.882) に達した。




図2 SNR対CER (白色ノイズ)




図3 SNR対CER (ピンクノイズ)

3.3 STOIとCERの乖離

図4に全ノイズ条件のSTOI対CER散布図を示す。GTCRNの点群はNo SEと比較してSTOI軸方向 (右方向) に移動する一方, CER軸方向 (上方向) にも移動するという逆説的なパターンを示した。例えば白色ノイズ SNR 0 dB では, STOI: 0.585→0.721 (+0.136), CER: 0.882→1.214 (+0.332) となった。一方 DSP-only は STOI・CER ともに No SE より悪化した。




図4 STOI対CER散布図。GTCRNはSTOI改善・CER悪化の乖離を示す

4. 考察

4.1 アーティファクト誤差仮説

Ochiai ら [2] はSEによる誤差をアーティファクト誤差・干渉誤差・ノイズ誤差の3成分に分解し, アーティファクト誤差がASRに最も有害であることを示した。本実験でGTCRNがSTOIを改善しながらCERを悪化させる現象は, GTCRNが知覚的に自然な音声を生じつつ, Whisperが学習した音響特徴と乖離したアーティファクトを導入していると解釈できる。

4.2 ドメインミスマッチの影響

GTCRNはDNS3 (気導マイク, 主に英語) で学習されており, 喉マイク音声は学習分布外である。低域偏重かつ高周波欠落という喉マイクの周波数特性は, GTCRNに「ノイズ」として誤認識され, 過剰な抑圧や変形を引き起こす可能性がある。喉マイク専用学習済みSEモデルを用いた場合の効果検証が今後の課題である。

4.3 DSP-onlyの問題点

DSP-only はSTOI・CER の両方を悪化させた。300 Hz ハイパスフィルタは喉マイクのエネルギーの大半 (300 Hz 以下) を除去するため, むしろ有害な前処理となっていると考えられる。カットオフ周波数のパラメータ感度分析が必要である。

5. おわりに

本稿では喉マイク音声に対するSEの効果はCERとSTOIの両面から評価した。主要な知見は以下の通りである。

- (1) DSP-onlyおよびGTCRNは全ノイズ条件でCERを悪化させる。

(2) GTCRNはSTOIを改善しながらCERを悪化させる知覚品質とASR性能の乖離を示す。

(3) 本現象は気導マイク学習済みSEモデルの喉マイクへのドメイン外適用に起因するアーティファクト誤差によって説明される。

今後は、Whisper large-v3 による再評価、PESQ計測、DSPパラメータ感度分析、および実環境ノイズを用いた検証を行う予定である。

[2] T. Ochiai et al., "Rethinking Processing Distortions: How Do They Affect the Downstream ASR Performance?" IEEE/ACM Trans. Audio, Speech, Lang. Process., TASLP 2024, arXiv:2404.14860.

[3] X. Rong et al., "GTCRN: A Speech Enhancement Model Requiring Ultra-Tiny Resources," arXiv:2404.11567, 2024.

[4] Y. Kim et al., "TAPS: Throat and Acoustic Pairing Speech Dataset," HuggingFace: yskim3271/Throat_and_Acoustic_Pairing_Speech_Dataset.

付表 全条件のCER・STOI計測結果

条件	ノイズ	SNR	CER ↓	STOI ↑
baseline_acoustic	—	clean	0.131	-
baseline_throat	—	clean	0.269	-
dsp_only/clean	—	clean	0.416	0.847
gtcrn/clean	—	clean	0.296	0.990
no_se/white/snr_-5	white	-5	0.977	0.526
no_se/white/0	white	+0	0.882	0.585
no_se/white/5	white	+5	0.662	0.637
no_se/white/10	white	+10	0.512	0.696
no_se/white/20	white	+20	0.330	0.854
no_se/pink/snr_-5	pink	-5	1.042	0.483
no_se/pink/0	pink	+0	0.862	0.577
no_se/pink/5	pink	+5	0.635	0.660
no_se/pink/10	pink	+10	0.463	0.753
no_se/pink/20	pink	+20	0.305	0.936
dsp_only/white/snr_-5	white	-5	0.998	0.388
dsp_only/white/0	white	+0	1.028	0.434
dsp_only/white/5	white	+5	0.977	0.482
dsp_only/white/10	white	+10	0.802	0.540
dsp_only/white/20	white	+20	0.512	0.699
dsp_only/pink/snr_-5	pink	-5	1.001	0.380
dsp_only/pink/0	pink	+0	1.010	0.444
dsp_only/pink/5	pink	+5	0.843	0.510
dsp_only/pink/10	pink	+10	0.654	0.599
dsp_only/pink/20	pink	+20	0.489	0.782
gtcrn/white/snr_-5	white	-5	1.188	0.659
gtcrn/white/0	white	+0	1.214	0.721
gtcrn/white/5	white	+5	0.982	0.767
gtcrn/white/10	white	+10	0.708	0.810
gtcrn/white/20	white	+20	0.378	0.900
gtcrn/pink/snr_-5	pink	-5	1.081	0.624
gtcrn/pink/0	pink	+0	1.108	0.726
gtcrn/pink/5	pink	+5	0.854	0.788
gtcrn/pink/10	pink	+10	0.542	0.846
gtcrn/pink/20	pink	+20	0.370	0.936

色：緑(CER<0.30)・黄(0.30 - 0.50)・橙(0.50 - 0.80)・赤(≥0.80)

謝辞

本研究に使用したTAPSデータセットを公開してくださった研究者の方々に感謝する。

参考文献

[1] C.O. Mawalim, S. Okada, M. Unoki, "Are Recent Deep Learning-Based Speech Enhancement Methods Ready to Confront Real-World Noisy Environments?" Proc. Interspeech 2024, pp. 1735–1739, DOI: 10.21437/Interspeech.2024-129.