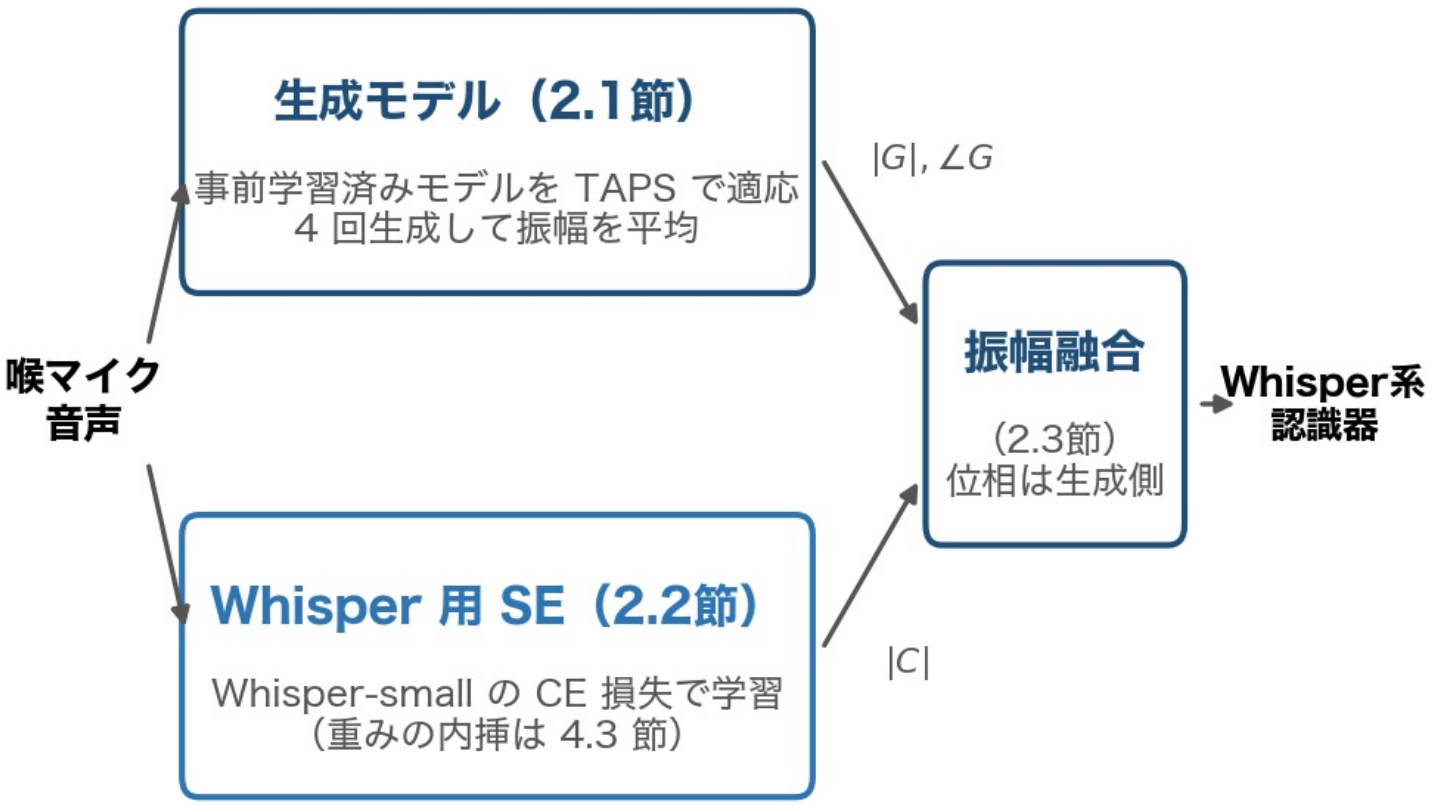
欠けた高域を生成モデルで補い、Whisper 用の強調を混ぜる



- 喉マイクは騒音に強いが、**4 kHz 以上が無い**
- 生成モデル（NVIDIA、4.3億パラメータ）を喉マイク→気導マイクの対で適応
- Whisper 用の音声強調と**振幅を半々で混ぜる**（融合A、学習不要）
- 9種の認識器で評価（損失・選択は Whisper-small のみ）

データ: TAPS（韓国語、喉マイクと気導マイクの同時収録。test 10話者・1,000発話、学習と話者は重ならない）

生成モデルは9種すべてで誤りを減らし、喉マイク用に学習した Whisper にも効いた

	処理なし	従来の強調	生成モデル	融合A
Whisper-small*	0.447	0.230	0.169	0.163
Whisper-medium	0.337	0.196	0.151	0.144
Whisper-large-v3-turbo	0.257	0.170	0.131	0.125
FT Whisper（喉マイク）	**0.138**	0.146	0.100	**0.092**
Qwen3-ASR	0.243	0.136	0.097	0.094
XLSR（系統が違う）	0.584	0.222	0.161	0.163
Zipformer（系統が違う）	0.997	0.542	0.433	**0.483**

- 生成モデルは従来の強調より **19〜32% 減**（9種すべて）
- 喉マイクで学習した Whisper も **0.138 → 0.092**
- 融合A は Whisper 系にさらに 2〜8%
- Zipformer は融合で**悪化**

文字誤り率（句読点除去、TAPS test）。従来の強調 = TAPS 公開の SE-Conformer。*: 損失・選択に使用

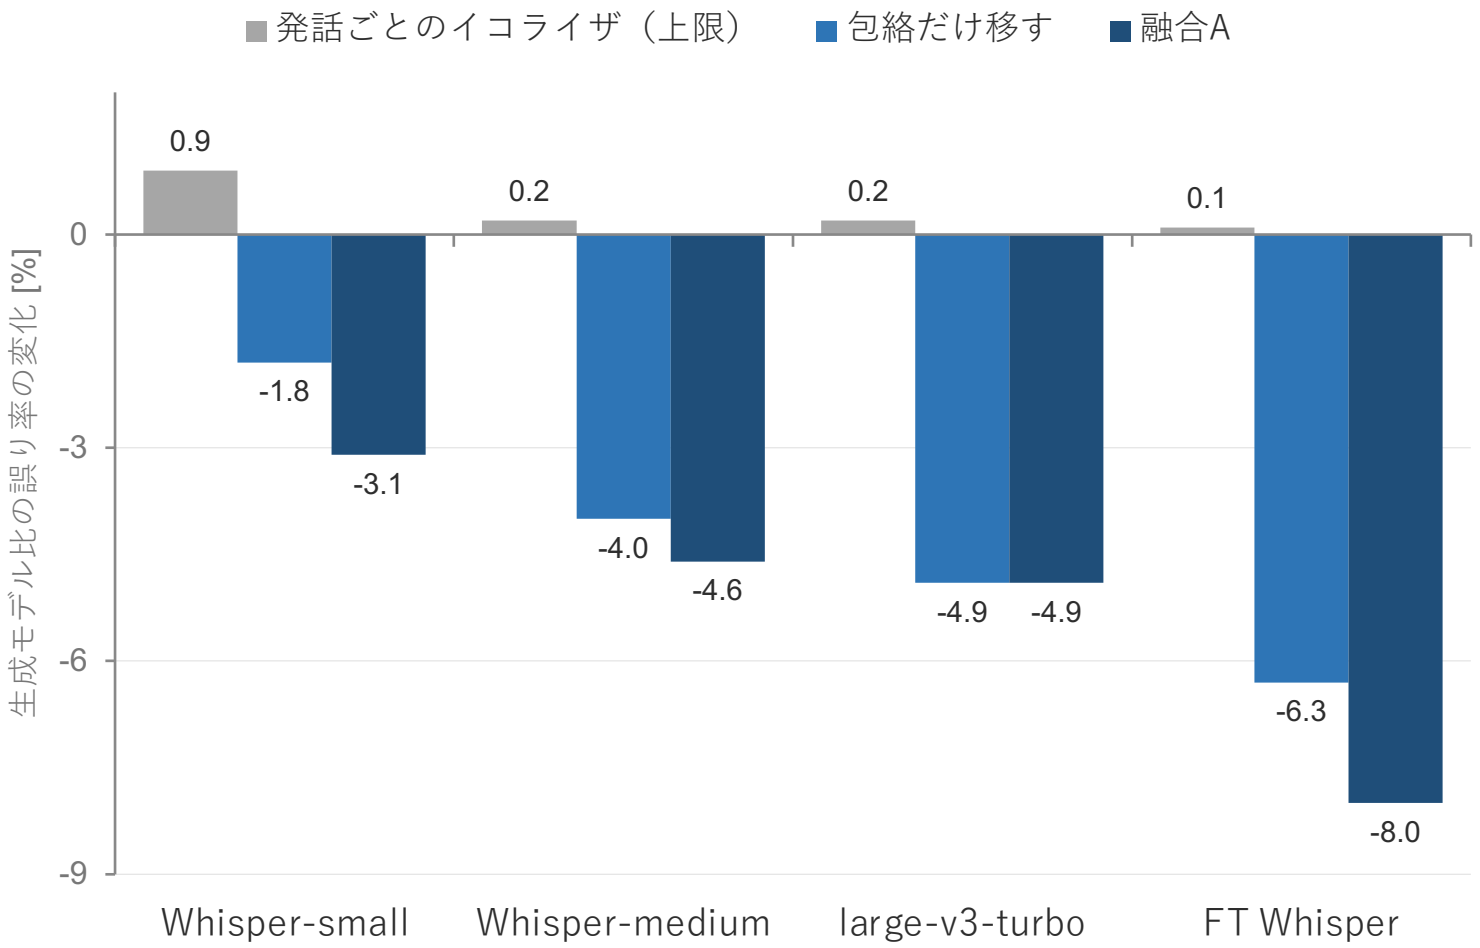
別の喉マイク（VibraVox）でも、適応し直せば改善が再現した

	処理なし	TAPS の部品のまま	適応後 生成モデル	適応後 融合A
Whisper-small	0.422	0.711	0.087	**0.079**
Whisper-large-v3-turbo	0.270	0.654	0.053	**0.045**
Qwen3-ASR	0.242	0.594	0.047	**0.041**
XLSR（仏語）	0.275	0.501	0.063	**0.058**

- そのまま使うと**どれも悪化**
- 適応し直すと**70〜82% 減**
- 1,000対（約1.3時間）で全データの約86%

VibraVox speech_clean test（21話者・3,064発話、学習と話者は重ならない）。少量適応は1試行・10k step

融合の効果は平均的な音色ではなく、時間変化する包絡から来る



- 固定のイコライザは**どれも効かない**（±1.5% 以内）
- 時間変化する包絡を移すと**効果の 58〜100%**が戻る
- 傾き・高域の量・フォルマントの変化は、誤りの減り方と**相関しない**

発話ごとのイコライザ = その発話の融合A の平均スペクトルに合わせる（現実には使えない上限）。dev の固定・区間別のイコライザも同様に効果なし

まとめ: 欠けた成分の補完が土台、Whisper 向けの調整は上乗せ

分かったこと

- 生成モデルの適応は9種すべてに効き、喉マイク用に学習した Whisper にも上乗せできる
- Whisper 用の音声強調を混ぜると Whisper 系にさらに 2〜8%。効くのは時間変化する包絡
- 別の喉マイクでは部品の再適応が必要だが、作り方は再現する

次の予定

- 日本音響学会 2027年春季に4ページで申し込む（申込 11/11〜11/24）
- 融合を一部のフレームだけにかけ、どこで効くかを確かめる（評価中）
- 計算量の削減（生成のステップ数・回数を減らす）

限界: 計算量が大きい（4.3億パラメータを20段×4回）。蒸留して1つの強調器にする試みは融合A に届かなかった