


喉マイクの音声を 「どの音声認識でも読める音」に直す

音声強調から生成モデルへ：ここまでの振り返りと今後


春日 裕次 ゼミ進捗報告 2026年10月1日

喉マイクは騒音に強いが、音が欠けていて認識の誤りが多い



- 喉マイクの音をそのまま Whisper-small にかけると、**文字の誤り率 45%**
- 普通のマイク向けの雑音除去を通すと、**かえって誤りが増えた**（卒論前半）
- 目標：**どの音声認識でも誤りが減る** 喉マイク用の音声強調（クラウドなど作り直せない認識器にも使える）


Whisperに合わせた音声強調は、入力の違う認識器では逆効果だった



文字誤り率の相対的な増減（元の音声強調と比べて）

- Whisperと**同じ入力**（音の特徴の作り方）の認識器では誤りが減る
- 入力が違う認識器（波形をそのまま入れる等）では**誤りが増える**
- 特定の認識器に合わせると、その認識器専用になる

認識器に頼らない音声強調を4つ平均すると、全9つで少し改善



文字誤り率の相対変化（元の音声強調と比べて）

- 4つの音声強調の出力を、振幅で平均しただけ（認識器は使わない）
- **入力が違う認識器も含め、全部で改善** → 認識器に頼らない方向が正しい
- ただし改善は小さく、4つ動かすので重い

4つ = TAPS 公開の SE-Conformer・Demucs・TSTNN と、再構成のみで再学習した SE-Conformer


問題は音の「汚れ」ではなく「欠け」なので、生成モデルに着目

	これまでの音声強調	生成モデル
仕組み	入力の音を直接加工する	「自然な声」を学んでおき、描き直す
欠けた音	平均的な音で埋める → こもる	自然な声として描き足せる
認識器	使わなくてよい	使わなくてよい

- 先行例：仏語の喉マイクでは、生成モデルの調整が最良（ただし評価は認識器1つ）
- → **9つの認識器で、どれでも効くかを確認める**


Hauret et al., arXiv:2508.02974 (VibraVox の喉マイク: 処理なし 50.8% → 生成モデル 7.6%、音素誤り率)

NVIDIAの事前学習済み生成モデルを、喉マイク用に調整した



- ・ 音声認識を学習に一切使わない → 特定の認識器に合わせ込まない
- ・ 欠けた高い音や子音も、事前学習で覚えた「自然な声」から補える

生成モデルの調整で、9つの音声認識すべての誤りが減った



- Whisper系でも、**Whisper**に合わせた音声強調より良い
- **入力が違う認識器**でも改善
- テスト話者**10人全員**で改善

生成は毎回少し変わるが、今はテストデータで1回生成した分のみ（再確認中）。生成モデル: NVIDIA NeMo (Ku et al., arXiv:2409.16117)

最終ゴール：どの認識器でも効く前処理と、その設計原理

最終ゴール（修士）

どの認識器でも誤りが減る喉マイク用の前処理を作る
なぜ効くのかを示す

（認識器の重みは変えない）

達成の基準

- 入力の違う認識器を含め、どれも改善・悪化なし
- 既存の喉マイク用音声強調（TAPS）より明確に良い
- 実際に使える計算量
- 別のデータでも同じ結論

作業仮説（これまでの結果から）

どの認識器にも効く = 自然な声に近い音
特定の認識器だけ = その癖に合わせた音

- Whisper用の学習：人工的な成分 → **他で悪化**
- 4つの平均：癖が打ち消し合う → 全9つで改善
- 生成モデル：自然な声に描き直す → 全9つ改善

生成モデルは候補の一つ。仮説ごとに小さく試して絞り込む

方向	確かめる仮説	最初の小さな実験	続ける条件
A. 分析 最初に回す	自然な声に近いほど、どの認識器でも誤りが減る	→ 既存の全出力で、自然な声との距離と9認識器の誤りの関係を見る	→ 関係が明確なら柱に
B. 事前学習	効いているのは生成でなく、事前学習の知識	→ 事前学習なしの対照・1段で出す版	→ 事前学習ありが大差
C. 生成のさせ方	生成のばらつきが誤りの原因	→ シード違いのばらつきと誤りの関係	→ 両者が連動
D. 損失の設計	自然な声との距離を損失にすれば軽くても効く	→ SSL表現の損失などを9認識器で評価	→ 生成モデルに近づく
E. 軽量化	良い出力を教師にして、軽いモデルへ移せる	→ 未学習のデータで教師を作り、蒸留	→ 効果の大半が残る

- 1週間ごとに「仮説 → 小さな実験 → 9つの認識器で確認 → 続ける／捨てる」を回す

確認はいつも同じ条件: 入力の違う認識器を含む9つ・話者単位の検定・悪化する認識器がないか

参考文献

- TAPS: Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026.
- Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117.
- 山中 涼雅 ほか, “Zero-shot音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” 日本音響学会 2026年秋季, 1-Q-42.
- 和田 航次郎 ほか, “咽喉マイク自由発話音声における感情認識の検討,” 日本音響学会 2026年秋季, 1-Q-56.
- Sato et al., “Generic speech enhancement with self-supervised representation space loss,” arXiv:2507.07631, 2025.
- J. Hauret et al., arXiv:2508.02974, 2025. (喉マイクのリアルタイム変換、生成モデルとの比較を含む)
- J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.

付録：試した6つの方法と結果

方法	考え方	どの認識器でも効いたか
普通のマイク向けの音声強調	既存の雑音除去をそのまま使う	✕ 誤りが増えた（卒論前半）
Whisperに合わせて学習	Whisperが読みやすい音にする	△ Whisper系だけ改善、他は悪化
複数の認識器に合わせて学習	入力の違う認識器にも合わせる	✕ 学習に使っていない認識器で悪化
4つの音声強調の出力を平均	各手法の癖を打ち消す（重い）	○ 全9つで改善（−3〜−14%）
特徴を普通のマイクに近づける	認識器に頼らない（Sato ら型）	○ 調べた4つで改善（−7〜−13%）
生成モデルを調整	音そのものを作り直す	◎ 全9つで −15〜−24%

%は元の音声強調（TAPS SE-Conformer）と比べた文字誤り率の相対変化。Sato ら型は開発データ、その他はテストデータの結果で、条件はまだそろっていない

付録：関連研究

研究	対象	目的	音声認識の誤り
山中ら（東大 2026）	喉マイク（韓国語・日本語）	普通のマイクらしい音に変換	どの方法でも増加
Sato ら（2025）	普通のマイクの雑音	認識器に頼らない音声強調	複数の認識器で減少
本研究	喉マイク（韓国語）	どの認識器でも誤りを減らす	9つすべてで減少 （入力の違う認識器も）

- ・ 山中らの方が進んでいる点：**別の喉マイク・日本語でも検証**、同時録音のデータが不要