


喉マイクの音声を 「どの音声認識でも読める音」に直す

生成モデルの予備実験・課題・今後の方針

春日 裕次 ゼミ進捗報告 2026年10月1日


Whisperに合わせた音声強調は、入力の違う認識器では逆効果だった



文字誤り率の相対的な増減（元の音声強調と比べて）


- Whisperと**同じ入力**（音の特徴の作り方）の認識器では誤りが減る
- 入力が違う認識器（波形をそのまま入れる等）では**誤りが増える**
- 目標：**どの音声認識でも誤りが減る前処理**（クラウドなど作り直せない認識器にも使える）

そこで、音声認識を使わず、生成モデルで音そのものを作り直す



- ・ 音声認識を学習に一切使わない → 特定の認識器に合わせ込まない
- ・ 欠けた高い音や子音も、事前学習で覚えた「自然な声」から補える

生成モデルの調整で、9つの音声認識すべての誤りが減った



- Whisper系でも、**Whisper**に合わせた音声強調より良い
- **入力が違う認識器**でも改善
- テスト話者**10人全員**で改善

生成は毎回少し変わるが、今はテストデータで1回生成した分のみ（再確認中）。生成モデル: NVIDIA NeMo (Ku et al., arXiv:2409.16117)

効果は大きいが、理由・確かさ・他のデータでの効果・新しさが課題

-
- ① **なぜ効いたか** 事前学習のおかげか、単にモデルが大きい（約35倍）からか
-
- ② **結果は確かか** 1回生成しただけ。他の方法との同じ条件での比較もまだ
-
- ③ **他のデータでも効くか** 1つのデータセット（韓国語 TAPS）でしか確かめていない
-
- ④ **自分の工夫はどこか** 公開モデルを調整しただけ（計算も重い）

次は、認識に向けた生成のさせ方を探し、最後に軽くする

段階	ねらい	やること
1. 結果を固める	課題①②	事前学習なしの同じモデルと比較 生成し直し・開発データ・別のデータセット（VibraVox）で再確認
2. 生成のさせ方	本研究の中心	何回か生成して平均する／互いに一番似た候補を選ぶ ランダムな状態ではなく、元の音声強調の出力から生成を始める
3. 軽くする	実用	2 の出力を正解にして、軽い音声強調へ蒸留

・ 2 は今の学習済みモデルのまま試せる（認識器は使わない）

参考文献

- TAPS: Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026.
- Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117.
- 山中 涼雅 ほか, “Zero-shot音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” 日本音響学会 2026年秋季, 1-Q-42.
- 和田 航次郎 ほか, “咽喉マイク自由発話音声における感情認識の検討,” 日本音響学会 2026年秋季, 1-Q-56.
- Sato et al., “Generic speech enhancement with self-supervised representation space loss,” arXiv:2507.07631, 2025.
- J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.

付録：試した6つの方法と結果

方法	考え方	どの認識器でも効いたか
普通のマイク向けの音声強調	既存の雑音除去をそのまま使う	✕ 誤りが増えた（卒論前半）
Whisperに合わせて学習	Whisperが読みやすい音にする	△ Whisper系だけ改善、他は悪化
複数の認識器に合わせて学習	入力の違う認識器にも合わせる	✕ 学習に使っていない認識器で悪化
4つの音声強調の出力を平均	各手法の癖を打ち消す（重い）	○ 全9つで改善（−3〜−14%）
特徴を普通のマイクに近づける	認識器に頼らない（Sato ら型）	○ 調べた4つで改善（−7〜−13%）
生成モデルを調整	音そのものを作り直す	◎ 全9つで −15〜−24%

%は元の音声強調（TAPS SE-Conformer）と比べた文字誤り率の相対変化。Sato ら型は開発データ、その他はテストデータの結果で、条件はまだそろっていない

付録：関連研究

研究	対象	目的	音声認識の誤り
山中ら（東大 2026）	喉マイク（韓国語・日本語）	普通のマイクらしい音に変換	どの方法でも増加
Sato ら（2025）	普通のマイクの雑音	認識器に頼らない音声強調	複数の認識器で減少
本研究	喉マイク（韓国語）	どの認識器でも誤りを減らす	9つすべてで減少 （入力の違う認識器も）

- ・ 山中らの方が進んでいる点：**別の喉マイク・日本語でも検証**、同時録音のデータが不要