


喉マイクの音声を 「どの音声認識でも読める音」に直す

音声強調から生成モデルへ：ここまでの振り返りと今後


春日 裕次 ゼミ進捗報告 2026年10月1日

喉マイクは騒音に強いが、音が欠けていて認識の誤りが多い



- 喉マイクの音をそのまま Whisper-small にかけると、**文字の誤り率 45%**
- 普通のマイク向けの雑音除去を通すと、**かえって誤りが増えた**（卒論前半）
- 目標：**どの音声認識でも誤りが減る** 喉マイク用の音声強調（クラウドなど作り直せない認識器にも使える）


Whisperに合わせた音声強調は、入力の違う認識器では逆効果だった



文字誤り率の相対的な増減（元の音声強調と比べて）

- Whisperと**同じ入力**（音の特徴の作り方）の認識器では誤りが減る
- 入力が違う認識器（波形をそのまま入れる等）では**誤りが増える**
- 特定の認識器に合わせると、その認識器専用になる

認識器に頼らない音声強調を4つ平均すると、全9つで少し改善



文字誤り率の相対変化（元の音声強調と比べて）

- 4つの音声強調の出力を、振幅で平均しただけ（認識器は使わない）
- **入力が違う認識器も含め、全部で改善** → 認識器に頼らない方向が正しい
- ただし改善は小さく、4つ動かすので重い

4つ = TAPS 公開の SE-Conformer・Demucs・TSTNN と、再構成のみで再学習した SE-Conformer


問題は音の「汚れ」ではなく「欠け」なので、生成モデルに着目

	これまでの音声強調	生成モデル
仕組み	入力の音を直接加工する	「自然な声」を学んでおき、描き直す
欠けた音	平均的な音で埋める → こもる	自然な声として描き足せる
認識器	使わなくてよい	使わなくてよい

- 先行例：仏語の喉マイクでは、生成モデルの調整が最良（ただし評価は認識器1つ）
- → **9つの認識器で、どれでも効くかを確認める**


Hauret et al., arXiv:2508.02974 (VibraVox の喉マイク: 処理なし 50.8% → 生成モデル 7.6%、音素誤り率)

NVIDIAの事前学習済み生成モデルを、喉マイク用に調整した



- ・ 音声認識を学習に一切使わない → 特定の認識器に合わせ込まない
- ・ 欠けた高い音や子音も、事前学習で覚えた「自然な声」から補える

生成モデルの調整で、9つの音声認識すべての誤りが減った



- Whisper系でも、**Whisper**に合わせた音声強調より良い
- **入力が違う認識器**でも改善
- テスト話者**10人全員**で改善

生成は毎回少し変わるが、今はテストデータで1回生成した分のみ（再確認中）。生成モデル: NVIDIA NeMo (Ku et al., arXiv:2409.16117)

最終ゴール：どの認識器でも効く前処理と、その設計原理

最終ゴール（修士）

どの認識器でも誤りが減る喉マイク用の前処理を作る
なぜ効くのかを示す

（認識器の重みは変えない）

達成の基準

- 入力の違う認識器を含め、どれも改善・悪化なし
- 既存の喉マイク用音声強調（TAPS）より明確に良い
- 実際に使える計算量
- 別のデータでも同じ結論

作業仮説（これまでの結果から）

どの認識器にも効く = 自然な声に近い音
特定の認識器だけ = その癖に合わせた音

- Whisper用の学習：人工的な成分 → **他で悪化**
- 4つの平均：癖が打ち消し合う → 全9つで改善
- 生成モデル：自然な声に描き直す → 全9つ改善

生成モデルは候補の一つ。仮説ごとに小さく試して絞り込む

方向	確かめる仮説	最初の小さな実験	続ける条件
A. 分析（最初に回す）	自然な声に近いほど、どの認識器でも誤りが減る	既存の全出力で、自然な声との距離と9認識器の誤りの関係を見る	関係が明確なら柱に
B. 事前学習	効いているのは生成でなく、事前学習の知識	事前学習なしの対照／1段で出力する版	事前学習ありが大差
C. 生成のさせ方	生成のばらつきが誤りの原因	シード違いのばらつきと誤りの関係	両者が連動
D. 損失の設計	自然な声との距離を損失にすれば軽くても効く	SSL表現の損失などを9認識器で評価	生成モデルに近づく
E. 軽量化	良い出力を教師にして、軽いモデルへ移せる	未学習のデータで教師を作り、蒸留	効果の大半が残る

- 1週間ごとに「仮説 → 小さな実験 → 9つの認識器で確認 → 続ける／捨てる」を回す

確認はいつも同じ条件: 入力の違う認識器を含む9つ、話者単位の検定、悪化する認識器がないか

参考文献

- TAPS: Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026.
- Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117.
- 山中 涼雅 ほか, “Zero-shot音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” 日本音響学会 2026年秋季, 1-Q-42.
- 和田 航次郎 ほか, “咽喉マイク自由発話音声における感情認識の検討,” 日本音響学会 2026年秋季, 1-Q-56.
- Sato et al., “Generic speech enhancement with self-supervised representation space loss,” arXiv:2507.07631, 2025.
- J. Hauret et al., arXiv:2508.02974, 2025. (喉マイクのリアルタイム変換、生成モデルとの比較を含む)
- J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.

付録：試した6つの方法と結果

方法	考え方	どの認識器でも効いたか
普通のマイク向けの音声強調	既存の雑音除去をそのまま使う	✕ 誤りが増えた（卒論前半）
Whisperに合わせて学習	Whisperが読みやすい音にする	△ Whisper系だけ改善、他は悪化
複数の認識器に合わせて学習	入力の違う認識器にも合わせる	✕ 学習に使っていない認識器で悪化
4つの音声強調の出力を平均	各手法の癖を打ち消す（重い）	○ 全9つで改善（−3〜−14%）
特徴を普通のマイクに近づける	認識器に頼らない（Sato ら型）	○ 調べた4つで改善（−7〜−13%）
生成モデルを調整	音そのものを作り直す	◎ 全9つで −15〜−24%

%は元の音声強調（TAPS SE-Conformer） と比べた文字誤り率の相対変化。Sato ら型は開発データ、その他はテストデータの結果で、条件はまだそろっていない

付録：関連研究

研究	対象	目的	音声認識の誤り
山中ら（東大 2026）	喉マイク（韓国語・日本語）	普通のマイクらしい音に変換	どの方法でも増加
Sato ら（2025）	普通のマイクの雑音	認識器に頼らない音声強調	複数の認識器で減少
本研究	喉マイク（韓国語）	どの認識器でも誤りを減らす	9つすべてで減少 （入力の違う認識器も）

- ・ 山中らの方が進んでいる点：**別の喉マイク・日本語でも検証**、同時録音のデータが不要