


喉マイクの音声を 「どの音声認識でも読める音」に直す

生成モデルの予備実験・関連研究・課題・今後の方針

春日 裕次 ゼミ進捗報告 2026年10月1日

Whisperに合わせた音声強調は、入力の違う認識器では逆効果だった




誤りの増減（元の音声強調と比べて）

- Whisperと同じ**入力**の認識器では誤りが減る
- 入力の作りが違う認識器では**誤りが増える**
- 目標：どの音声認識でも**誤りが減る前処理**（クラウドなど作り直せない認識器にも使える）

卒論の方法：Whisper-small が正しく書き起こせるように音声強調（TAPS SE-Conformer）を追加学習。比べる相手は追加学習前の同じモデル

生成モデルの調整で、9つの音声認識すべての誤りが減った



- 大量の音声で事前学習した「音声を作るAI」を、喉マイクと普通のマイクの**同時録音で調整**
- **音声認識は学習に使っていない**
- テスト話者**10人全員**で改善

テストデータで1回生成した分のみ（開発データ・再生成での確認は実行中）。Zipformer は空白込み。生成モデル: NVIDIA NeMo flow matching (Ku et al., arXiv:2409.16117)

聞こえを良くする研究はあるが、どの認識器でも効くかは未確認

研究	対象	目的	音声認識の誤り
山中ら（東大, 2026）	喉マイク（TAPS・日本語）	普通のマイクらしい音へ	どの方法でも増加
Sato ら（2025）	普通のマイクの雑音	認識器に頼らない音声強調	複数の認識器で減少
本研究	喉マイク（TAPS）	どの音声認識でも誤りを減らす	入力の違う9つすべてで減少

- ・ 山中らの方が進んでいる点：別の喉マイク・日本語でも検証、同時録音のデータが不要

効果は大きいが、理由・確かさ・別のマイクでの効果・新しさが課題

① なぜ効いたか

大量の音声での事前学習のおかげか、モデルが大きい（元の約35倍）だけか

② 結果は確かか

テストデータで1回生成しただけ。先行研究の方法との同条件比較もまだ

③ 別のマイクで効くか

データセット1つ・喉マイク1種類でしか確かめていない

④ 自分の工夫はどこか

公開モデルを調整しただけで、手法としての新しさが無い

まず結果を確かめ、そのうえで手法の工夫に進む

時期	課題	やること
～1週間	①②	事前学習なしで同じモデルを学習して比較／開発データ・生成し直して再確認
～2週間	③	別の喉マイク（仏語の公開データ VibraVox）で検証
その先	④	マイクの情報を手がかりに少ないデータで別のマイクへ対応／生成を複数回行って平均し安定化

まとめと相談したいこと

1. Whisperに合わせた音声強調は、入力の違う認識器で逆効果
2. 生成モデルの調整で、9つの音声認識すべての誤りが15～24%減った
3. 理由・確かさ・別のマイクでの効果・自分の工夫を、これから確かめる

相談したいこと

- 別のマイクでの検証のため、日本語で自分でも録音すべきか
- 手法の新しさをどこに置くのがよいか
- 非商用ライセンスの公開モデルを土台にしてよいか

参考文献

- Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026. (TAPS)
- Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117.
- 山中 涼雅 ほか, “Zero-shot音声変換を用いた咽喉マイク音声の気導音復元に関する初期検討,” 日本音響学会 2026年秋季, 1-Q-42.
- 和田 航次郎 ほか, “咽喉マイク自由発話音声における感情認識の検討,” 日本音響学会 2026年秋季, 1-Q-56.
- Sato et al., “Generic speech enhancement with self-supervised representation space loss,” arXiv:2507.07631, 2025.
- J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.