


ゼミ 進捗報告

喉マイクの音声を 「どの音声認識でも読める音」に直す

生成モデルの予備実験・課題・関連研究・これからの方針

春日 裕次 / 2026年10月1日

Whisperに合わせた音声強調は、作りの違う音声認識で逆効果だった



卒論の方法：Whisperが正しく書き起こせるように音声強調を学習 → 誤りの増減（元の音声強調と比べて）

Whisper-small

Whisperと同じ入力

Qwen3-ASR


Whisperと同じ入力

XLS-R

入力が違う

Zipformer


入力が違う



目標：どの音声認識でも誤りが減る前処理（クラウドなど作り直せない認識器にもそのまま使える）

→ **今回、生成モデルで9つすべての誤りが減った**

生成モデルで、9つの音声認識すべての誤りが減った



何をしたか

大量の音声で事前に学習された「**音声を作るAI**」（生成モデル）を、喉マイクと普通のマイクの同時録音で調整。**音声認識は学習に使っていない**

ほかに試した方法

複数の音声認識に合わせて学習
→ 学習に使っていない認識器で悪化
音声の特徴を普通のマイクに近づける（Sato ら型）
→ 4つの認識器で改善（同じ条件での比較はこれから）

テスト話者10人全員で改善（全認識器）。ただしテストデータで1回生成した分のみ。開発データ・再生成での確認は実行中。Zipformer は空白込みの誤り率

聞こえを良くする研究はあるが、どの音声認識でも効くかは未確認

研究	対象	目的・方法	結果
山中ら 東大・2026秋 音響学会	喉マイク (TAPS+日本語)	普通のマイクらしい音へ (声質変換・帯域拡張)	聞こえは改善、 認識の誤りはどの方法でも増加 ※誤りの測り方は本研究と異なる
Sato ら 2025	普通のマイク (雑音除去)	特定の認識器に頼らない 音声強調	複数の認識器で改善 → 本研究で比較対象として再現
本研究	喉マイク (TAPS)	どの音声認識でも 誤りを減らす	入力の違う9つの認識器すべてで改善

山中らが上の点：別の喉マイク・日本語でも検証／同時録音のデータが要らない → 本研究の課題（次ページ）

その他：和田ら（神戸大・三菱電機、2026秋 音響学会）喉マイクの感情認識でも、汎用の雑音除去を通すと認識が悪化

効果は大きいが、理由・確かさ・広がり・自分の工夫がまだ

① なぜ効いたか

「大量の音声での事前学習」のおかげか、単にモデルが大きい（元の約35倍）からか

② 結果は確かか

テストデータで1回生成しただけ。開発データ・再生成での確認、先行研究の方法との同じ条件での比較がまだ

③ 別のマイクで効くか

データセット1つ・喉マイク1種類でしか確かめていない

④ 自分の工夫はどこか

公開モデルを調整しただけで、手法としての新しさが無い（計算が重いことも課題）

まず結果を確かめ、そのうえで手法の工夫に進む

～1週間 課題①②

- 事前学習なしで同じモデルを学習して比較
- 開発データ・生成し直しで再確認
- 先行研究の方法と同じ条件で比較

～2週間 課題③

- 別の喉マイク：仏語の公開データ (VibraVox)
- 汎用の音声復元ツール (Sidon) とも比較
- 処理時間を測る

その先 課題④

- マイクの情報を手がかりに、少ないデータで別のマイクへ対応
- 生成を複数回行って平均し、誤りを安定して減らす

相談したいこと

1. 別のマイクでの検証のために、日本語で自分でも録音すべきか
2. 手法の新しさをどこに置くのがよいか
3. 非商用ライセンスの公開モデルを土台にしてよいか