

喉マイクの音声を Whisper 系の音声認識向けに直す

生成モデルと Whisper 用の音声強調を混ぜる方法と、その分析

春日 裕次 ゼミ進捗報告 2026年10月8日

前回から、目標を「Whisper 系の誤りを下げる音声強調」に絞った

前回まで


どの認識器でも誤りが減る音声強調
(入力の違う認識器も含めて 9つ)

今回から

→ Whisper 系の認識器の誤りを下げる音声強調
(Whisper と同じ音の特徴を入力にする認識器)


-
- 学習と設定選びに使うのは **Whisper-small だけ**
 - ほかの Whisper 系 5つ (base・medium・large-v3-turbo・喉マイクで再学習した Whisper・Qwen3-ASR) は**評価専用**
 - 入力の違う認識器 (XLS-R・Zipformer) は、**Whisper 系専用になっているか**を見る対照

方法：生成モデルの4回平均に、Whisper 用の音声強調を半分混ぜる



- 混ぜる割合 0.5 は、開発データで Whisper-small だけを見て選んだ（0.25～0.75 で結果はほぼ同じ）
- 新たな学習は不要。部品はどちらも学習済み

Whisper 系6つすべてで、生成モデル単体よりさらに誤りが減った



- 元の音声強調より**26～37% 減**
- 生成モデル単体より**さらに減少**
- Zipformer では**12% 増**→ Whisper 系専用の上乗せ

数値は文字誤り率 (%)。生成モデル単体との差: medium・turbo・再学習 Whisper は 10/10 話者 (p=0.002)、small 9/10、base・Qwen3 は有意差なし

既存の方法と同じ条件で比べても、混ぜたものが最も良い

	元の音声強調	Whisper 用 音声強調	自己教師あり 表現の損失	生成モデル (4回平均)	混ぜたもの
Whisper-small	23.0	19.6	20.3	16.9	16.3
Whisper-base	27.3	26.7	24.1	20.5	20.1
Whisper-medium	19.6	16.9	17.7	15.0	14.4
large-v3-turbo	17.0	14.1	15.3	13.1	12.5
Whisper（再学習）	14.6	12.1	12.4	10.0	9.2
Qwen3-ASR	13.6	11.4	11.4	9.7	9.4

- Whisper の損失で mel を直す方法（Dissen ら型）は元の音声強調と同程度

生成モデル自体を Whisper の損失で学習する方法は全滅した

試したこと	結果
生成の途中の見積もりに Whisper の損失をかけて追加学習	Whisper-small 18.0% → 19.3% (悪化)
生成の最後の段にだけ損失をかける (DRaFT)	開発データの損失が悪化、打ち切り
生成の出力に小さな補正モジュールを足す	効果なし
Whisper 用音声強調を「混ぜた後の音」で学習し直す	Whisper 系で 0.2~1.9% だけ改善

- Whisper に合わせる成分は、**生成モデルの外で足す（混ぜる）方が素直に効く**

途中の見積もり = 生成の途中から1段で出した仮の完成音。この見積もりの損失は下がるが、20段で生成した音には持ち越されない

上乗せは両方の帯域から、他の認識器の悪化は高域から来る

	生成モデル (4回平均)	混ぜたもの	櫛状の成分を 除いて混ぜる	4 kHz 未満 だけ混ぜる	4 kHz 以上 だけ混ぜる
Whisper-small	16.9	16.3	16.3	16.6	16.7
Whisper-medium	15.0	14.4	14.4	14.5	14.8
Whisper (再学習)	10.0	9.2	9.3	9.4	9.9
Zipformer (対照)	43.3	48.3	49.1	43.1	47.9

- Whisper 用音声強調が作る**櫛状の成分は原因ではない**（除いても同じ）
- Whisper 系の上乗せは**低域・高域のどちらか一方だと約半分**
- Zipformer の悪化は、**元々無い 4 kHz 以上を Whisper 向けに作った成分**が原因

文字誤り率（%）。櫛状の成分 = Whisper 用音声強調の出力に現れる 250 Hz 間隔のピーク。喉マイクは 8 kHz 収録のため 4 kHz 以上は元々無い

今の形は「既存の部品を混ぜただけ」で、提案手法としては弱い

言えること

- Whisper 系6つで既存の方法より明確に良い
- 事前学習が効果の源（事前学習なしでは悪化）
- Whisper 用の成分の効く帯域・害になる帯域

弱い点

- 新しい部品がない
- 重い（大きな生成モデルを 4回）
- データは TAPS（韓国語・1機種）だけ

→ 音響学会は「分析」として出し、手法は別に作る

次は、提案手法になる形を3つの方向で小さく試す

方向	最初の小さな実験	確かめること
1. 軽くする	混ぜた出力を教師にして、軽い音声強調1つに移す	効果が軽いモデルに残るか
2. 別のデータ	フランス語の喉マイク（VibraVox）で試す	TAPS 以外でも同じ結論か
3. 他分野の発想	敵対的サンプルの「転移」の技法で Whisper 用音声強調を学習し直す	学習に使わない Whisper にも効くか

確認はいつも同じ：Whisper 系6つ・入力の違う認識器・話者単位の検定

参考文献

- TAPS: Y. Kim et al., “Throat and acoustic paired speech dataset for deep learning-based speech enhancement,” Scientific Data, 2026.
- Ku et al., “Generative speech foundation model pretraining for high-quality speech extraction and restoration,” arXiv:2409.16117.
- Sato et al., “Generic speech enhancement with self-supervised representation space loss,” arXiv:2507.07631, 2025.
- Dissen et al., Interspeech 2024. (凍結した Whisper の損失で前処理を学習)
- Ochiai et al., “Rethinking processing distortions: How do they affect the downstream ASR performance?” IEEE/ACM TASLP, 2024.
- J. Hauret et al., “Vibravox: A dataset of French speech captured with body-conduction audio sensors,” Speech Communication, 2025.