

喉マイク音声認識のための ASR 損失に基づく音声強調の最適化

春日 裕次 (明治大学 総合数理学部 先端メディアサイエンス学科)

1. はじめに

喉マイク (咽喉マイク) は、頸部表面の振動を接触型加速度センサで検出するマイクロフォンである。通常の気導マイクが空気中の音波を收音するのに対し、喉マイクは体内を伝播する振動を直接検出するため、周囲の環境騒音の影響を受けにくいという大きな利点がある。この特性から、高騒音環境下での通信 (軍事・産業) や、発話障害者の音声補助など、多様な応用が期待されている。

しかし、頸部の軟組織を介した信号伝播は物理的なローパスフィルタとして機能し、3~4 kHz 以上の高域成分が大幅に減衰する。この帯域制限により、喉マイク音声は気導マイク音声と比較して音声品質が低下し、自動音声認識 (Automatic Speech Recognition; ASR) の精度が著しく劣化する。例えば、TAPS データセット [4]において Whisper-small で韓国語喉マイク音声を認識した場合の CER (Character Error Rate) は 0.47 であり、気導マイク音声と比較して大幅に高い。

この課題に対し、音声強調 (Speech Enhancement; SE) を前処理として適用する手法が研究されてきた。しかし近年、Ochiai ら [1]は気導マイクの文脈において、SE が ASR 精度を改善するどころか悪化させる場合があることを報告した。彼らは既存の直交射影に基づく分解 (Orthogonal Projection-based Decomposition; OPD) を用いた DSA (Distortion Source Analysis) により、SE の推定信号を target 成分・interference error・noise error・artifact error に分解し、artifact error が逆効果の主因であることを特定した。Mawalim ら [2]も、STOI (Short-Time Objective Intelligibility) や PESQ (Perceptual Evaluation of Speech Quality) が改善しているにもかかわらず ASR 精度が悪化する現象を報告している。

この「知覚品質の改善が ASR 精度の改善を保証しない」という問題の一因は、従来の SE が波形品質の復元 (L1 損失や STFT 損失) を最適化目標としており、ASR 精度の最適化が間接的にしか行われない点にある。Close ら [3]は自己教師あり音声表現の特徴距離を SE 損失に利用する Perceive &

Predict を提案し、知覚品質指標との相関を示したが、実際の ASR 性能 (CER) への効果は評価されていない。

本研究では、この問題に対して **Whisper の交差エントロピー (Cross-Entropy; CE) 損失を SE の学習損失に直接組み込む** ASR-aware SE を提案する。提案手法は、SE モデルの出力を Whisper に入力し、その書き起こし誤りを最小化するように SE を学習させる。韓国語喉マイクデータセット TAPS [4]を用いた実験により、以下の知見を得た。

- (1) 提案手法はベースライン SE の CER を 20.7% 改善した (0.252→0.200)。
- (2) 学習に使用していない Whisper 系列の別サイズモデルでも改善が転移した。
- (3) 知覚品質と ASR 精度は異なる最適化目標であることが確認された。

2. ベースラインと提案手法

2.1 ベースライン : TAPS SE-Conformer

ベースラインとして、TAPS 論文 [4]で提供された SE-Conformer (12.1M パラメータ) の事前学習済みモデルを追加学習なしでそのまま使用する。このモデルは L1 波形損失と多解像度 STFT 損失の和 (以下、再構成損失) により 200 エポック学習されたものである。

2.2 提案手法 : ASR 損失による追加学習

提案手法では、上記ベースラインの重みを初期化点とし、再構成損失に ASR 損失を加えた損失関数で追加学習 (fine-tuning) を行う。再構成損失は TAPS 論文と同じ構成・時間周波数設定の L1+多解像度 STFT 損失であり、波形品質を維持する正則化として機能する。

$$L_{\text{recon}} = L1(\hat{s}, s_{\text{air}}) + \text{STFT}(\hat{s}, s_{\text{air}})$$

ここで $\hat{s}$ は SE 出力、 s_{air} は気導マイク音声 (参照信号) である。ASR 損失として以下の 2 種を比較する。

(a) Encoder 距離損失

SE 出力と気導音声の Whisper encoder 出力間の L1 距離を損失に加える。

$$L_{\text{enc}} = L_{\text{recon}} + \lambda \times L1(\text{Enc}(\hat{s}), \text{Enc}(s_{\text{air}}))$$

Whisper encoder は凍結し、勾配は encoder 出力の L1 距離からメルスペクトログラム変換を経由して SE モデルに逆伝播する。Close ら[3]の Perceive & Predict も同様に encoder 表現の距離を SE 損失に利用するが、ASR 精度 (CER) への効果は評価されていない。

(b) CE 損失 (提案手法)

Whisper 全体 (encoder+decoder) の交差エントロピー損失を使用する。

$$L_{CE} = L_{recon} + \lambda \times CE(\text{Whisper}(\hat{y}), y)$$

ここで y は正解テキスト、CE は Whisper decoder 出力と正解テキスト間の交差エントロピーである。Whisper の全パラメータは凍結し、勾配は CE 損失から decoder、encoder、メルスペクトログラム変換を経由して SE モデルに逆伝播する。

encoder 距離損失が中間表現の類似度という間接的な目標を最適化するのに対し、CE 損失は正解テキストに対する token 単位の交差エントロピーを最小化する点が本質的に異なる。

3. 実験条件

3.1 データセット

韓国語喉マイクデータセット TAPS (Throat and Acoustic Paired Speech Dataset) [4]を使用した。TAPS は喉マイクと気導マイクのペア同時収録データセットであり、60 話者・6,000 発話から構成される。話者独立な分割設計 (train: 40 話者・4,000 発話、dev: 10 話者・1,000 発話、test: 10 話者・1,000 発話) が採用されている。喉マイクは 8 kHz で収録され 16 kHz にアップサンプリングされている。

3.2 SE モデルと学習設定

TAPS 論文で提供された SE-Conformer (12.1M パラメータ) の事前学習済み重みから初期化し追加学習を行った。15 秒を超える発話は音声とテキストの対応を維持するため除外した (train: 78 件除外、dev: 9 件除外)。最適化には Adam

($\text{lr}=3 \times 10^{-4}$, $\beta=(0.9, 0.99)$) を使用し、batch size=4、最大 50 エポック、early stopping (patience=5) で学習した。CE 損失の Whisper forward 部分には AMP (混合精度演算) を適用した。

3.3 評価設定

ASR 評価には faster-whisper (CTranslate2 形式) を使用し、言語=韓国語、beam size=5 で CER を計測した。CER は発話ごとに jiwer.cer で計算し 1.0 でキャップした後、全発話の算術平均をとった (発話平均 capped CER)。汎用性検証として Whisper-base (74M) ・small (244M) ・medium (769M) の 3 モデルで評価した。知覚品質は pySTOI による STOI と ITU-T P. 862 に基づく PESQ (広帯域モード) で計測し、同一発話の気導マイク音声を参照信号とした。

4. 実験結果

4.1 CE 損失の λ 探索

表 1 に CE 損失の重み λ と CER の関係を示す。 λ の選択は dev CER に基づいて行い、test セットは最終評価のみに使用した。 $\lambda = 10.0$ が dev 上で最良であり、対応する test CER は 0.200 で、TAPS pretrained ベースラインと比較して 20.7%の改善となった。Wilcoxon 符号順位検定の結果、 $p = 3.38 \times 10^{-93}$ であり統計的に極めて有意な差が確認された。話者内の依存を考慮し話者平均を単位とした検定 ($n = 10$) でも $p = 0.002$ であり有意な差が確認された。

λ	dev CER	test CER	Δ vs TAPS
TAPS pretrained	0.285	0.252	—
$\lambda=0$ (再構成のみ)	0.286	0.257	+2.1%
CE $\lambda=1.0$	0.262	0.228	-9.5%
CE $\lambda=2.0$	0.246	0.216	-14.4%
CE $\lambda=5.0$	0.235	0.202	-19.8%
CE $\lambda=10.0$ (best)	0.232	0.200	-20.7%

表 1: CE 損失の λ 値と CER (λ は dev CER で選択)

また、再構成損失 (L1+STFT) の効果を検証する ablation 実験を行った。CE 損失のみ (再構成損失なし、 $\lambda = 10.0$) で学習した場合の test CER は 0.205 であり、TAPS pretrained (0.252) を上回るものの、再構成損失を加えた場合 (0.200) と比較すると CER が高い。再構成損失の追加が CER の低下に寄与していることが観測された。逆に、CE 損失を用いず再構成損失のみで同一条件の追加学習 ($\lambda = 0$) を行った場合の test CER は 0.257 であり、TAPS pretrained (0.252) から改善しなかった。したがって、CER の低下は追加学習そのものではなく CE 損失の導入によるものと考えられる。

4.2 別 ASR モデルでの評価

表 2 に、Whisper-small で学習した CE-aware SE を異なるサイズの Whisper モデルで評価した結果を示す。提案手法 (CE $\lambda = 10.0$) は全 3 モデルで TAPS pretrained より CER が低下した。Whisper-small では相対 20.7%、medium では 13.9% の低下が観測された。Whisper-base では 2.2% の低下にとどまった。一方、encoder 距離損失 (Enc L1 $\lambda = 5.0$) は TAPS pretrained とほぼ同等の CER にとどまった。

SE 条件	W-base	W-small	W-medium
No SE	0.671	0.470	0.360
TAPS pretrained	0.294	0.252	0.219
Enc L1 ($\lambda = 5.0$)	0.298	0.251	0.218
CE ($\lambda = 10.0$)	0.287	0.200	0.189

表 2: Whisper 系列の異なるサイズでの CER 比較

4.3 Encoder 距離分析

CE 損失の改善メカニズムを分析するため、各 SE 条件について 3 つの Whisper モデルの encoder 表現間 L1 距離を計測した (表 3)。SE 出力と気導音声を各 encoder に入力し、出力表現の L1 距離を計算した。

SE 条件	base L1	small L1	medium L1
No SE	0.367	0.386	0.408
TAPS pretrained	0.157	0.200	0.226
Enc L1 ($\lambda = 5.0$)	0.157	0.192	0.224
CE ($\lambda = 10.0$)	0.236	0.326	0.346

表 3: 各 Whisper モデルの encoder 表現間 L1 距離

注目すべきは、CE 損失 (CER 最良) が TAPS pretrained よりも encoder 距離が**大幅に大きい**点である (small: 0.200→0.326)。CE 損失で学習した SE の出力は気導音声に encoder 空間で近づいておらず、むしろ離れている。それにも関わらず CER は大幅に改善している (表 2)。これは、encoder 表現を気導音声に近づけることが ASR 精度向上の必要条件ではないことを示す。

一方、Enc L1 は Whisper-small の encoder 距離を縮小 (0.200→0.192) しているが、CER の低下は限定的である (0.252→0.251)。CE は距離が増加しつつ CER が大幅低下しており、条件間で encoder 距離の順位と CER の順位が一致しない。以上の結果は、気導参照への encoder L1 距離の低

下だけでは CER 改善を説明できないことを示唆する。CE 損失は気導音声に似た表現を生成するのではなく、ASR の書き起こし誤りを減少させる別の表現を生成している可能性がある。

4.4 知覚品質評価

表 4 に STOI・PESQ・CER の比較を示す。TAPS pretrained は STOI 0.892・PESQ 1.975 と最も高い STOI・PESQ 値を達成するが、CER は 0.252 にとどまる。一方、提案手法 (CE $\lambda = 10.0$) は STOI 0.792・PESQ 1.215 と STOI・PESQ が低下するにも関わらず、CER は 0.200 と最良である。

条件	STOI	PESQ	CER
No SE	0.697	1.224	0.471
TAPS pretrained	0.892	1.975	0.252
Enc L1 ($\lambda = 5.0$)	0.878	1.775	0.251
CE ($\lambda = 10.0$)	0.792	1.215	0.200

表 4: STOI・PESQ・CER の比較

この結果は、従来報告されてきた現象 - SE により STOI・PESQ が改善するにも関わらず CER が悪化する [1][2] - の逆パターンを示している。すなわち、STOI・PESQ が低下するにも関わらず CER が改善する現象が観測された。STOI・PESQ の最適化と CER の最適化は双方向に乖離しうること示しており、「気導音声への復元」を目標とする従来 SE の前提が、ASR 応用には最適でない可能性を示唆する。

4.5 スペクトル分析

CE 損失が SE 出力をどのように変化させたかを調べるため、test 100 発話 (10 話者×10 発話) の平均パワースペクトルを求め、移動中央値で包絡成分を除去した残差を比較した (図 1)。TAPS pretrained と気導音声の残差には規則的な構造が見られないのに対し、CE ($\lambda = 10.0$) の出力には 3.0-7.75 kHz の 250 Hz 間隔の位置に 10-20 dB の鋭いピークが並ぶ楕状の成分が現れた。




図 1: 包絡除去後の平均スペクトル (灰線: 250 Hz 間隔)

表 5 に、4-8 kHz における 250 Hz 格子上の残差の平均 (ピーク高さ) を示す。ピーク高さは λ と

もに単調に増加し、再構成損失を除いた CE only で最大となった。 $\lambda = 0$ では TAPS pretrained と同程度であることから、この成分は CE 損失によって生じたものである。250 Hz は本 SE-Conformer の最深層の時間解像度（4 倍アップサンプル後に stride 4 の層を 4 段通過：64 kHz / 4⁴）と一致しており、転置畳み込みによるアップサンプリング由来の成分である可能性があるが、原因の特定は今後の課題である。

条件	ピーク高さ	対照
気導音声	0.2 dB	0.1 dB
TAPS pretrained	2.6 dB	0.3 dB
$\lambda=0$ （再構成のみ）	2.8 dB	0.0 dB
CE $\lambda=1.0$	6.7 dB	1.0 dB
CE $\lambda=5.0$	10.1 dB	0.3 dB
CE $\lambda=10.0$	12.5 dB	0.5 dB
CE only $\lambda=10.0$	15.4 dB	1.8 dB

表 5: 250 Hz 格子上の残差（4-8 kHz、対照は格子の中間位置）

5. 考察とまとめ

本研究では、Whisper の交差エントロピー損失を SE 学習に直接組み込む ASR-aware SE を提案し、韓国語喉マイクデータセット TAPS で評価した。主要な知見を以下にまとめる。

第一に、提案手法（CE $\lambda = 10.0$ ）は TAPS pretrained ベースラインと比較して CER を 20.7% 低下させた（0.252→0.200、 $p = 3.38 \times 10^{-93}$ ）。話者平均を単位とした検定でも有意であった（ $p = 0.002$ ）。第二に、この改善は学習に使用した Whisper-small 以外のサイズ（base・medium）にも CER の低下として観測された。第三に、encoder 距離分析（表 3）により、気導参照への encoder L1 距離の低下だけでは CER 改善を説明できないことが示唆された。CE 損失で学習した SE は encoder 空間において気導音声からむしろ離れるが、CER は低下している。第四に、スペクトル分析により、CE 損失は気導音声には存在しない 250 Hz 間隔の櫛状成分を SE 出力に生じさせることが明らかになった（図 1、表 5）。

一方、提案手法の CER 0.200 は Whisper ファインチューニング（CER 0.136）には及ばない。しかし、SE は波形前処理として異なる ASR に接続できる利点があり、今回評価した 3 サイズには同一 SE を再学習なしで適用できた。本研究は Whisper 系列内での評価に限られており、異なる ASR アーキテクチャや他言語への汎化は今後の検証課題であ

る。

参考文献

[1] T. Ochiai, et al., “Rethinking Processing Distortions: Disentangling the Impact of Speech Enhancement Errors on Speech Recognition Performance,” IEEE/ACM Trans. Audio, Speech, and Language Processing, vol. 32, 2024.

[2] C.O. Mawalim, S. Okada, and M. Unoki, “Are Recent Deep Learning-Based Speech Enhancement Methods Ready to Confront Real-World Noisy Environments?” Proc. Interspeech, DOI: 10.21437/Interspeech.2024-129, 2024.

[3] G. Close, W. Ravenscroft, T. Hain, and S. Goetze, “Perceive and Predict: Self-Supervised Speech Representation Based Loss Functions for Speech Enhancement,” Proc. ICASSP, 2023.

[4] Y. Kim, et al., “Throat and Acoustic Paired Speech Dataset for Deep Learning-Based Speech Enhancement,” Scientific Data (Nature), DOI: 10.1038/s41597-026-07268-2, 2026.