

ASR 損失で学習した喉マイク音声強調の効果と汎化範囲

春日 裕次（明治大学 総合数理学部 先端メディアサイエンス学科）

1. はじめに

喉マイクは頸部表面の振動を接触型センサで検出するため、周囲の環境騒音の影響を受けにくい。一方、頸部の軟組織を介した伝播は物理的なローパスフィルタとして働き、高域成分が大きく失われる。韓国語喉マイクデータセット TAPS[4]では喉マイクが 8 kHz で収録されており、4 kHz 以上は収録時点から存在しない。このため Whisper-small[11]で喉マイク音声进行認識した場合の文字誤り率（CER）は 0.47 と高い。

前処理としての音声強調（SE）は有力な対策であるが、知覚品質（STOI・PESQ）の改善が ASR 精度の改善を保証しないことが知られている[1][2]。この乖離に対し、ASR の損失を直接用いて SE を学習する研究が行われてきた。Bagchi ら[5]は凍結した音響モデルの出力を模倣する損失で SE を学習し、Dissen ら[6]は凍結した Whisper の損失で前段ネットワークを学習した。

しかし、SE を前処理として用いる最大の利点は、後段の ASR を選ばずに接続できる点にある。特定の ASR の損失で学習した SE の改善が、学習に使用していない ASR、特に異なる系列の ASR にも持ち越されるかは十分に検証されていない。

本研究では、凍結した Whisper の交差エントロピー（CE）損失で SE を追加学習し、その効果と汎化範囲を TAPS で検証する。本研究の貢献は以下の 3 点である。

- (1) 学習に用いた Whisper-small では、句読点を正規化した評価でも CER が改善することを示す（【64 待ち】）。
- (2) その改善は Whisper 系列内には持ち越されるが、CTC 系の認識器（MMS、XLS-R）ではむしろ悪化することを示す。
- (3) 正規化しない評価では改善の一部が句読点出力の抑制によるものであることを示し、ASR 損失で学習した SE の評価における注意点を明らかにする。

2. 手法

ベースラインは TAPS 論文[4]の SE-Conformer（12.1M パラメータ）の事前学習済みモデル（以

下 TAPS SE）である。このモデルは L1 波形損失と多解像度 STFT 損失の和（再構成損失 L_{recon} ）で学習されている。提案手法では、TAPS SE の重みを初期値とし、次の損失で追加学習する。

$$L_{\text{CE}} = L_{\text{recon}}(\hat{s}, s_{\text{air}}) + \lambda \times \text{CE}(\text{Whisper}(\hat{s}), y)$$

ここで $\hat{s}$ は SE 出力、 s_{air} は同時収録の気導マイク音声、 y は正解テキストである。Whisper-small の全パラメータは凍結し、勾配は decoder・encoder・対数メルスペクトログラム変換を経由して SE に逆伝播する。

比較手法として、SE 出力と気導音声の Whisper encoder 出力間の L1 距離を λ 倍して加える手法（Enc L1、Close ら[3]と同系統）も学習した。また、 $\lambda = 0$ （再構成損失のみで同一条件の追加学習）を対照とした。

3. 実験条件

3.1 データと学習

TAPS[4]（60 話者・6,000 発話）の話者独立な分割（train 40 話者・dev 10 話者・test 10 話者、各 100 発話/話者）を用いた。学習では、音声とテキストの対応を保つため 15 秒を超える発話を除外した（train 78 件、dev 9 件）。評価は全 test 1,000 発話で行った。最適化は Adam（lr = 3×10^{-4} ）、batch size 4、最大 50 エポック、early stopping の基準は dev の学習損失とした。 λ は {0, 0.1, 0.5, 1, 2, 5, 10} を探索し、dev の CER（3.2 節の正規化後）で選択した。各条件の学習は 1 回である。

3.2 評価

テキスト正規化。TAPS の正解テキストは句読点を含まない。一方 Whisper は文末に句点などを出力するため、未正規化の CER には句読点の有無が混入する。そこで正解と認識結果の双方から Unicode の句読点を除去し、連続する空白を 1 つにまとめてから CER を計算した（以下 CER）。参考として未正規化の値（raw）も示す。CER は発話ごとに計算して 1.0 で打ち切り、発話平均をとった。

認識器。学習に用いた Whisper-small に加え、Whisper 系列内の汎化として Whisper-base・

medium、および喉マイク音声でファインチューニングした Whisper-small (FT Whisper) を用いた。系列外の汎化として、CTC 型の MMS-1B[9] (韓国語アダプタ) と XLS-R[10]を韓国語で追加学習したモデル (kresnik/wav2vec2-large-xlsr-korean) を用いた。Whisper 系列は faster-whisper (beam size 5)、CTC 系は greedy 復号で認識した。

統計. 同一話者の発話は独立でないため、話者ごとの平均 CER を単位とした Wilcoxon 符号順位検定 ($n = 10$) を用い、改善した話者数を併記した。

4. 実験結果

4.1 学習に用いた認識器での効果

表 1 に λ ごとの CER を示す。【64 待ち : dev で選ばれた λ 、test CER、TAPS 比、話者単位 p 値・改善話者数】 未正規化の CER では改善幅が大きく見えるが、文末に句読点が付く発話の割合は TAPS SE の【64 待ち : 約 91%】に対し提案手法では【64 待ち : 0%】であった。提案手法は Whisper が句読点を出力しないように SE 出力を変化させており、未正規化の改善幅のうち【64 待ち : 約 4 割】はこの効果による。

条件	dev	test	test (raw)	句点率
TAPS SE	-	-	-	-
$\lambda=0$ (再構成のみ)	-	-	-	-
CE $\lambda=1$	-	-	-	-
CE $\lambda=2$	-	-	-	-
CE $\lambda=5$	-	-	-	-
CE $\lambda=10$	-	-	-	-
CE only $\lambda=10$	-	-	-	-

表 1: λ ごとの CER (Whisper-small、正規化後。raw は未正規化) 【64 待ち】

4.2 他の認識器への汎化

表 2 に、SE 条件と認識器の組み合わせごとの CER を示す。【64・62 待ち】 Whisper 系列内では提案手法が TAPS SE より CER を下げる一方、CTC 系の MMS-1B と XLS-R では提案手法が TAPS SE より CER を上げた。 $\lambda = 0$ では CTC 系でも TAPS SE と同程度であることから、この悪化は CE 損失によるものである。Enc L1 はいずれの認識器でも TAPS SE とほぼ同等であった。【FT Whisper の列の解釈を追記】

SE	W-b	W-s*	W-m	FT	MMS	XLS-R
No SE	-	-	-	-	-	-

TAPS SE	-	-	-	-	-	-
Enc L1	-	-	-	-	-	-
$\lambda=0$	-	-	-	-	-	-
CE (提案)	-	-	-	-	-	-

表 2: 認識器ごとの CER (正規化後、*は学習に使用) 【64・62 待ち】

4.3 提案手法は何を変えたか

CE 損失が SE 出力をどう変えたかを調べるため、test 100 発話 (10 話者×10 発話) の平均パワースペクトルを求め、移動中央値で包絡を除いた残差を比較した (図 1)。提案手法の出力には、3.0-7.75 kHz の 250 Hz 間隔の位置に 10-20 dB の鋭いピークが並ぶ櫛状の成分が現れた。4-8 kHz における 250 Hz 格子上的残差の平均は、TAPS SE の 2.6 dB、 $\lambda = 0$ の 2.8 dB に対し、 $\lambda = 1、5、10$ でそれぞれ 6.7、10.1、12.5 dB、再構成損失を除いた CE only で 15.4 dB と λ とともに単調に増加した。250 Hz は本 SE-Conformer の最深層の時間解像度 (64 kHz / 4⁴) と一致しており、転置畳み込みに由来する可能性がある。




図 1: 包絡除去後の平均スペクトル (灰線: 250 Hz 間隔)

この櫛状成分が CER の改善を担っているかを調べるため、提案手法の出力の 250 Hz 格子位置にノッチフィルタを適用したところ、CER はほとんど変化しなかった (表 3)。また、4 kHz を境に低域と高域を TAPS SE と提案手法で入れ替えると、提案手法の低域と TAPS SE の高域の組み合わせで提案手法とほぼ同じ CER が得られた。したがって改善は主に 4 kHz 以下の変化によるもので、櫛状成分は副産物と考えられる。【62 待ち : 1000 発話の値で確認】

条件	CER
TAPS SE	-
提案手法	-
提案手法+櫛ノッチ	-
提案低域+TAPS 高域	-
TAPS 低域+提案高域	-

表 3: 帯域入れ替え・ノッチの効果 (Whisper-small、正規化後) 【62 待ち】

なお提案手法は TAPS SE に比べ STOI (0.892→0.792)・PESQ (1.975→1.215) がともに低く、気導音声との Whisper encoder 出力の距

離も大きい (0.200→0.326)。提案手法は気導音声に近づくのではなく、Whisper にとって認識しやすい別の信号を作っている。Iwamoto ら[7]は気導マイク音声において ASR の学習が SE の artifact error を減らすことを報告しているが、本研究では CE 損失によって気導音声に存在しない成分が増えた。

5. 考察

以上の結果は、CE 損失で学習した SE が、学習に用いた認識器に向けて入力を調整する「波形領域のアダプタ」として働くことを示唆する。その効果は Whisper 系列内には持ち越されるが、系列外の認識器では失われ、むしろ悪化する。一方、気導音声の表現に近づける Enc L1 は認識器を選ばない代わりに改善も小さい。ASR 損失による SE の学習には、対象の認識器への特化と汎用性のトレードオフが存在する。自己教師あり表現空間の距離を損失として学習した SE が複数の下流タスクで有効であるという報告[8]と合わせると、汎化の範囲は損失の種類に依存すると考えられる。

また、未正規化の CER では句読点出力の抑制が改善として計上された。ASR 損失で学習した SE の評価では、テキストの正規化と、学習に用いていない系列の認識器による評価が必要である。

本研究の限界として、各条件の学習が1回であること、 λ の探索範囲が10までであること、韓国語のみの評価であることが挙げられる。

6. まとめ

凍結した Whisper の CE 損失で喉マイク用 SE を学習し、その効果と汎化範囲を検証した。学習に用いた Whisper では正規化後も CER が改善したが、改善は Whisper 系列内に限られ、CTC 系の認識器では悪化した。今後は複数系列の認識器の損失を組み合わせ、学習に用いていない認識器で評価する枠組みにより、認識器に依存しない ASR 指向の SE を検討する。

参考文献

[1] T. Ochiai, et al., “Rethinking Processing Distortions: Disentangling the Impact of Speech Enhancement Errors on Speech Recognition Performance,” IEEE/ACM TASLP, vol. 32, 2024.
[2] C.O. Mawalim, S. Okada, and M. Unoki, “Are Recent Deep Learning-Based Speech Enhancement Methods Ready to Confront Real-World Noisy Environments?”

Proc. Interspeech, 2024.

[3] G. Close, W. Ravenscroft, T. Hain, and S. Goetze, “Perceive and Predict: Self-Supervised Speech Representation Based Loss Functions for Speech Enhancement,” Proc. ICASSP, 2023.

[4] Y. Kim, et al., “Throat and Acoustic Paired Speech Dataset for Deep Learning-Based Speech Enhancement,” Scientific Data, 2026.

[5] D. Bagchi, P. Plantinga, A. Stiff, and E. Fosler-Lussier, “Spectral Feature Mapping with Mimic Loss for Robust Speech Recognition,” Proc. ICASSP, 2018.

[6] Y. Dissen, S. Yonash, I. Cohen, and J. Keshet, “Enhanced ASR Robustness to Packet Loss with a Front-End Adaptation Network,” Proc. Interspeech, 2024.

[7] K. Iwamoto, T. Ochiai, M. Delcroix, et al., “How Does End-to-End Speech Recognition Training Impact Speech Enhancement Artifacts?” Proc. ICASSP, pp. 11031-11035, 2024.

[8] H. Sato, T. Ochiai, M. Delcroix, et al., “Generic Speech Enhancement with Self-Supervised Representation Space Loss,” Frontiers in Signal Processing, vol. 5, 1587969, 2025.

[9] V. Pratap, et al., “Scaling Speech Technology to 1,000+ Languages,” JMLR, vol. 25, 2024.

[10] A. Babu, et al., “XLS-R: Self-supervised Cross-lingual Speech Representation Learning at Scale,” Proc. Interspeech, 2022.

[11] A. Radford, et al., “Robust Speech Recognition via Large-Scale Weak Supervision,” Proc. ICML, 2023.